

UNIVERSIDAD TECNOLÓGICA (UTEC)

ITRN

LICENCIATURA EN INGENIERÍA DE DATOS E INTELIGENCIA

ARTIFICIAL

Modelado predictivo de siniestros de tránsito basado en series temporales en Montevideo

Juan Lucas Pimentel Barreto - 54663222

Victor Samuel Uría Padilla - 54965630

Tutor:

Prof. Matias Leonardo López Pérez

20/09/2026

I. Declaración de autoría

Juan Lucas Pimentel Barreto (C.I. 5.466.322-2) y Víctor Samuel Uría Padilla (C.I. 5.496.563-0), estudiantes de la carrera Licenciatura en Ingeniería de Datos e Inteligencia Artificial en la Universidad Tecnológica del Uruguay, declaran que el presente informe entregado para su evaluación es original y de elaboración propia, lo que implica la no reproducción de fragmentos de obras no amparadas por el límite de cita, ni la copia o utilización de ideas, formulaciones, u otras, tomadas de cualquier obra, sin especificar su origen en el cuerpo del informe o en su lista de referencias bibliográficas.

Juan Lucas Pimentel Barreto	Víctor Samuel Uría Padilla
	

II. Resumen / Abstract

Índice

I. Declaración de autoría.....	1
II. Resumen / Abstract.....	2
III. Lista de cuadros, ilustraciones y tablas.....	5
Cuadros.....	5
Ilustraciones.....	5
Tablas.....	5
IV. Glosario de abreviaciones y definiciones.....	7
1. Introducción.....	10
1.1 Problema.....	10
1.2 Objetivos.....	11
1.2.1 Objetivo general.....	11
1.2.2 Objetivos específicos.....	11
1.3 Alcance.....	12
1.4 Limitaciones.....	13
2. Marco conceptual.....	14
2.1 Revisión de la literatura.....	14
2.1.1 La siniestralidad vial como problema público y como objeto de medición....	14
2.1.2 Modelos clásicos de series temporales aplicados a la siniestralidad.....	14
2.1.3 Aprendizaje automático y predicción espacialmente desagregada.....	14
2.1.4 Las condiciones meteorológicas como variables exógenas.....	15
2.1.5 Síntesis de los antecedentes revisados.....	15
2.1.6 Brechas identificadas.....	16
2.2 Definición de conceptos.....	17
2.2.1 Siniestro de tránsito y unidad de análisis.....	17
2.2.2 Serie temporal, componentes y estacionariedad.....	17
2.2.3 Datos de conteo, sobredispersión y exceso de ceros.....	17
2.2.4 Variables exógenas, rezagos y variables derivadas.....	18
2.2.5 Fuga de información y validación temporal.....	18
2.2.6 Métricas de evaluación.....	18
2.3 Modelos y estructuras.....	19
2.3.1 Línea base.....	19
2.3.2 Modelos de series temporales: evaluación de viabilidad.....	19
2.3.3 Reformulación como problema de aprendizaje supervisado.....	21
2.3.4 Árboles de decisión.....	21
2.3.5 Modelos locales y globales, y reserva de zonas.....	22
2.3.6 Explicabilidad e interpretación.....	22
2.4 Relación con la investigación.....	23
3. Metodología.....	24
3.1 Tipo de investigación.....	24
3.2 Contexto de la investigación.....	24
3.2.1 Ámbito territorial y unidad de análisis.....	24

3.2.2 Continuidad con el Proyecto de Ingeniería de Datos.....	24
3.2.3 Delimitación temporal del período de estudio.....	25
3.3 Instrumentos de recolección de datos.....	25
3.3.1 Procedimiento de diagnóstico de los datos.....	25
3.4 Procedimientos de análisis de datos.....	26
3.4.1 Preparación del conjunto de modelado.....	26
3.4.2 Construcción y selección de variables.....	27
3.4.3 Diseño de la evaluación: particiones, validación y métricas.....	27
3.4.4 Medidas contra la fuga de información.....	29
3.4.5 Referencias, línea base y modelos evaluados.....	31
3.4.6 Entorno de ejecución y reproducibilidad.....	32
3.5 Aspectos éticos.....	33
4. Resultados.....	34
4.1 Diagnóstico de los datos.....	34
4.1.1 Calidad.....	34
4.1.2 Cobertura.....	35
4.1.3 Adecuación al problema.....	36
4.1.4 Limitaciones de los datos y amenazas a la validez.....	38
4.2 Conjunto de datos preparado.....	39
4.3 Línea base y resultados preliminares.....	40
4.3.1 Desempeño en validación interna.....	40
4.3.2 Desempeño en el bloque final, evaluado preliminarmente en E2.....	41
4.3.3 Lectura de los resultados preliminares.....	43
Referencias bibliográficas.....	44
Anexos.....	46
Anexo A – Procedencia y verificación de las fuentes.....	46
Anexo B – Calidad: faltantes y valores atípicos.....	46
Anexo C – Cobertura territorial por municipio.....	48
Anexo D – Estructura temporal de las series.....	49
Anexo E – Preparación: cobertura de las acciones y verificación.....	50
Anexo F – Resultados complementarios de la línea base.....	52
F.1 Ejecución en el servidor institucional.....	53

III. Lista de cuadros, ilustraciones y tablas

Cuadros

Cuadro 1 – Resumen de los principales artículos del marco conceptual

Cuadro 2 – Métricas de evaluación y su papel en la comparación

Cuadro 3 – Medidas contra la fuga de información

Cuadro 4 – Modelos evaluados bajo el protocolo común

Cuadro 5 – Limitaciones de los datos y su tratamiento

Cuadro E1 – Cobertura de las acciones de preparación (Anexo E)

Cuadro E2 – Decisiones de limpieza y transformación (Anexo E)

Ilustraciones

Las ilustraciones se presentan en los anexos.

Ilustración B1 – Cobertura temporal del registro, con el tramo excluido señalado (Anexo B).

Ilustración C1 – Distribución territorial de los siniestros acumulados por municipio (Anexo C).

Ilustración D1 – Autocorrelación por municipio, observada y sobre el residuo, frente a la banda nula (Anexo D).

Ilustración F1 – Observado y predicho en el **bloque final** por la referencia con calendario, la media constante y el árbol B (Anexo F).

Ilustración F2 – Volumen mensual predicho y observado, dispersión entre lo predicho y lo observado en el bloque final (Anexo F).

Tablas

Tabla 1 – Particiones cronológicas del conjunto

Tabla 2 – Autocorrelación por municipio frente a la banda nula de Poisson

Tabla 3 – Aporte de cada bloque de información, medido en desviación de Poisson

Tabla 4 – Desempeño en validación interna por origen móvil

Tabla 5 – Desempeño en el bloque final, evaluado preliminarmente en E2 (47 semanas, 329 días)

Tabla A1 – Fuentes de datos, procedencia y verificación

Tabla A2 – Recorte del archivo al alcance del proyecto

Tabla B1 – Faltantes codificados como texto, por columna

Tabla B2 – Valores atípicos de la serie diaria del departamento, según dos criterios de Tukey

Tabla B3 – Cobertura temporal y evolución interanual

Tabla C1 – Cobertura territorial por municipio

Tabla C2 – Caracterización del panel según la partición territorial

Tabla D1 – Estructura temporal de las series de los municipios C y A

Tabla E1 – Verificación cruzada entre dos implementaciones independientes

Tabla F1 – Efecto de limitar la profundidad del árbol B

Tabla F2 – Importancia de variables del árbol B, por reducción de impureza

Tabla F3 – Volumen mensual predicho y observado del árbol B en el bloque final

Tabla F4 – Variabilidad semanal de la desviación en el bloque final

IV. Glosario de abreviaciones y definiciones

ACF (*Autocorrelation Function*) Función de autocorrelación. Definida en 2.2.2.

ADF (*Augmented Dickey-Fuller*) Prueba de raíz unitaria. Su hipótesis nula es la presencia de una raíz unitaria; rechazarla es evidencia a favor de la estacionariedad en media.

ARIMA / SARIMA / SARIMAX (*Autoregressive Integrated Moving Average*) Familia de modelos de series temporales que combina términos autorregresivos, de diferenciación y de media móvil. SARIMA agrega un componente estacional y SARIMAX, además, regresores exógenos.

Backtesting Procedimiento de evaluación de un método de pronóstico que reproduce su uso operativo sobre datos históricos, desplazando sucesivamente el momento desde el cual se predice.

Banda nula Rango de valores de una estadística compatible con la hipótesis de ausencia de estructura, obtenido aquí por simulación de series de Poisson con la tasa media de cada municipio.

Bloque final Tramo cronológico final de la serie (06/02/2025–31/12/2025), definido al inicio como conjunto de evaluación. Fue consultado durante el desarrollo del Entregable 2, por lo que no constituye un conjunto reservado e independiente; su uso efectivo se detalla en la Sección 3.4.4.

Box-Cox Familia de transformaciones de potencia indexada por un parámetro λ , utilizada para estabilizar la varianza. Un λ cercano a 0 corresponde al logaritmo y uno cercano a 0,5, a la raíz cuadrada.

Calibración Correspondencia entre la intensidad predicha por un modelo y la frecuencia efectivamente observada en los casos a los que asignó esa intensidad.

Centinela Valor de texto que codifica un dato faltante sin utilizar la representación nula del formato de archivo.

Desvianza de Poisson Medida de discrepancia entre valores observados y predichos apropiada para variables de conteo; pondera el error por el nivel esperado del conteo (McCullagh y Nelder, 1989).

EPSG:4326 Sistema de referencia de coordenadas geográficas WGS 84.

ETL (*Extract, Transform, Load*) Proceso de extracción, transformación y carga de datos.

Fuga de información Utilización, durante el entrenamiento o la selección de un modelo, de datos que no estarían disponibles en el momento real de la predicción.

Índice de dispersión Cociente entre la varianza y la media de una variable de conteo. Un valor cercano a 1 es compatible con un proceso de Poisson.

KPSS (*Kwiatkowski-Phillips-Schmidt-Shin*) Prueba de estacionariedad. Su hipótesis nula es la opuesta a la del ADF: que la serie es estacionaria.

Línea base Punto de referencia inicial, simple y reproducible, frente al cual se juzga si un modelo posterior aporta una mejora real.

Ljung-Box Prueba conjunta de ausencia de autocorrelación hasta un rezago dado, aplicada aquí a la serie de un municipio.

MAE (*Mean Absolute Error*) Promedio del valor absoluto de la diferencia entre lo predicho y lo observado. Se expresa en siniestros por día.

Origen móvil Esquema de validación temporal en el que el punto de corte entre entrenamiento y evaluación se desplaza hacia adelante y el procedimiento se repite.

PACF (*Partial Autocorrelation Function*) Función de autocorrelación parcial: la correlación entre dos observaciones separadas por k períodos, descontado el efecto de los rezagos intermedios.

Panel Estructura de datos en la que cada fila corresponde a la combinación de una unidad transversal y un período. Aquí, el par (día, municipio).

PID Proyecto de Ingeniería de Datos, asignatura previa del mismo equipo, de la que este proyecto hereda datos y activos.

Predicción recursiva Esquema en el que, para predecir más de un período hacia adelante, el modelo utiliza sus propias predicciones como entrada de los pasos siguientes. Se opone al esquema directo, que solo usa valores observados.

RMSE (*Root Mean Squared Error*) Raíz del promedio de los errores al cuadrado. Pondera más los errores grandes que el MAE.

Sobredispersión Situación en la que la varianza de una variable de conteo supera a su media, lo que contradice el supuesto de un proceso de Poisson puro.

TRL (*Technology Readiness Level*) Escala de nivel de madurez tecnológica. El nivel 5 corresponde a la validación de un prototipo en un entorno relevante.

UNASEV Unidad Nacional de Seguridad Vial.

Ventana expansiva Variante del origen móvil en la que el tramo de entrenamiento crece en cada corte, en lugar de desplazarse conservando una longitud fija (ventana deslizante).

WFS (*Web Feature Service*) Protocolo estándar de acceso a datos geográficos vectoriales.

WMS (*Web Map Service*) Protocolo estándar de publicación de mapas como imágenes. Su documento de capacidades se utilizó para localizar la capa territorial, que luego se descargó por WFS.

1. Introducción

La información sobre siniestralidad vial disponible en Uruguay permite describir detalladamente lo ocurrido en términos históricos, pero carece de capacidad para anticipar eventos a la escala en que se planifica la gestión pública. Este trabajo propone como horizonte de uso siete días y como unidad territorial el municipio, escala en la que una estimación prospectiva podría incorporarse a la planificación de operativos; la periodicidad efectiva con que se adoptan hoy las decisiones operativas de fiscalización no se documenta en este informe. Entre los agregados anuales y departamentales que se publican y esa escala de uso propuesta existe una brecha, que este trabajo atiende transformando los registros históricos en estimaciones prospectivas que respalden la toma de decisiones basada en evidencia.

Concretamente, el proyecto busca estimar la cantidad esperada de siniestros de tránsito registrados por municipio y por día en el departamento de Montevideo, considerando un horizonte de predicción de siete días. Para ello, el estudio utiliza tres insumos principales sobre un período de 1.645 días (comprendido entre el 1.º de julio de 2021 y el 31 de diciembre de 2025): el registro nacional de la Unidad Nacional de Seguridad Vial (UNASEV), del cual se seleccionaron 36.612 hechos tras aplicar los criterios de recorte sobre un total original de 224.694; la cartografía oficial de los ocho municipios de Montevideo; y una serie meteorológica diaria departamental.

1.1 Problema

Esta falta de capacidad prospectiva en la gestión pública responde principalmente al nivel de agregación espacial y temporal de los insumos disponibles. Actualmente, los informes oficiales publican agregados anuales por departamento y el antecedente nacional de modelado proyecta la serie de personas lesionadas del país con periodicidad mensual (Unidad Nacional de Seguridad Vial, 2025, 2026). Ninguno de los dos formatos responde la pregunta que enfrenta quien debe decidir dónde concentrar un operativo de fiscalización la semana próxima, o si conviene reforzar la presencia en determinada zona durante un fin de semana largo.

El problema se formula, en consecuencia, como la **estimación de la cantidad esperada de siniestros de tránsito por municipio y por día en el departamento de Montevideo**, a partir del registro histórico y de las variables de calendario y meteorológicas disponibles, evaluada con un protocolo que respete el orden temporal de los datos y que

compare las alternativas propuestas, con diferentes parámetros y ajustes, contra una línea base correctamente especificada.

Conviene delimitar el problema también por lo que no es. El objeto de la predicción no es el siniestro individual: los datos no permiten anticipar en qué esquina ni a qué hora ocurrirá un hecho, y ninguna afirmación de ese tipo se deriva de este trabajo. Tampoco es la estimación del riesgo por unidad de exposición, puesto que no se dispone de datos de volumen de tránsito: lo que se modela es la cantidad de siniestros **registrados**, no la probabilidad de siniestro por viaje. La distinción no es una salvedad formal. Un municipio con más siniestros registrados no es necesariamente el más peligroso para quien circula por él, y el informe se abstiene deliberadamente de esa lectura.

La pertinencia del abordaje desde la ingeniería de datos y la inteligencia artificial se apoya en que el insumo existe y está infrautilizado. El registro nacional acumula más de doscientos mil hechos georreferenciados, la cartografía oficial de los municipios es de acceso abierto y las series meteorológicas históricas están disponibles mediante servicios públicos. Lo que falta no es el dato, sino el procedimiento que lo convierta en una estimación con su margen de error declarado.

1.2 Objetivos

1.2.1 Objetivo general

Desarrollar un modelo de aprendizaje automático para la predicción de siniestros de tránsito a partir de series temporales e integrar sus resultados en una interfaz que permita visualizar las zonas y períodos con mayor cantidad esperada de siniestros.

1.2.2 Objetivos específicos

- **Adaptar el proceso ETL** del Proyecto de Ingeniería de Datos para obtener la granularidad temporal requerida y reutilizar las variables exógenas ya disponibles, evitando nuevas llamadas recurrentes a APIs externas con límite de uso.
- **Evaluar y comparar estrategias de entrenamiento y validación** (con y sin variables exógenas, ventana expansiva y ventana deslizante) mediante métricas de error estandarizadas.
- **Seleccionar el modelo con mejor desempeño y solidez**, documentando sus limitaciones y sesgos previsibles.

- **Implementar en el dashboard una nueva pestaña con interfaz gráfica intuitiva** que permita visualizar las predicciones y la distribución territorial de la cantidad esperada de siniestros sobre un mapa.

1.3 Alcance

El estudio se delimita en cuatro dimensiones. En lo territorial, se circunscribe al departamento de Montevideo y adopta como unidad espacial la división oficial en ocho municipios. La restricción responde a una recomendación del docente de la asignatura y el tutor, se fundamenta en dos consideraciones: Montevideo concentra el volumen de siniestros necesario para sostener series de conteo suficientemente pobladas, y el municipio constituye la partición administrativa oficial del departamento, con autoridades propias, lo que lo vuelve una unidad útil para la planificación territorial: una estimación referida a él puede traducirse en una decisión de gestión. En lo temporal, la serie analizada abarca desde el 1.º de julio de 2021 hasta el 31 de diciembre de 2025, con periodicidad diaria; el capítulo 3 documenta la evidencia que fundamenta el inicio del período.

La unidad de análisis es el par formado por un día y un municipio, y la variable objetivo es la cantidad de siniestros registrados en ese municipio durante ese día. Las variables explicativas comprenden el calendario, las condiciones meteorológicas diarias del departamento y la información derivada del propio historial de cada municipio. En cuanto al producto, el proyecto entrega un procedimiento reproducible que estima esa cantidad esperada, la evaluación de su desempeño con métricas desagregadas por municipio, y la integración de los resultados en el tablero heredado de la etapa anterior, a nivel de prototipo funcional en entorno relevante.

La evaluación de las predicciones se reporta de manera desagregada municipio por municipio y no únicamente de forma global, permitiendo que cada gobierno municipal analice la estimación de su propio territorio junto con su correspondiente margen de error.

Asimismo, la puesta a punto del protocolo metodológico se realizó sobre la serie de un único municipio antes de extender su aplicación al conjunto del panel.

Quedan fuera del alcance cuatro aspectos que conviene enunciar para evitar expectativas que el trabajo no satisface. No se modela la gravedad de los siniestros ni su distribución horaria, porque la agregación diaria por municipio descarta esas dimensiones del conjunto de modelado. No se estima el riesgo por unidad de exposición, por ausencia de datos de tránsito. No se predice la localización puntual de hechos individuales. Y no se

abordan las causas del fenómeno: el trabajo es predictivo y no explicativo en sentido causal, de modo que la asociación entre una variable y la cantidad de siniestros no autoriza a afirmar que la primera produzca la segunda.

1.4 Limitaciones

Las limitaciones del estudio se enuncian aquí de forma sintética y se retoman con su evidencia en el apartado 4.1.4, una vez presentado el diagnóstico que las sustenta.

- Subregistro: Los datos comprenden únicamente los siniestros registrados, siendo la fracción no registrada desconocida y potencialmente desigual entre municipios (ver 4.1.4).
- Ausencia de datos de exposición: La falta de datos sobre flujo vehicular limita las conclusiones a la cantidad esperada de siniestros registrados y no al riesgo por viaje (ver 4.1.4).
- Similitud territorial entre zonas: La escasa variabilidad entre los ocho municipios (razón máximo sobre mínimo de 1,71) estrecha el margen para ordenarlos por cantidad esperada de siniestros registrados y debilita la prueba de generalización (ver 4.1.4).
- Variables meteorológicas observadas: El uso de datos meteorológicos observados y no pronosticados establece una cota optimista respecto del desempeño en una operación real (ver 4.1.4).
- Restricciones del marco académico: Las limitaciones temporales y de recursos de la asignatura obligan a priorizar la solidez del procedimiento sobre la exploración exhaustiva (ver 4.1.4).

2. Marco conceptual

Este capítulo reúne el marco conceptual que sustenta las decisiones técnicas del proyecto, sistematizando la literatura relevante sobre series temporales, modelos predictivos de conteo y sus criterios de evaluación

2.1 Revisión de la literatura

La revisión se organizó en cuatro núcleos temáticos, que delimitan el espacio de decisiones técnicas del proyecto: la siniestralidad vial como problema público y como objeto de medición, los modelos clásicos de series temporales aplicados a su predicción, los enfoques de aprendizaje automático y la predicción espacialmente desagregada, y el papel de las condiciones meteorológicas como variables exógenas.

2.1.1 La siniestralidad vial como problema público y como objeto de medición

A escala global, los siniestros de tránsito constituyen una de las principales causas de mortalidad, cobrando aproximadamente 1,19 millones de vidas anuales (World Health Organization, 2023). En el marco del Decenio de Acción para la Seguridad Vial 2021-2030, la gestión y análisis de datos se concibe como un insumo estratégico para respaldar políticas públicas basadas en evidencia. A nivel local, la Unidad Nacional de Seguridad Vial registra la siniestralidad en Uruguay, donde el departamento de Montevideo concentra el mayor volumen absoluto de hechos en un entorno urbano denso y de alta frecuencia de interacciones.

2.1.2 Modelos clásicos de series temporales aplicados a la siniestralidad

La predicción mediante modelos autorregresivos estacionales (SARIMA) se apoya en la presencia de patrones periódicos semanales y anuales derivados de los ciclos de movilidad (Deretić et al., 2022). Aunque la metodología Box-Jenkins ofrece un marco formal de identificación y diagnóstico (Hyndman y Athanasopoulos, 2021), presenta limitaciones ante la coexistencia de múltiples frecuencias estacionales en series diarias. El antecedente nacional directo modela personas lesionadas a escala mensual y agregada (Unidad Nacional de Seguridad Vial, 2025), lo que evidencia la necesidad de desarrollar modelos con mayor resolución espacial y temporal.

2.1.3 Aprendizaje automático y predicción espacialmente desagregada

Al abordar la predicción espacialmente desagregada, surgen dificultades metodológicas como la frecuencia de conteos bajos o ceros en áreas reducidas, la interdependencia espacio-temporal entre zonas y la variabilidad no observada del comportamiento humano (de Medrano y Aznarte, 2021). Las revisiones sistemáticas señalan que los algoritmos de aprendizaje automático superan habitualmente a los modelos ARIMA en series complejas (Kontopoulou et al., 2023), utilizando enfoques basados en árboles y ensamblados (Géron, 2023). Sin embargo, se advierte una debilidad recurrente en la literatura: la omisión de líneas base estadísticas simples contra las cuales contrastar si la mejora de los modelos complejos es real.

2.1.4 Las condiciones meteorológicas como variables exógenas

El efecto de la meteorología depende de la escala temporal: a nivel diario, la precipitación incrementa el riesgo de siniestro, siendo este efecto más pronunciado cuanto mayor es la duración del período seco previo debido a la acumulación de residuos en el pavimento y la falta de costumbre de los conductores (Eisenberg, 2004). Esto justifica incorporar la lluvia mediante rezagos e indicadores derivados. Las series de reanálisis meteorológico histórico se obtienen mediante servicios abiertos como Open-Meteo (s. f.).

2.1.5 Síntesis de los antecedentes revisados

Cuadro 1 – Resumen de los principales artículos del marco conceptual

Autores (Año)	Título	Técnicas utilizadas	Metodología / Herramienta	Principales hallazgos y aportes
World Health Organization (2023)	Global status report on road safety 2023	Estadística descriptiva; indicadores comparados	Relevamiento global de registros nacionales	Dimensiona la siniestralidad como problema de salud pública y vincula las metas del Decenio de Acción con la calidad de los sistemas de información.
Eisenberg (2004)	The mixed effects of precipitation on traffic crashes	Regresión binomial negativa; rezagos de precipitación	Datos estado-día y estado-mes, EE. UU., 1975-2000	La precipitación aumenta el riesgo a escala diaria y puede reducirlo a escala mensual. El riesgo crece con la duración del período seco previo, lo que justifica el uso de rezagos.
Hyndman y Koehler (2006)	Another look at measures of forecast accuracy	Análisis comparado de métricas de error	Evaluación teórica y empírica sobre series heterogéneas	Muestra las limitaciones del MAPE ante valores nulos o cercanos a cero y propone el error escalado (MASE) como métrica robusta

Autores (Año)	Título	Técnicas utilizadas	Metodología / Herramienta	Principales hallazgos y aportes
				y comparable entre series.
de Medrano y Aznarte (2021)	A new spatio-temporal neural network approach for traffic accident forecasting	Redes neuronales espacio-temporales con variables exógenas	Predicción simultánea por barrio en Madrid, con datos urbanos y meteorológicos	Identifica la rareza de los siniestros, la interdependencia espacio-temporal y la dependencia del comportamiento humano como dificultades de la predicción desagregada.
Deretić et al. (2022)	SARIMA modelling approach for forecasting of traffic accidents	SARIMA; metodología Box-Jenkins	Identificación por ACF y PACF, estimación y diagnóstico de residuos	Confirma la pertinencia del enfoque estacional para series de siniestralidad y aporta un procedimiento reproducible de especificación y validación.
Kontopoulou et al. (2023)	A review of ARIMA vs. machine learning approaches for time series forecasting in data driven networks	ARIMA, SARIMA, SVM, árboles, potenciado de gradiente, híbridos	Revisión sistemática de estudios comparativos en cinco dominios	El aprendizaje automático supera a ARIMA en la mayoría de los casos, con excepciones. Advierte que muchos estudios omiten la comparación con una línea base estadística bien especificada.
Unidad Nacional de Seguridad Vial (2025)	Modelos SARIMA para la predicción de lesionados en siniestros de tránsito en Uruguay	SARIMA	Series nacionales de personas lesionadas	Antecedente nacional directo que valida el enfoque en el contexto uruguayo, aunque a nivel agregado y con menor granularidad temporal y espacial.

Fuente: elaborado por los autores.

2.1.6 Brechas identificadas

La revisión de la literatura permite identificar cuatro brechas principales:

- Granularidad espacial: en la revisión realizada no se identificaron antecedentes que modelen la siniestralidad a nivel intradepartamental o municipal en Montevideo.
- Granularidad temporal: Predominio de datos mensuales que diluyen el ciclo semanal y los eventos meteorológicos puntuales (Eisenberg, 2004).
- Ausencia de línea base: Omisión habitual de referencias estadísticas simples y bien especificadas en la literatura (Kontopoulou et al., 2023)

- Comparación bajo protocolo común: Escasez de evaluaciones que comparen modelos tradicionales y de aprendizaje automático sobre los mismos datos y métricas (Kontopoulou et al., 2023).

2.2 Definición de conceptos

2.2.1 Siniestro de tránsito y unidad de análisis

En este trabajo, un siniestro de tránsito es todo hecho ocurrido en la vía pública con participación de al menos un vehículo en movimiento del que resultan personas lesionadas y que es registrado por el organismo competente. La precisión es necesaria porque el registro utilizado contabiliza siniestros con personas lesionadas y no incluye los hechos con daños exclusivamente materiales (Unidad Nacional de Seguridad Vial, 2026); en consecuencia, ninguna afirmación de este informe se extiende a esa categoría.

2.2.2 Serie temporal, componentes y estacionariedad

Una serie temporal consiste en una secuencia cronológicamente ordenada de observaciones a intervalos regulares. El análisis clásico descompones la serie en tres componentes (Hyndman y Athanasopoulos, 2021): tendencia (movimiento de largo plazo), estacionalidad (patrón repetitivo de periodicidad fija, predominantemente semanal y anual) y componente irregular (variación no explicada). Para aplicar modelos de la familia ARIMA se requiere estacionariedad (constancia de media, varianza y autocorrelación en el tiempo), la cual suele lograrse mediante diferenciación. La identificación de órdenes en la metodología Box-Jenkins se apoya en la función de autocorrelación (ACF) y la autocorrelación parcial (PACF).

2.2.3 Datos de conteo, sobredispersión y exceso de ceros

La variable objetivo es un conteo entero no negativo. El grado de dispersión se evalúa mediante el índice de dispersión (cociente entre varianza y media): valores cercanos a uno corresponden a un proceso de Poisson, mientras que valores marcadamente superiores señalan sobredispersión e introducen el uso de la distribución binomial negativa (Eisenberg, 2004). Aunque la desagregación espacial fina suele inducir un exceso de ceros (de Medrano y Aznarte, 2021), la partición gruesa por municipios reduce marcadamente esa proporción y permite tratar el problema como una regresión de conteo ordinaria. El **balanceo de clases no corresponde**, porque la tarea es una regresión de conteo y no una clasificación. Respecto de los modelos con **inflación de ceros**, la

proporción observada por sí sola no demuestra su ausencia: lo que puede afirmarse es que, con el diagnóstico disponible, no hay evidencia suficiente para priorizar esa familia.

2.2.4 Variables exógenas, rezagos y variables derivadas

Las variables exógenas aportan información sin ser predichas por el modelo, abarcando en este estudio factores de calendario y series meteorológicas obtenidas de Open-Meteo (s. f.). Los rezagos (valores pasados de una variable) y las variables derivadas (como medias móviles o días transcurridos desde la última precipitación) permiten reformular la serie temporal como un problema de aprendizaje supervisado tabular. Se exige estrictamente que todo predictor esté disponible en el momento operativo de emitir la predicción.

2.2.5 Fuga de información y validación temporal

La fuga de información (data leakage) consiste en incorporar inadvertidamente datos futuros o no disponibles en el momento de la predicción durante el entrenamiento o selección del modelo. Su prevención requiere tres condiciones (Hyndman y Athanasopoulos, 2021): particiones cronológicas (validación y prueba estrictamente posteriores al entrenamiento), ajuste de transformaciones exclusivamente sobre el conjunto de entrenamiento, y validación por origen móvil (expanding window).

2.2.6 Métricas de evaluación

En un problema de conteo, el objetivo reside en estimar la intensidad esperada del proceso. La función de pérdida principal es la **desviación de Poisson**, que corresponde a la familia de la variable objetivo y pondera el error según el nivel esperado; el MAE y el RMSE la acompañan como secundarias, expresadas en siniestros por día. Se prescinde del error escalado (MASE) propuesto por Hyndman y Koehler (2006): no por una limitación del método ingenuo estacional, sino porque las métricas adoptadas resultan más pertinentes para el objetivo de este trabajo, ya que el MASE informa el error relativo a un método de referencia y no permite leer el error en la unidad en que se planifica.

La evaluación atiende además a la **calibración** —la correspondencia entre la intensidad predicha y la frecuencia observada— y al **ordenamiento** de las zonas según su cantidad esperada de siniestros registrados. En este hito la calibración se informa únicamente mediante la razón entre el total predicho y el total observado, que describe el volumen

agregado; una verificación completa exigiría contrastar lo predicho con lo observado por estratos de intensidad y queda para el Entregable 3.

2.3 Modelos y estructuras

2.3.1 Línea base

Una **línea base** es un punto de referencia inicial, simple y reproducible, que permite determinar si los modelos posteriores aportan una mejora real. Su función no es competir con los modelos candidatos sino calibrar la interpretación de sus métricas: una reducción del error que no supere con claridad a la línea base indica que la complejidad adicional no está justificada.

La referencia habitual en series con estacionalidad semanal es el método ingenuo estacional, que predice para cada zona y día el valor observado en el mismo día de la semana anterior. Ese método presupone persistencia temporal dentro de cada zona, supuesto que debe verificarse antes de adoptarlo: si la autocorrelación de las series por zona no supera la banda que produciría un proceso de Poisson sin memoria, la regla carece de fundamento y su desempeño sería el de un generador de ruido. La línea base adoptada en este trabajo prescinde de esa suposición y descompone la intensidad esperada en dos factores: la **tasa histórica de la zona**, estimada exclusivamente sobre el tramo de entrenamiento, y un **factor de calendario** asociado al tipo de día. Esa construcción recoge las dos fuentes de variación que el análisis exploratorio identifica como reales, la diferencia estructural entre zonas y el ciclo semanal, sin atribuir a la serie una memoria de corto plazo mayor que la observada. La forma multiplicativa se prefiere frente al cruce saturado de zona por día, que estima un parámetro independiente para cada celda: al multiplicar el número de parámetros por el de combinaciones, ese cruce reparte las observaciones en grupos pequeños y su desempeño fuera de muestra puede resultar peor que el de una constante.

2.3.2 Modelos de series temporales: evaluación de viabilidad

La familia de modelos autorregresivos integrados de media móvil (ARIMA) y su extensión estacional con regresores exógenos (SARIMAX; ver definiciones en el Glosario) constituye la aproximación clásica predominante en la literatura sobre siniestralidad (Deretić et al., 2022) y el enfoque empleado por el antecedente nacional (Unidad Nacional de Seguridad Vial, 2025)

Por esta razón, la decisión de **no priorizar su aplicación** en este proyecto requiere un fundamento explícito, apoyado en las propiedades del panel de datos y en el alcance del trabajo.

Su aplicabilidad a un panel de zonas depende de tres condiciones. La primera es que el conteo por unidad y período resulte suficientemente alto para sostener la aproximación normal sobre la que se estiman los parámetros. La segunda es que las series individuales presenten autocorrelación distinguible del ruido que produciría un proceso de Poisson sin memoria; en ausencia de ella, la identificación por la metodología de Box-Jenkins converge a una especificación sin términos autorregresivos ni de media móvil, es decir, a la media de la serie, y el esfuerzo de especificación no produce modelo alguno. La tercera es que el componente estacional aporte información que las variables de calendario no contengan ya: si al descontar el día de la semana y los feriados la autocorrelación en el rezago estacional desaparece, ese componente resulta redundante con un regresor que cualquier modelo puede incorporar.

La evaluación de aplicabilidad sobre el diagnóstico del panel arroja lo siguiente: el conteo medio por zona es suficiente; la autocorrelación en el primer rezago supera la banda nula en cinco de los ocho municipios (**Tabla 2**); y, al descontar las variables de calendario, ningún municipio conserva autocorrelación en el rezago siete, de modo que el componente estacional estricto resulta redundante frente a un regresor de calendario que cualquier modelo puede incorporar. A ello se suma que el conjunto de evidencias sobre la estructura temporal no respalda diferenciar ni transformar la varianza (ver 4.1.3), y que la formulación estándar admite un único período estacional, insuficiente para representar simultáneamente los patrones semanal y anual (Hyndman y Athanasopoulos, 2021).

Estos elementos no vuelven inaplicable la familia SARIMA/SARIMAX: una especificación de esa familia puede ajustarse sobre estas series. Lo que indican es que su aporte esperado sobre este problema resulta reducido —quedaría esencialmente un término autorregresivo de primer orden, que se conserva directamente como atributo en los modelos supervisados— frente a un costo alto de especificación y diagnóstico por municipio. **La decisión de no priorizarla es, por lo tanto, de pertinencia, costo y alcance, y no de validez técnica.**

Respuesta a la observación del Comité Académico. El Comité aprobó la propuesta con la condición de acotar la cantidad de modelos y de evaluar en particular la demanda técnica y de tiempo asociada a SARIMA. En respuesta, el proyecto trabaja con un conjunto reducido de alternativas y no acumula familias de modelos. SARIMA/SARIMAX

se evaluó como enfoque posible y no se prioriza en la experimentación principal, por la relación entre su aporte esperado sobre estas series, la complejidad de especificación y diagnóstico que exigiría en un panel de ocho zonas, y el tiempo disponible en la asignatura. Esta decisión no supone que SARIMA sea técnicamente inválido en general ni para series de siniestralidad: el propio antecedente nacional lo emplea a escala mensual y agregada (Unidad Nacional de Seguridad Vial, 2025). La lista de modelos y variantes que integran la comparación del Entregable 3 quedará cerrada antes de comenzar esa comparación.

2.3.3 Reformulación como problema de aprendizaje supervisado

Los algoritmos de aprendizaje automático de propósito general no operan directamente sobre series temporales, sino sobre matrices de observaciones y atributos. La reformulación consiste en construir, para cada par zona-período, un vector de atributos compuesto por rezagos de la variable objetivo, estadísticos de ventanas móviles, variables de calendario, variables meteorológicas contemporáneas y rezagadas, y un identificador de zona; la variable objetivo pasa a ser el conteo del horizonte de predicción definido. De ahí que la ingeniería de características ocupe un lugar central: la información temporal que los modelos ARIMA capturan por construcción debe proveerse explícitamente mediante los atributos (Géron, 2023).

2.3.4 Árboles de decisión

Un **árbol de decisión** particiona recursivamente el espacio de atributos mediante cortes binarios que minimizan una medida de error, y asigna a cada región resultante un valor de predicción. Para un objetivo de conteo el criterio de división admite dos opciones: el **error cuadrático**, que es el criterio por omisión de la implementación empleada, y la **desviación de Poisson**, que coincide con la pérdida natural de la familia y elige las particiones por su capacidad de separar regiones de distinta intensidad esperada. El modelo base de este trabajo se ajusta con el criterio por omisión, de modo que la referencia aprendida quede definida por la configuración más simple disponible y el efecto del criterio pueda medirse después como una variación deliberada bajo el mismo protocolo. La elección se declara porque condiciona la lectura de los resultados del apartado 4.3: el modelo minimiza durante el ajuste una pérdida distinta de aquella con la que se lo evalúa. El modelo presenta tres propiedades relevantes para el problema planteado: representa relaciones no lineales e interacciones sin especificarlas previamente, no requiere estacionariedad ni normalidad, y admite atributos de naturaleza heterogénea en una misma matriz.

La elección de un árbol único, en lugar de los métodos de conjunto que dominan la literatura comparativa (Kontopoulou et al., 2023), responde a dos consideraciones. La primera es la explicabilidad: un árbol de profundidad acotada puede representarse íntegramente y sus reglas admiten lectura directa, propiedad que los conjuntos de cientos de árboles pierden y que solo recuperan de manera aproximada mediante técnicas de atribución y explicabilidad. La segunda es que la capacidad del modelo no constituye necesariamente la restricción operativa del problema: cuando la información disponible impone un techo de mejora reducido, un modelo de mayor capacidad no puede superarlo y la complejidad adicional se traduce en varianza antes que en desempeño. Las limitaciones del árbol único deben declararse igualmente, en particular su alta varianza y su incapacidad de extrapolar fuera del rango observado, lo que obliga a tratar cualquier tendencia sostenida mediante atributos explícitos. Los métodos de conjunto que desarrolla Géron (2023) constituyen la extensión natural del enfoque y se señalan como trabajo futuro.

2.3.5 Modelos locales y globales, y reserva de zonas

La desagregación por zona plantea una decisión estructural. Un **modelo local** ajusta una especificación independiente para cada zona, lo que permite capturar dinámicas propias pero reduce las observaciones disponibles por modelo y multiplica el número de especificaciones a mantener. Un **modelo global** ajusta una única especificación sobre el conjunto de todas las zonas, incorporando atributos de nivel de zona, lo que aprovecha la información compartida entre unidades y resulta conveniente cuando los conteos individuales son bajos (de Medrano y Aznarte, 2021).

La **reserva de zonas** se complica cuando las unidades son pocas: cada exclusión altera de manera apreciable el conjunto restante, de modo que el procedimiento defendible consiste en excluir una zona por vez y promediar el desempeño sobre todas las exclusiones, asumiendo que la estimación resultante tiene varianza alta. A ello se añade que, cuanto más se parecen las zonas entre sí, menor es el margen para que un modelo las ordene por su cantidad esperada de siniestros registrados.

2.3.6 Explicabilidad e interpretación

La explicabilidad se entiende aquí como la capacidad de fundamentar el comportamiento del modelo a partir de evidencias obtenidas durante su desarrollo y evaluación, y no como una propiedad intrínseca del algoritmo. Los recursos disponibles difieren según el modelo. En la línea base multiplicativa, cada factor es directamente legible: la tasa de la

zona expresa su nivel estructural y el factor de calendario, la modulación semanal. En un árbol de decisión de profundidad acotada, la estructura completa de reglas es representable y auditable, lo que permite verificar qué cortes sobre qué variables generan cada predicción; a ello se agregan la importancia de atributos calculada por permutación, que mide la degradación del desempeño al alterar aleatoriamente una variable, y los valores de atribución por observación. A ello se suman el análisis de residuos por zona y período y la inspección de los casos de mayor error.

2.4 Relación con la investigación

La estructura del proyecto responde de manera directa a los conceptos del marco conceptual. La definición de la unidad de análisis a nivel de par día-municipio resuelve la granularidad espacial y temporal requerida para la gestión. El bloque de variables exógenas incorpora los factores de calendario y meteorológicos, incluyendo el indicador de período seco previo fundamentado por Eisenberg (2004). El diseño de evaluación adopta particiones estrictamente cronológicas y validación por origen móvil (Hyndman y Athanasopoulos, 2021), empleando la desviación de Poisson como métrica principal por la naturaleza de conteo de la variable objetivo y juzgando todo desempeño frente a una línea base explícita y correctamente especificada (Kontopoulou et al., 2023)

3. Metodología

3.1 Tipo de investigación

La investigación es **aplicada** y de enfoque **cuantitativo**. Busca resolver un problema práctico: estimar con anticipación la cantidad de siniestros de tránsito en una unidad territorial de gestión, con su margen de error declarado. Toda la evidencia proviene de registros administrativos y series numéricas, sin recolección de datos primarios. El estudio es **descriptivo** en una primera etapa (caracterización de fuentes, calidad y cobertura) y **predictivo** en la segunda (estimación fuera de muestra), y no tiene alcance explicativo ni causal. Por la dependencia cronológica de las observaciones y el riesgo de fuga de información (Secciones 2.2.2 y 2.2.5), el diseño prescinde de particiones aleatorias y adopta un esquema cronológico con validación por origen móvil (Sección 3.4.3).

3.2 Contexto de la investigación

3.2.1 *Ámbito territorial y unidad de análisis*

El ámbito es el departamento de Montevideo, particionado en sus **ocho municipios** oficiales (A, B, C, CH, D, E, F y G), y la unidad de análisis es el par (**día, municipio**) definido en la Sección 2.2.1, organizado como un panel con ceros explícitos. Cada hecho se asigna a su municipio por **intersección punto-polígono** entre sus coordenadas de origen y la capa vectorial oficial (Intendencia de Montevideo, 2026); como los límites discurren mayoritariamente sobre avenidas y cursos de agua de gran porte, el riesgo de error en los bordes es menor que con unidades más pequeñas. La contrapartida de la partición gruesa se analiza en la Sección 4.1.2.

3.2.2 *Continuidad con el Proyecto de Ingeniería de Datos*

El estudio hereda del Proyecto de Ingeniería de Datos (PID) el registro nacional unificado y georreferenciado de siniestros, la reproyección de coordenadas a EPSG:4326, el vocabulario de codificación y la estructura base del tablero. El procedimiento de preparación para el modelado, en cambio, se rediseñó por completo: cambió la unidad de análisis al par día-municipio, se sustituyeron las bases relacionales por archivos planos que se ejecutan sin infraestructura asociada, se fijó y verificó el formato de fecha, se incorporó el tratamiento de duplicados y se consolidó el bloque meteorológico en una serie diaria única.

3.2.3 Delimitación temporal del período de estudio

El período abarca del **1.º de julio de 2021 al 31 de diciembre de 2025**, con frecuencia diaria. El corte inicial excluye el primer semestre de 2021, cuyo nivel aparece deprimido de forma atípica. Una explicación posible, que este trabajo no verifica, son las restricciones de movilidad vigentes durante ese período en el marco de la pandemia de COVID-19; el informe no aporta evidencia que establezca esa relación y la decisión de recorte se funda únicamente en el comportamiento de la propia serie. La decisión se fundamentó en tres pasos, cuyos resultados se presentan en la Sección 4.1.2: verificar el nivel deprimido, descartar mediante el índice estacional mensual que respondiera a un nivel anual más bajo, y comprobar que el tramo conservado encadena con las variaciones interanuales ordinarias. El recorte conserva la tendencia creciente del período, que se trata en el modelado.

3.3 Instrumentos de recolección de datos

La investigación se apoya en tres fuentes secundarias, cuya procedencia se detalla en el Anexo A (Tabla A1). En cada ejecución, los procedimientos calculan la huella criptográfica sha256 de cada archivo y la comparan con la registrada, de modo que cada resultado puede atribuirse a una versión determinada de los datos: es el primer eslabón de la trazabilidad entre dato, código y resultado.

El **registro de siniestros**, incorporado a través del PID, es el registro nacional de la Unidad Nacional de Seguridad Vial (UNASEV), con 224.694 hechos y 11 columnas, todos con personas lesionadas. Sus coordenadas asignadas en origen permiten la asignación territorial directa, sin geocodificación de texto. La **cartografía de municipios** proviene del servidor geográfico institucional de la Intendencia de Montevideo (2026); se obtuvo el 7 de setiembre de 2026 por WFS, en formato GeoJSON y EPSG:4326, y define los polígonos de los ocho municipios sin costos ni restricciones de uso. La **serie meteorológica** es una serie diaria única para el departamento, obtenida de Open-Meteo (s. f.) para las coordenadas $-34,87$ y $-56,17$ y almacenada localmente; asume uniformidad espacial, ya que aporta variación temporal común pero no explica diferencias entre municipios, y usa datos observados y no pronosticados, por lo que cualquier desempeño que dependa de ella sería una cota optimista (Secciones 2.1.4 y 2.2.4). En este hito ningún modelo la utiliza.

3.3.1 Procedimiento de diagnóstico de los datos

El diagnóstico evalúa la completitud, la cobertura, la adecuación y las limitaciones del panel de ocho municipios, y reconstruye el panel de forma independiente desde las fuentes crudas para contrastarlo con la salida de la preparación. Se complementa con un análisis de estructura temporal —tendencia, estacionalidad, autocorrelación, estacionariedad y transformaciones— sobre dos series individuales: la del **Municipio C**, el de mayor volumen registrado, y la del **Municipio A**, de volumen intermedio, que actúa como contraste. El recorte aplicado deja una base de **36.612** siniestros en ocho municipios y 1.645 días, tras retener Montevideo (62.427 registros), acotar el período, eliminar 90 duplicados exactos y descartar 11 hechos fuera de todo polígono; el detalle paso a paso está en el Anexo A (Tabla A2).

3.4 Procedimientos de análisis de datos

3.4.1 Preparación del conjunto de modelado

La preparación se ejecutó como un procedimiento integral que extrae del archivo original, limpia, recorta al alcance, asigna cada siniestro a su municipio y construye el panel con ceros explícitos. Cinco decisiones determinan el conjunto resultante y se detallan, con su justificación y su efecto, en el Anexo E (Cuadro E2): eliminar los duplicados exactos, que antes de su eliminación convertían el máximo del objetivo en un artefacto de carga; fijar el formato de fecha y verificarlo contra el día de la semana declarado, que lo explica en su totalidad; descartar las columnas de gravedad, que agregadas por día suman exactamente el objetivo y serían una fuga perfecta; resumir el calendario en una categórica de tres niveles, que conserva el 22,3 % de la varianza diaria frente al 20,8 % que explica el día de la semana; y mantener el panel sin variables de nivel de zona, con una verificación automática que detiene la ejecución si alguna se incorpora. El Anexo E (Cuadro E1) contrasta cada acción de preparación con las pautas de la asignatura y deja constancia de las que no corresponden a este problema: la imputación, porque no hay faltantes; el balanceo, porque no hay clases; la transformación del objetivo, desaconsejada por la Sección 4.1.3; el escalado, innecesario para los modelos evaluados; y la reducción de dimensionalidad, sobre doce columnas.

Se descartaron además las columnas constantes tras el recorte (departamento e indicador de geocodificación) y las que no sobreviven a la agregación diaria (hora, calle y tipo de siniestro), y se verificó que todas las coordenadas caen dentro del país.

El procedimiento incorpora 16 verificaciones automáticas que detienen la ejecución ante una falla de integridad (Sección 4.2 y Anexo E). La agregación municipal reduce los ceros

al 8,60 %. El balanceo no corresponde, porque la tarea es una regresión de conteo; y con el diagnóstico disponible no hay evidencia suficiente para priorizar modelos con inflación de ceros (Sección 2.2.3).

3.4.2 Construcción y selección de variables

Las variables se organizan en tres bloques (Sección 2.2.4), con distinto grado de uso en este hito:

1. **Historia de la serie.** Rezagos de la variable objetivo, contruidos al modelar con valores observados antes del origen de cada predicción. Los modelos sin variables exógenas usan solo este bloque.
2. **Calendario.** Variable categórica de tres niveles (día entre semana, fin de semana y feriado), con los feriados oficiales y bancarios: 77 días en el período, incluidos Carnaval y Semana de Turismo. La usan la referencia con calendario y el árbol con calendario; este último recibe además el tiempo transcurrido en años.
3. **Meteorología.** Temperaturas media, máxima y mínima, precipitación, velocidad del viento, un código de estado del tiempo en cinco niveles y un indicador de lluvia (más de 0,1 mm). Está disponible en el conjunto preparado, pero ningún modelo de este hito la utiliza, porque el diagnóstico no encontró aporte fuera de muestra (Sección 4.1.3).

En el marco conceptual (Sección 2.2.4) tanto el calendario como la meteorología son variables exógenas. En lo que sigue, la expresión "**sin variables exógenas**" designa a los modelos que utilizan únicamente la historia de la serie —L0 y el árbol A—; los modelos con calendario (L1 y el árbol B) sí incorporan una variable exógena. **Ningún modelo de este hito utiliza meteorología.**

La **tasa histórica de cada municipio**, el bloque de nivel de zona, solo tiene sentido en el panel completo: se incorporará en el Entregable 3, estimada exclusivamente con el tramo de entrenamiento de cada partición. La selección excluye las variables que suman el objetivo, las constantes, las representaciones enteras de variables cíclicas y cualquier dato que no estaría disponible al emitir la predicción.

3.4.3 Diseño de la evaluación: particiones, validación y métricas

La serie se divide cronológicamente en un bloque de desarrollo (80 %) y un bloque final (20 %), cuyo uso efectivo en este hito se detalla en la Sección 3.4.4, según la Tabla 1.

Tabla 1 – Particiones cronológicas del conjunto

Bloque	Desde	Hasta	Días	Porcentaje
Entrenamiento inicial	2021-07-01	2024-03-13	987	60,0 %
Validación por origen móvil (ventana expansiva)	2024-03-14	2025-02-05	329	20,0 %
Bloque final (evaluado preliminarmente en E2)	2025-02-06	2025-12-31	329	20,0 %

Fuente: elaboración propia.

Validación interna. Dentro del desarrollo se aplica un **origen móvil con ventana expansiva** (Sección 2.2.5): el primer entrenamiento abarca los 987 días iniciales, el modelo predice los siete días siguientes, el origen avanza siete días y el ajuste se repite con todo lo observado antes de él, hasta completar **47 cortes**. El horizonte de siete días responde al uso propuesto por el proyecto: planificar la semana siguiente (Sección 1.1). La evaluación sobre el bloque final reproduce el esquema sobre sus 329 días, con el ajuste congelado en el desarrollo: solo avanza la historia observada que cada modelo necesita como entrada, como ocurriría en operación. La validación interna cubre los modelos con calendario y sus contrastes (Cuadro 4); los modelos sin exógenas se evaluaron **sobre el bloque final** con la misma partición y esquema, con configuraciones fijadas antes de ejecutar y sin selección de hiperparámetros, y su validación interna se hará en el Entregable 3.

Métricas. La principal es la **desvianza de Poisson media** (Sección 2.2.6), con las del Cuadro 2 como secundarias. La desvianza no está definida cuando la predicción vale cero: para calcularla, las predicciones nulas se reemplazan por 10^{-6} , mientras que el resto de las métricas usa las predicciones originales sin redondear. Como el aporte de un día con predicción nula y siniestros observados depende de ese valor, se informa la cantidad de días con predicción cero de cada modelo. No se informa el sesgo medio que registra base.ipynb: sobre la misma serie observada es una transformación de la razón total.

Cuadro 2 – Métricas de evaluación y su papel en la comparación

Métrica	Papel	Lectura
Desvianza de Poisson media	Principal: comparar y seleccionar	Pondera el error según el nivel esperado y penaliza más la subestimación; menor es mejor
MAE	Secundaria	Siniestros de diferencia por día, en promedio
RMSE	Secundaria	Como el MAE, pero pondera más los errores grandes
Total predicho / observado	Calibración del volumen agregado	1 indica volumen total correcto; menos de 1, subestimación. No informa sobre la calibración por día ni por nivel de intensidad

Métrica	Papel	Lectura
Días con predicción cero	Diagnóstica	Explica valores extremos de la desviación

Fuente: elaboración propia.

Los dos notebooks de modelado comparten partición, esquema y cálculo de métricas: la media constante, único modelo común, obtiene **sobre el bloque final** la misma desviación (1,2625 y 1,2620) y el mismo MAE (1,7411 y 1,7410) hasta el redondeo a tres decimales, lo que funciona como control cruzado del procedimiento.

3.4.4 Medidas contra la fuga de información

Para que ningún modelo reciba información que no tendría en operación se aplican las salvaguardas de la Sección 2.2.5, resumidas en el Cuadro 3. A ellas se suman dos medidas ya descritas en el Cuadro E2 (Anexo E): el descarte de las columnas de gravedad, que suman exactamente el objetivo, y la verificación automática que impide que el panel exportado contenga variables de nivel de zona.

Uso del bloque final en este hito. El bloque 06/02/2025–31/12/2025 se definió al inicio como tramo de evaluación, pero fue consultado en más de una ocasión durante el desarrollo del Entregable 2. Por lo tanto no puede presentarse como un conjunto reservado e independiente. Su uso efectivo fue el siguiente:

- Se evaluaron sobre él la media constante, repetir la semana anterior, L0, L1, el árbol A y el árbol B, con configuraciones fijadas antes de cada ejecución (Tabla 5).
- El notebook sin variables exógenas tuvo una versión previa, evaluada sobre ese mismo bloque con otra línea base y otros rezagos. Esa versión se reemplazó después de conocer sus resultados, al decidir que ningún modelo de ese notebook usaría calendario ni meteorología; sus cifras constan en el registro de experimentos del repositorio.
- Parte del diagnóstico que orientó la elección de rezagos y de bloques de variables se calculó sobre el período completo y, por lo tanto, incluye este tramo (Tabla 2 y segunda mitad de la Tabla 3).
- Tras observar los resultados de la Tabla 5 se tomaron tres decisiones que se informan en la Sección 4.3.3: mantener L0 pese a quedar por detrás de la media constante, fijar el tratamiento de la deriva de nivel como condición del modelado, y definir el conjunto de referencias del Entregable 3.

En consecuencia, los resultados del apartado 4.3 se presentan como evidencia exploratoria de desarrollo y no como una evaluación final. Este bloque no se utilizará para

nuevas decisiones de selección en el Entregable 3. La forma que tomará la evaluación final, dado que el período ya fue inspeccionado, queda registrada como decisión pendiente, a resolver con el docente de la asignatura y el tutor al inicio del Entregable 3; no se constituirá artificialmente otro tramo de prueba dentro de 2021–2025, porque esos datos también fueron consultados durante el diagnóstico.

Existe un tramo posterior al período de estudio: la Unidad Nacional de Seguridad Vial publicó los datos de siniestralidad del primer semestre de 2026. **A la fecha de este entregable ese tramo no fue descargado, inspeccionado ni utilizado en ninguna decisión del proyecto.** Se registra como la alternativa a evaluar para constituir la prueba final del Entregable 3, sujeta a cuatro condiciones que se resolverán con el docente y el tutor antes de acceder a él: que se mantenga sin inspeccionar hasta acordar el protocolo; que se verifique su esquema y su vocabulario con las mismas comprobaciones aplicadas al registro actual; que se declare su condición de dato preliminar, sujeto a revisión al consolidarse el año; y que se considere que cubre medio año y no un ciclo anual completo. La decisión no se toma en este hito.

Cuadro 3 – Medidas contra la fuga de información

Riesgo	Medida adoptada
Entrenar con datos posteriores a los evaluados	Partición estrictamente cronológica; el bloque final es el tramo final de la serie
Estimar parámetros con información futura	Toda media, factor o árbol se ajusta con la ventana de entrenamiento de cada corte. Sobre el bloque final, el ajuste queda congelado en el bloque de desarrollo
Realimentar predicciones como si fueran observaciones	Los modelos con rezagos de siete o más días no requieren recursión dentro del horizonte semanal. El árbol sin exógenas, que usa el rezago de un día, predice de forma recursiva: toma sus propias predicciones como ese rezago, nunca observaciones posteriores al origen
Dar a un modelo variables que no debe usar	Los modelos sin exógenas leen solo fecha, municipio y objetivo. El árbol informa sus variables (rezagos de 1, 7, 14 y 21 días) y la ausencia de exógenas
Usar el bloque final para ajustar parámetros	Ningún parámetro se estimó con ese tramo: el objeto que lo contiene no interviene entre la definición de las particiones y la evaluación. Riesgo no eliminado: el tramo fue consultado durante el desarrollo y sus resultados intervinieron en decisiones posteriores (Sección 3.4.4)
Elegir variables, rezagos o formas de modelo con información del bloque final	Riesgo declarado, no eliminado. El diagnóstico se calculó sobre el período completo: la segunda mitad de la Tabla 3

Riesgo	Medida adoptada
	contiene ese tramo , y los rezagos del árbol sin exógenas se apoyan en esa autocorrelación. Ningún parámetro se ajustó con él; en el Entregable 3 esos análisis se recalcularán solo con el bloque de desarrollo. Ese recálculo mejora el procedimiento hacia adelante, pero no revierte el uso ya realizado de este período.

Fuente: elaboración propia.

3.4.5 Referencias, línea base y modelos evaluados

Conforme a la Sección 2.3.1, la evaluación se organiza en **dos niveles de referencia**, definidos por la información que cada modelo puede usar, y ambos se contrastan con la media constante.

L0, línea base sin variables exógenas, predice cada día con el promedio de lo observado 7, 14, 21 y 28 días antes: usa solo la historia de la serie, recoge el ciclo semanal, atenúa el ruido de copiar una sola semana y acompaña los cambios de nivel, porque su ventana avanza. La cantidad de semanas se fijó antes de ejecutar y no se ajustó. **L1, referencia con calendario**, es la tasa histórica por factor de calendario, que con una sola serie se reduce a la media de entrenamiento de cada tipo de día; es la forma multiplicativa que el diagnóstico identificó como la mejor combinación fuera de muestra (Sección 4.1.3), aunque allí el factor distinguía el día de la semana y el feriado (14 medias). Todo modelo posterior se compara con la referencia de su mismo conjunto de información.

Cuadro 4 – Modelos evaluados bajo el protocolo común

Modelo	Información que usa	Papel	Evaluado en
Media constante	Ninguna: media del entrenamiento	Piso común	Validación y bloque final
Repetir semana anterior	Serie: valor de siete días antes	Referencia estacional habitual	Validación y bloque final
L0 – Promedio de las últimas cuatro semanas	Serie: valores de 7, 14, 21 y 28 días antes	Línea base sin exógenas	Bloque final
L1 – Tasa por factor de calendario	Calendario: media del entrenamiento por tipo de día	Referencia con calendario	Validación y bloque final
Media móvil de 56 días por calendario	Calendario, con el nivel de los últimos 56 días	Contraste sobre el tratamiento de la tendencia	Validación
Árbol A	Serie: rezagos de 1, 7, 14 y 21 días, recursivo	Primer modelo aprendido sin exógenas	Bloque final
Árbol B	Rezagos de 7, 14 y 21 días, calendario y tiempo en años	Primer modelo aprendido con calendario	Validación y bloque final

Fuente: elaboración propia.

Los dos árboles son **modelos aprendidos de arranque**, configurados a mano y sin selección de hiperparámetros. El **árbol A**, implementado con skforecast, reproduce la configuración inicial del equipo: profundidad máxima de 15 niveles, predicción recursiva y rezagos que la autocorrelación del Municipio C muestra fuera de la banda de azar (Sección 4.1.3). El **árbol B** limita la profundidad a cuatro niveles, con un mínimo de 20 observaciones por hoja, y usa rezagos que no requieren recursión, por la explicabilidad de sus reglas (Sección 2.3.4). El protocolo se puso a punto sobre la serie del Municipio C.

3.4.6 Entorno de ejecución y reproducibilidad

Cada procedimiento es un notebook que se ejecuta de principio a fin sin intervención manual (jupyter nbconvert --execute). Cada uno registra las versiones de sus bibliotecas y la huella de sus entradas, y escribe sus tablas y figuras en experiments/<notebook>/. Esas tablas son la fuente de todas las cifras de este informe, y al pie de cada elemento se indica la que corresponde. Los datos crudos no se versionan: el README documenta cómo obtenerlos, y la preparación regenera data/processed/ a partir de ellos.

Entorno único. Los seis notebooks se ejecutan sobre un mismo entorno: Python 3.13.15, con pandas 2.3.3, NumPy 2.5.2, SciPy 1.18.1, scikit-learn 1.9.0, statsmodels 0.14.6, matplotlib 3.11.1, geopandas 1.1.4, holidays 0.103 y skforecast 0.25.0. El repositorio fija esas versiones en requirements.txt (diecisiete dependencias directas, con versión exacta) y el árbol completo en requirements-lock.txt (ciento treinta y seis paquetes), que se aplica como restricción: pip install -r requirements.txt -c requirements-lock.txt. La versión de pandas responde a una restricción dura: skforecast 0.25.0 exige pandas ≥ 2.1 , < 3.0 .

Verificación de reproducibilidad. El entorno se unificó el 20/09/2026, después de comprobar que las corridas previas se habían hecho con tres combinaciones distintas de intérprete y bibliotecas. Se instaló un entorno limpio, se reejecutaron los seis notebooks en orden de dependencia y se comparó, archivo por archivo y celda por celda, la salida nueva contra una copia de la anterior, sin aplicar tolerancias. De ciento veintidós tablas, ciento ocho resultaron idénticas byte a byte y catorce presentaron diferencias, todas atribuibles a la fecha de ejecución, al registro del propio entorno o a etiquetas de tipo de pandas; ninguna celda mostró diferencia numérica. De treinta y una figuras, veintiocho resultaron idénticas y dos difieren en menos del 0,006 % de sus píxeles, con una diferencia máxima de 1 sobre 255 por canal. Un segundo entorno instalado desde cero con el mismo procedimiento produjo un pip freeze idéntico.

La comparación detectó una única diferencia de contenido, ajena a los resultados del modelado: en pandas 2.x, la conversión a texto de una columna con un valor nulo lo transforma en la cadena "nan" y lo cuenta como un valor más. El patrón se corrigió en los tres procedimientos donde aparecía, conservando el nulo. Ninguna cifra citada en este informe dependía de ese valor.

El entrenamiento verificado en el servidor institucional (Anexo F.1) corre en un contenedor con un entorno propio (Python 3.10.12, pandas 1.5.3, scikit-learn 1.2.0), independiente del entorno local descrito aquí. Las cifras de este informe provienen de las corridas locales.

3.5 Aspectos éticos

El proyecto no realiza tratamiento de datos personales en los términos de la Ley N.º 18.331: los registros carecen de identificación de las personas involucradas y se agregan al par (día, municipio), de modo que solo se manejan conteos territoriales. Las tres fuentes se utilizan dentro de sus condiciones de acceso abierto.

El riesgo ético principal está en la interpretación. Una estimación por municipio podría leerse como un ordenamiento de peligrosidad territorial, lectura que carece de sustento por la falta de datos de exposición y por un subregistro posiblemente desigual entre zonas; por eso el informe restringe su vocabulario a la «cantidad esperada de siniestros registrados». Usar estas estimaciones para asignar recursos, además, podría profundizar sesgos de cobertura institucional. El uso de herramientas de inteligencia artificial generativa no constituye una fuente académica citada y, por lo tanto, no integra la lista de referencias; se declara y se documenta de forma incremental en `documentacion/registro_uso_IA.md` y en la declaración institucional correspondiente.

4. Resultados

Este capítulo presenta los resultados del segundo hito: el diagnóstico de los datos (4.1), el conjunto de modelado y su verificación (4.2), y el desempeño de las referencias y de los primeros modelos aprendidos bajo el protocolo de la Sección 3.4.3 (4.3). Las cifras proceden de las tablas que los procedimientos generan en cada ejecución, indicadas al pie de cada elemento; el detalle que excede al cuerpo se incorpora en los anexos.

4.1 Diagnóstico de los datos

4.1.1 Calidad

Compleitud. El archivo no tiene valores nulos, pero sí faltantes codificados como texto, que en el recorte afectan al 4,48 % de las localidades y al 2,33 % de las calles, frente al 17,91 % y el 12,37 % del archivo nacional (Anexo B, Tabla B1). El equipo infiere que el problema de completitud era en buena medida del interior del país. Ninguna de esas columnas se usa como predictora —el municipio se deriva de la geometría—, así que no se imputa: se declara el conteo.

Duplicados. Hay 347 filas idénticas en todas sus columnas, 90 de ellas en el recorte, agrupadas en 71 conjuntos; uno reúne diez copias. Sin identificador de siniestro no es posible distinguir con certeza un duplicado de carga de dos hechos reales idénticos; el equipo infiere que son artefactos de carga y los elimina, decisión conservadora respecto de la cola alta del objetivo.

Consistencia interna. El día de la semana declarado permite verificar el formato de fecha con evidencia del propio archivo: el formato con el mes primero explica el **100 %** de los días sin fechas inválidas, mientras que el del día primero deja 133.356 fechas no interpretables y coincide en apenas el 6,80 %, lo que refuta la suposición de formato mixto de la etapa anterior. Las comprobaciones de horas fuera de rango, registros de otro departamento y fechas fuera del período arrojan cero casos.

Precisión espacial y asignación territorial. Todas las coordenadas son múltiplos de cinco metros y hay 7.833 posiciones distintas, de las que la más repetida concentra el 0,31 % de los hechos: se infiere una geocodificación ajustada a esquina o tramo de calle, que es la condición que vuelve viable la asignación punto-polígono. Los ocho polígonos reciben siniestros y **11 hechos (0,03 %)** caen fuera de todos, en bordes costeros o departamentales; se descartan en lugar de reasignarlos arbitrariamente.

Validez temporal y valores atípicos. Los 1.645 días registran al menos un siniestro, con un mínimo diario departamental de 4, una mediana de 22,0 y un máximo de 44. El criterio de Tukey marca 8 días atípicos en la serie del departamento y 9 dentro de cada grupo de calendario (Anexo B, Tabla B2). No se eliminó ni corrigió ninguno: 5 de los 8 que marca el criterio global son normales para su grupo, y los atípicos altos dentro del grupo son todos de 2023 en adelante, coherente con la tendencia creciente.

Serie meteorológica. Cubre los 1.645 días sin duplicados, faltantes ni valores fuera de rango físico, con temperaturas medias de entre 4,9 y 31,7 grados y precipitaciones de entre 0 y 105,3 milímetros.

4.1.2 Cobertura

Cobertura temporal. El período conservado acumula 3.936 siniestros en el segundo semestre de 2021, 7.665 en 2022, 7.873 en 2023, 8.398 en 2024 y 8.740 en 2025, con medias diarias que van de 21,00 a 23,95 y variaciones interanuales de +2,7 %, +6,4 % y +4,4 % desde 2023 (Anexo B, Tabla B3).

El año 2021 aporta solo el segundo semestre, la mitad más activa, por lo que la variación hacia 2022 no es interpretable; la comparación homogénea entre segundos semestres arroja 21,39 siniestros diarios en 2021, 22,05 en 2022, 22,68 en 2023, 23,96 en 2024 y 24,62 en 2025.

Exclusión del primer semestre de 2021. Los tres pasos anunciados en la Sección 3.2.3 arrojan el siguiente resultado. En **nivel**, ese semestre promedia **16,34 siniestros diarios** frente a **21,40** en los mismos meses de 2022 a 2025 (**-23,7 %**). En **forma**, el índice estacional mensual respecto de la media del propio año se aparta del patrón de referencia entre -7,0 % en junio y **-17,2 %** en abril, lo que descarta que la depresión responda a un nivel anual más bajo. En **suficiencia del corte**, el tramo conservado encadena con los años posteriores mediante variaciones interanuales de entre +2,8 % y +5,7 %, y su forma intraanual vuelve a la de referencia en cinco de sus seis meses. El costo es de **2.957 registros (7,5 % del recorte) y 181 días**. Se declaran dos excepciones: enero de 2021 no está deprimido (+1,1 %) y se excluye por conveniencia, no por evidencia; noviembre de 2021 se aparta en +10,7 % sin explicación disponible y se conserva.

Cobertura territorial. Los ocho municipios están representados y el reparto es parejo (Anexo C, Tabla C1 e Ilustración C1): el Municipio C concentra el 15,80 % de los siniestros y el CH, el 9,22 %, con una razón de **1,71** entre el de más y el de menos, y

todos superan el 84 % de días con al menos un hecho. A favor, todos tienen soporte suficiente para estimar una tasa estable; en contra, queda **poco margen para ordenarlos**, porque las diferencias entre posiciones contiguas pueden ser menores que el error de estimación. La similitud es de nivel y no de estructura: la Sección 4.1.3 muestra que dos municipios de volumen parecido difieren en su ciclo semanal. El mapa refleja dónde se registran siniestros, no dónde son más probables por unidad de exposición.

El panel resultante. El panel vigente tiene 13.160 filas, un 8,60 % de ceros y una media de 2,7821 siniestros por par día-municipio, frente al **95,08 %** de ceros de la grilla de 1 km y al **71,96 %** de los barrios que se ensayaron antes (los valores de la grilla y de los barrios corresponden a versiones previas sobre el período completo; ver la nota de la Tabla C2). Ese es el cambio de fondo que introduce la partición por municipios: el problema deja de ser la predicción de un evento infrecuente y pasa a ser una **regresión de conteo ordinaria**. El **balanceo no corresponde**, porque no hay clases que balancear. El porcentaje de ceros, por sí solo, no permite concluir que exista o no inflación de ceros; lo que muestra es que, con el diagnóstico disponible, no hay evidencia suficiente para priorizar esa familia de modelos.

Variables exógenas. El calendario reparte el período en 1.114 días entre semana, 454 de fin de semana y 77 feriados, con medias departamentales de 24,33, 18,31 y 15,64 siniestros diarios, respectivamente. El perfil semanal va de 25,74 siniestros el viernes a 16,06 el domingo. La serie meteorológica cubre el período completo sin faltantes.

4.1.3 Adecuación al problema

La variable objetivo. Tiene una media de **2,7821** y una varianza de **3,5039**, es decir, un índice de dispersión de **1,259**: el modo es dos siniestros, con el 22,56 % de las filas; el 8,60 % vale cero, el 18,47 % vale uno y el 72,93 % vale dos o más, con una cola que llega a 13. Es un conteo con **sobredispersión leve**, del que el equipo infiere que la distribución de Poisson sigue siendo la familia de referencia y la binomial negativa, su primera extensión razonable.

Señal temporal en el panel. El contraste relevante es contra el **puro azar**, porque una serie de Poisson sin memoria también produce autocorrelaciones no nulas: se simuló 400 series por municipio con su tasa media, se comparó la autocorrelación observada con la banda que generan y la medición se repitió sobre el residuo, descontados el día de

la semana y el feriado. La Tabla 2 presenta el resultado; el detalle por municipio está en el Anexo D.

Tabla 2 – Autocorrelación por municipio frente a la banda nula de Poisson

Rezago	Autocorrelación cruda (mediana)	Municipios sobre la banda	Autocorrelación del residuo (mediana)	Municipios sobre la banda	Banda nula
1	0,0558	5 de 8	0,0475	5 de 8	0,0464
7	0,0569	5 de 8	0,0079	0 de 8	0,0450

Fuente: elaboración propia

El desglose por rezago es la parte útil. **A rezago siete la señal es enteramente de calendario:** descontados el día de la semana y el feriado, ningún municipio queda sobre la banda. **A rezago uno queda una persistencia genuina**, que sobrevive al descuento en cinco de los ocho municipios, muy por encima de los 0,2 esperables por azar, aunque su magnitud es pequeña: una autocorrelación de 0,05 explica menos del 1 % de la varianza. El equipo concluye que el rezago de un día es candidato a evaluar, pero no puede ser el eje del modelo.

Aporte de cada bloque de variables. Se midió en dos pasadas (Tabla 3): una **dentro de muestra**, en la que cada predictor recibe la media del grupo calculada sobre los mismos datos con que se lo evalúa —una **cota superior inalcanzable**—, y otra **fuera de muestra**, que estima con la primera mitad temporal del panel y evalúa sobre la segunda.

Tabla 3 – Aporte de cada bloque de información, medido en desviación de Poisson

Información disponible	Desviación dentro de muestra	Mejora de	Desviación fuera de muestra	Mejora de
Constante global	1,36899	—	1,36394	—
Solo variables de día (techo de cualquier variable de día)	1,13018	-17,4 %	—	—
Solo factor de calendario efectivamente construible	—	—	1,30530	-4,3 %
Solo tasa histórica del municipio	1,26796	-7,4 %	1,26172	-7,5 %
Tasa del municipio por factor de calendario	1,02914	-24,8 %	1,20308	-11,8 %
Tasa del municipio, calendario y precipitación	—	—	1,20716	-11,5 %
Celdas saturadas de municipio, calendario y mes	—	—	1,50546	+10,4 %

Fuente: elaboración propia.

Dentro de muestra, el techo de las variables de día (-17,4 %) parece dominar, pero incluye toda la fluctuación diaria irreplicable y no paga costo por la cantidad de grupos.

Fuera de muestra el orden se invierte, con cuatro consecuencias: la **tasa histórica del municipio**, con ocho parámetros, mejora más que el calendario construible con catorce ($-7,5\%$ frente a $-4,3\%$); la **combinación multiplicativa** es la mejor de la tabla, lo que fundamenta la referencia L1; la **precipitación** no mejora el resultado, razón por la que el clima no se usa en este hito; y las **celdas saturadas** rinden peor que no usar información alguna, lo que justifica la forma multiplicativa frente al cruce independiente. Dos advertencias: la media del objetivo sube un **11,0 %** entre mitades (de 2,6369 a 2,9271), así que todos los predictores se estimaron sobre el tramo bajo y se evaluaron sobre el alto y las mejoras son conservadoras; y esa segunda mitad contiene el período de prueba, riesgo declarado en el Cuadro 3.

Estructura temporal de las series individuales. El análisis de las series de los municipios C y A fundamenta el tratamiento del objetivo. El Anexo D (Tabla D1) reúne sus indicadores: dispersión, perfil semanal, autocorrelación cruda, prueba de Ljung-Box, pruebas ADF y KPSS, efecto de diferenciar y λ de Box-Cox.

Lo que comparten. En ambas, la prueba ADF rechaza la raíz unitaria y la KPSS rechaza la estacionariedad. Las dos señales no son plenamente concordantes, y ninguna de ellas determina por sí sola un proceso específico: su combinación admite más de una lectura, entre ellas la de un proceso estacionario alrededor de un nivel que deriva lentamente. La decisión de no diferenciar se apoya en el conjunto de la evidencia disponible y no solo en esas pruebas: diferenciar vuelve fuertemente negativa la autocorrelación del primer rezago ($-0,4621$ y $-0,5044$), señal compatible con sobrediferenciación, y el λ de Box-Cox, próximo a 0,5 en las dos series, apunta a la raíz cuadrada y no al logaritmo. El objetivo se modela, entonces, como conteo, sin diferenciar ni transformar, y la deriva de nivel se trata en el modelado.

Lo que las distingue. En el Municipio C la autocorrelación cruda presenta picos en los múltiplos de siete, que en su mayoría desaparecen al descontar el calendario; en el Municipio A los rezagos uno, siete y veintiuno quedan dentro de la banda y el contraste entre viernes y domingo es menor. El equipo infiere que los rezagos elegidos sobre el Municipio C **no necesariamente aportan lo mismo en otros municipios**, y que el supuesto de un factor de calendario común a todas las zonas, implícito en la forma multiplicativa, debe contrastarse en el panel. Con dos series de ocho, ninguna de estas observaciones se generaliza al departamento.

4.1.4 Limitaciones de los datos y amenazas a la validez

El Cuadro 5 reúne las limitaciones que condicionan el modelado y la interpretación; las de calidad ya tratadas en la Sección 4.1.1 no se repiten. A ellas se agregan dos, de alcance acotado: la resolución espacial es gruesa, porque los municipios abarcan entre 1.148 y 14.380 hectáreas, y la serie meteorológica es observada y no pronosticada, de modo que cualquier desempeño que dependa de ella sería una cota optimista.

Cuadro 5 – Limitaciones de los datos y su tratamiento

Limitación	Evidencia	Tratamiento
Deriva creciente del nivel	+11,0 % en la media entre mitades del panel; medias anuales no monótonas en el Municipio C	Tratarla en el modelado: recalibración de nivel, ponderación de datos recientes o normalización del objetivo
Ocho zonas de nivel parecido	Razón de 1,71 entre el municipio de más y el de menos siniestros; estructura semanal distinta entre los municipios C y A	Declarar el margen estrecho para ordenar; excluir un municipio por vez y promediar; contrastar el factor de calendario común
Persistencia de corto plazo pequeña	Residuo sobre la banda en 5 de 8 municipios, con menos del 1 % de la varianza; en el Municipio A, el rezago 1 queda dentro de la banda	Evaluar el rezago de un día como candidato, sin asumirlo
Exógenas sin variación espacial	El clima es una serie única para el departamento	La tasa del municipio es el bloque principal; el clima se reevalúa
Ausencia de datos de exposición	No se dispone de volumen de tránsito	Limitar las afirmaciones a la cantidad esperada de siniestros registrados
Diagnóstico calculado sobre el período completo	La segunda mitad de la Tabla 3 y las autocorrelaciones incluyen el bloque final	Declararlo (Cuadro 3); recalcular con el bloque de desarrollo en el Entregable 3. Ese recálculo mejora el procedimiento hacia adelante, pero no revierte el uso ya realizado de este período.
Subregistro de siniestros	No medible con estos datos	Declararlo como amenaza a la validez

Fuente: elaboración propia

El subregistro es la limitación de mayor alcance y la única que no puede acotarse: la fracción no registrada, típicamente la de los hechos leves que no generan intervención, es desconocida y probablemente desigual entre municipios, de modo que cualquier ordenamiento podría estar sesgado sin que este diagnóstico lo detecte.

4.2 Conjunto de datos preparado

El procedimiento de preparación produce un panel de **13.160 filas y doce columnas** (1.645 días por ocho municipios) que contiene los 36.612 siniestros del recorte con ceros explícitos. Exporta además la capa limpia y georreferenciada de hechos, el catálogo de

municipios, las series individuales de los municipios C y A, y un diccionario de datos de 50 entradas. El conjunto se regenera íntegramente desde las fuentes y no se versiona.

Las **dieciséis verificaciones** que detienen la ejecución resultaron favorables. Comprueban, entre otros extremos, que el panel conserva todos los siniestros del recorte y es el producto completo de días por zonas, que la clave fecha-municipio no se repite, que no quedan faltantes ni columnas constantes o derivadas de la gravedad, y que el calendario y la serie meteorológica cubren el período sin huecos. Tres de ellas se incorporaron tras errores concretos del desarrollo, lo que ilustra su función: no documentan buenas intenciones, impiden repetir fallas ya observadas. La reejecución integral del 20/09/2026 volvió a ejecutar las dieciséis verificaciones con resultado favorable y reprodujo los cinco archivos de data/processed/ idénticos byte a byte (Sección 3.4.6).

La evidencia más sólida sobre la corrección del conjunto es externa al propio procedimiento. La reconstrucción independiente del panel realizada en el diagnóstico coincide con la salida de la preparación en filas, siniestros, municipios, días y máximo del objetivo (Anexo E, Tabla E1), y la asignación territorial reimplementada con la biblioteca geopandas, en el diagnóstico del Municipio C, reproduce exactamente los ocho conteos por municipio.

4.3 Línea base y resultados preliminares

Los resultados de este apartado se obtuvieron sobre **una única serie**, la del Municipio C, el de mayor cantidad de siniestros registrados: 1.645 días, una media de 3,5155 siniestros diarios, un índice de dispersión de 1,26 y un 4,8 % de días sin siniestros. La elección fija el protocolo sobre un caso simple antes de extenderlo al panel. **Sus métricas no son las del proyecto**, y nada de lo que sigue permite afirmar que un modelo generalice.

El promedio diario del **bloque final** (3,875) supera en un 13,1 % al del bloque de desarrollo (3,426), de modo que todo modelo de nivel fijo tenderá a subestimar (experiments/base_2/tablas/01_particion.csv).

4.3.1 Desempeño en validación interna

Los modelos con calendario y sus contrastes se evaluaron con los mismos 47 cortes y métricas (Tabla 4).

Tabla 4 – Desempeño en validación interna por origen móvil (modelos evaluados en `base.ipynb`)

Modelo	Desviación de Poisson	MAE	RMSE	Total predicho / observado
Media móvil de 56 días por calendario	1,3766	1,6501	2,1663	1,0102
L1 – Tasa por factor de calendario	1,3782	1,6114	2,1641	0,9146
Árbol B	1,4005	1,6815	2,1958	0,9981
Media constante	1,5178	1,7591	2,2735	0,9133
Repetir semana anterior	7,8956	2,3769	3,0647	1,0066

Fuente: elaboración propia

Las dos formas con calendario mejoran la desviación de la media constante en un 9,3 % (media móvil) y un 9,2 % (L1), y L1 obtiene el menor MAE del conjunto. El árbol B la mejora en un 7,7 %, pero queda por detrás de ambas, con una razón entre total predicho y observado próxima a 1 en desarrollo (0,998), lo que indica que acierta el volumen agregado y no que esté calibrado en todo el rango. Limitar su profundidad es una condición de funcionamiento: sin límite alcanza 31 niveles y 943 hojas, y su desviación sube a 12,6468 (Anexo F, Tabla F1). Se apoya sobre todo en el calendario —el fin de semana y el feriado reúnen 0,525 y 0,171 de la importancia por reducción de impureza—, seguido del tiempo transcurrido (0,226), mientras que los tres rezagos suman menos de 0,08 (Anexo F, Tabla F2). Esa medida favorece a las variables continuas, así que el peso de la tendencia debe leerse con cautela; la importancia por permutación prevista en la Sección 2.3.6 se calculará en el Entregable 3.

Repetir la semana anterior tiene una desviación más de cinco veces mayor que la media constante, mientras que su MAE es solo un 35 % mayor. El equipo atribuye la diferencia a los días en que predice cero y se observan siniestros, cuyo aporte depende del valor de reemplazo (Sección 3.4.3), como se constata **en el bloque final** (Tabla 5). La cifra no mide su error típico: muestra que copiar un único día es inadecuado cuando la métrica penaliza las predicciones nulas.

4.3.2 Desempeño en el bloque final, evaluado preliminarmente en E2

La Tabla 5 reúne los modelos evaluados sobre el **bloque final**, con el ajuste congelado en el desarrollo y las 47 semanas del período.

Tabla 5 – Desempeño en el bloque final, evaluado preliminarmente en E2 (47 semanas, 329 días)

Modelo	Información	Desvianza de Poisson	MAE	RMSE	Total predicho / observado	Días con predicción cero
L1 – Tasa por factor de calendario	Calendario	1,085	1,592	1,967	0,884	0 (a)
Media constante	Ninguna	1,262	1,741	2,120	0,884	0
L0 – Promedio de las últimas cuatro semanas	Serie	1,332	1,755	2,179	0,981	0
Árbol B	Serie, calendario y tendencia	1,679	1,906	2,409	0,723	0
Árbol A	Serie	3,462	2,137	2,738	0,967	7
Repetir semana anterior	Serie	5,007	2,228	2,866	0,996	10

Fuente: elaboración propia

notas:(a) Por construcción, L1 predice la media de entrenamiento del tipo de día correspondiente, siempre positiva, de modo que no puede producir predicciones nulas. (b) Valor obtenido de las predicciones guardadas de base.ipynb (experiments/base/...), no inferido de otras métricas.

La tabla admite tres lecturas:

La historia de la serie sola no supera a la media constante. El promedio de las últimas cuatro semanas (L0) queda un **5,2 %** por encima de la media constante en desvianza, y esta obtiene el mejor resultado en 29 de las 47 semanas (Anexo F, Tabla F4). La ventaja de L0 está en el volumen: predice el 98,1 % del total observado frente al 88,4 % de la media constante, porque su ventana acompaña el nivel de la serie. Se mantiene como línea base sin exógenas porque se fijó antes de la evaluación; su ventana se revisará con validación interna.

El calendario es lo único que mejora claramente a la media constante. La referencia L1 reduce su desvianza en un **14,1 %**, aunque subestima el volumen en la misma proporción. El resultado sugiere que el calendario aporta más que la historia reciente, en línea con las Tablas 2 y 3, pero no aísla ese efecto, porque L0 y L1 difieren también en cómo estiman el nivel.

Ninguno de los dos árboles supera a las referencias, y por mecanismos distintos. El árbol B subestima el volumen total en un 28 % y lo hace en todos los meses, con razones de entre 0,635 y 0,877: sus totales mensuales predichos van de 82,04 a 91,58 siniestros, mientras los observados van de 109 a 134 (Anexo F, Tabla F3). Se lo atribuye a que un árbol no extrapola el tiempo transcurrido, que **en el bloque final** supera siempre

el rango de entrenamiento, de modo que aplica cortes aprendidos en el tramo final del desarrollo, de nivel inferior al del período evaluado (Sección 2.3.4). El árbol A, en cambio, acierta el volumen total (0,967) porque sus excesos y sus faltas se compensan, pero con 716 hojas para 1.295 filas de entrenamiento memoriza días concretos: predijo cero en siete días, cinco de ellos con siniestros, y las cinco semanas que los contienen son las de mayor desviación, entre 9,64 y 19,34. Esa desviación, como la de repetir la semana anterior, depende del valor de reemplazo y no debe leerse aislada.

4.3.3 Lectura de los resultados preliminares

Esta etapa deja tres resultados, todos con el alcance de evidencia exploratoria que fija la Sección 3.4.4. El primero es que un buen resultado **en desarrollo no garantiza el desempeño en un período posterior de nivel distinto**: el árbol A, con la menor desviación de la primera semana (0,957), y el árbol B, que mejoraba a la media constante en validación (−7,7 %), quedan por debajo de las referencias al evaluarse sobre las 47 semanas. Una semana no basta para evaluar.

El segundo es que **quedan propuestas las referencias del Entregable 3** —la media constante para cualquier modelo, L0 para los que usen solo la serie y L1 para los que incorporen calendario—. Se deja constancia de que esta elección se tomó después de conocer los resultados del bloque final, por lo que se revisará al inicio del Entregable 3 junto con la definición de la evaluación final.

El tercero es que **tratar la deriva de nivel es una condición del modelado**. Esa necesidad surgía del diagnóstico, con un +11,0 % entre mitades del panel, antes de evaluar sobre el bloque final, y ese resultado la confirma.

Para el Entregable 3, con decisiones tomadas solo sobre la validación interna, se prevé fijar la profundidad y el tamaño mínimo de hoja de los árboles con la desviación como criterio, revisar la ventana de L0, incorporar el calendario y la tasa del municipio, tratar la deriva de nivel, comparar con familias propias de datos de conteo —la regresión de Poisson y los métodos de conjunto con pérdida de Poisson— y extender la evaluación al panel de ocho municipios, con métricas por municipio y exclusión de un municipio por vez. Allí se verificará también si los rezagos y el factor de calendario definidos sobre el Municipio C aportan lo mismo en los demás municipios (Sección 4.1.3). Los resultados de este apartado provienen de una única serie y no permiten afirmar que ningún procedimiento generalice al departamento.

Referencias bibliográficas

- Deretić, N., Stanimirović, D., Awadh, M. A., Vujanović, N., y Djukić, A. (2022). SARIMA modelling approach for forecasting of traffic accidents. *Sustainability*, 14(8), 4403. <https://doi.org/10.3390/su14084403>
- de Medrano, R., y Aznarte, J. L. (2021). A new spatio-temporal neural network approach for traffic accident forecasting. *Applied Artificial Intelligence*, 35(10), 782-801. <https://doi.org/10.1080/08839514.2021.1935588>
- Eisenberg, D. (2004). The mixed effects of precipitation on traffic crashes. *Accident Analysis & Prevention*, 36(4), 637-647. [https://doi.org/10.1016/S0001-4575\(03\)00085-X](https://doi.org/10.1016/S0001-4575(03)00085-X)
- Géron, A. (2023). *Aprende machine learning con Scikit-Learn, Keras y TensorFlow* (3.^a ed.). Anaya Multimedia.
- Hyndman, R. J., y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.^a ed.). OTexts. <https://otexts.com/fpp3/>
- Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Intendencia de Montevideo. (2026). Municipios de Montevideo [Capa vectorial zon_v_sig_municipios]. GeoServer institucional de la Intendencia de Montevideo. montevideo.gub.uy/app/geoserver
- Kontopoulou, V. I., Panagopoulos, A. D., Kakkos, I., y Matsopoulos, G. K. (2023). A review of ARIMA vs. machine learning approaches for time series forecasting in data driven networks. *Future Internet*, 15(8), 255. <https://doi.org/10.3390/fi15080255>
- McCullagh, P., y Nelder, J. A. (1989). *Generalized linear models* (2.^a ed.). Chapman & Hall.
- Open-Meteo. (s. f.). Historical Weather API. <https://open-meteo.com/en/docs/historical-weather-api>
- Unidad Nacional de Seguridad Vial. (2025). Modelos SARIMA para la predicción de lesionados en siniestros de tránsito en Uruguay. Presidencia de la República. https://www.gub.uy/unidad-nacional-seguridad-vial/sites/unidad-nacional-seguridad-vial/files/2025-10/SARIMA_lesionados_Formato%20UNASEV.pdf
- Unidad Nacional de Seguridad Vial. (2026). Informe anual de siniestralidad vial 2025. Presidencia de la República. <https://www.gub.uy/unidad-nacional-seguridad-vial/datos-y-estadisticas/estadisticas>
- World Health Organization. (2023). Global status report on road safety 2023. World Health Organization. <https://www.who.int/publications/i/item/9789240086517>

Anexos

Los anexos reúnen el material que respalda el cuerpo del informe y que, por su nivel de detalle, no lo integra. Cada uno está citado desde el texto. El código completo, los notebooks y las tablas de salida permanecen en el repositorio del proyecto.

Anexo A – Procedencia y verificación de las fuentes

Tabla A1 – Fuentes de datos, procedencia y verificación

Fuente	Archivo	Tamaño	Huella sha256	Verificación en cada corrida
Registro de siniestros (UNASEV)	uru_siniestros_unificado.csv	26,19 MB	48a8a7e8...	Huella, dimensiones y vocabulario de las columnas categóricas
Capa de municipios (Intendencia de Montevideo)	municipios_montevideo.geojson	2,87 MB	ed0ba13e...	Huella, cantidad de polígonos y fecha de modificación
Serie meteorológica (Open-Meteo)	clima_montevideo.csv	0,08 MB	f40e6c3c...	Cobertura del período y ausencia de faltantes

Fuente: elaboración propia

Tabla A2 – Recorte del archivo al alcance del proyecto

Paso	Registros	Porcentaje del archivo
Registros del archivo original	224.694	100,0 %
Tras retener el departamento de Montevideo	62.427	27,8 %
Tras retener las fechas desde el 1.º de enero de 2021	39.676	17,7 %
Tras excluir el primer semestre de 2021	36.713	16,3 %
Tras eliminar 90 duplicados exactos	36.623	16,3 %
Tras descartar 11 hechos fuera de todo polígono	36.612	16,3 %

Fuente: elaboración propia

Nota: Hasta la corrida del 14/09/2026, el diagnóstico de la serie del Municipio C registraba para la capa de municipios una huella distinta (c5d9f651...) de la del diagnóstico principal (ed0ba13e...): esa ejecución había utilizado otra copia del archivo, que no se conserva. Tras la reejecución integral del 20/09/2026 los dos procedimientos registran la misma huella, ed0ba13e..., que es la vigente. Ninguna tabla de resultados cambió entre ambas corridas, de modo que la diferencia entre copias no alteró ninguna salida. Cada procedimiento registra su propia huella y su propia fecha, en lugar de asumir las del diagnóstico principal.

Anexo B – Calidad: faltantes y valores atípicos

Tabla B1 – Faltantes codificados como texto, por columna

Columna	Archivo nacional	Recorte del proyecto
Localidad	17,91 %	4,48 % (1.646 registros)
Calle	12,37 %	2,33 % (854 registros)
Tipo de siniestro	0,01 %	0,03 % (10 registros)
Gravedad, día de la semana, departamento	0,00 %	0,00 %

Fuente: elaboración propia.

Tabla B2 – Valores atípicos de la serie diaria del departamento, según dos criterios de Tukey

Indicador	Valor
Cuartiles de la serie diaria (Q1, Q3) e intervalo intercuartílico	18, 27 y 9
Límites del criterio global	4,5 y 40,5
Días atípicos con el criterio global	8 (0,49 % del período): 7 por encima y 1 por debajo
Días atípicos dentro de su grupo de calendario	9: 8 por encima y 1 por debajo; ningún feriado
Días marcados por ambos criterios	3
Días marcados solo por el criterio global	5
Días marcados solo dentro de su grupo	6


Fuente: elaboración propia.

Tabla B3 – Cobertura temporal y evolución interanual

Año	Siniestros	Días observados	Media diaria	Variación
2021	3.936	184	21,39	no comparable
2022	7.665	365	21,00	no comparable
2023	7.873	365	21,57	+2,7 %
2024	8.398	366	22,95	+6,4 %
2025	8.740	365	23,95	+4,4 %

Fuente: elaboración propia.

Ilustración B1 – Cobertura temporal del registro, con el tramo excluido señalado.



Fuente: elaboración propia.

El criterio se aplica sobre la serie diaria del departamento, ya deduplicada, y no sobre la variable objetivo por par día-municipio. Los límites no alimentan ninguna transformación, de modo que calcularlos sobre el período completo no introduce fuga. Ningún día se eliminó ni se corrigió (Sección 4.1.1).


Anexo C – Cobertura territorial por municipio

Tabla C1 – Cobertura territorial por municipio

Municipio	Siniestros	Porcentaje	Días con al menos un siniestro	Media diaria
C	5.783	15,80 %	95,2 %	3,516
B	5.377	14,69 %	95,0 %	3,269
D	5.319	14,53 %	95,6 %	3,233
A	5.016	13,70 %	94,2 %	3,049
F	4.424	12,08 %	93,2 %	2,689
G	3.701	10,11 %	87,9 %	2,250
E	3.615	9,87 %	86,0 %	2,198
CH	3.377	9,22 %	84,3 %	2,053

Fuente: elaboración propia.

Ilustración C1 – Distribución territorial de los siniestros acumulados por municipio.



Fuente: elaboración propia.

Tabla C2 – Caracterización del panel según la partición territorial

Partición	Zonas	Filas	Ceros	Media	Índice de dispersión	Máximo	Periodo
Grilla de 1 km (superada)	403	735.878	95,08 %	0,0538	1,136	5	1/1/2021 – 31/12/2025 (1.826 días)
Barrios (superada)	62	113.212	71,96 %	0,3495	1,132	7	1/1/2021 – 31/12/2025 (1.826 días)
Municipios (vigente)	8	13.160	8,60 %	2,7821	1,259	13	31/12/2025 (1.645 días)

Fuente: elaboración propia.

Nota: Las tres alternativas no son estrictamente comparables: la grilla y los barrios se construyeron sobre el período completo 2021–2025, antes de excluir el primer semestre de 2021. La tabla se conserva como antecedente exploratorio del cambio de partición territorial. La diferencia en la proporción de ceros responde principalmente al tamaño de las zonas, pero no puede atribuirse en su totalidad a la agregación territorial, porque los períodos difieren.


Anexo D – Estructura temporal de las series

Tabla D1 – Estructura temporal de las series de los municipios C y A

Indicador	Municipio C	Municipio A
Media diaria / índice de dispersión	3,5155 / 1,260	3,0492 / 1,1226
Media anual: mínimo y 2025	3,3288 (2023) y 3,7562	2,6685 (2022) y 3,3836
Media del viernes / media del domingo	4,268 / 2,038 (razón 2,09)	3,5234 / 2,4681 (razón 1,43)
Autocorrelación cruda, rezagos 1 / 7 / 14	0,0785 / 0,0764 / 0,1706	0,0396 / 0,0266 / 0,0511
Ljung-Box, p-valor a 7, 14 y 30 rezagos	< 0,001 en los tres	0,0074 / 0,0013 / 0,00026
ADF: estadístico (p-valor)	-7,0716 ($4,92 \cdot 10^{-10}$)	-17,8908 ($2,98 \cdot 10^{-30}$)
KPSS: estadístico (p-valor)	1,2915 ($\leq 0,01$)	2,8405 ($\leq 0,01$)
Autocorrelación a rezago 1 tras diferenciar (d = 1)	-0,4621	-0,5044
λ de Box-Cox (máxima verosimilitud, serie + 1)	0,4733	0,475

Fuente: elaboración propia.

Ilustración D1 – Autocorrelación por municipio, observada y sobre el residuo, frente a la banda nula.



Fuente: elaboración propia.

La banda nula se obtuvo por simulación de 400 series de Poisson por municipio, con la tasa media de cada uno. La lectura agregada está en la Tabla 2.

Anexo E – Preparación: cobertura de las acciones y verificación

Cuadro E1 – Cobertura de las acciones de preparación

Acción	Estado	Fundamento
Limpieza	Aplicada	Duplicados exactos, formato de fecha verificado, coordenadas validadas
Transformación	Aplicada	Reproyección de coordenadas y agregación al par día-municipio
Transformación del objetivo	No corresponde	Ni diferenciación ni logaritmo o Box-Cox: la Sección 4.1.3 lo desaconseja
Imputación	No corresponde	Cero faltantes en las columnas que sobreviven al recorte y en la serie meteorológica
Codificación	Aplicada	Calendario en tres niveles y estado del tiempo en cinco
Escalado	No corresponde en este hito	Los modelos evaluados son invariantes a la escala; si uno posterior lo requiere, se ajustará dentro de cada partición de entrenamiento
Balanceo	No corresponde	La tarea es una regresión de conteo, no una clasificación: no hay clases que balancear
Construcción de variables	Aplicada parcialmente	Calendario, bloque meteorológico y rezagos, estos últimos al modelar. La tasa del municipio se incorporará en el Entregable 3, estimada solo con entrenamiento
Selección de variables	Aplicada	Descarte de constantes, de no utilizadas y de las que producirían fuga
Reducción de dimensionalidad	No corresponde	El conjunto final tiene doce columnas

Fuente: elaborado por los autores.

Cuadro E2 – Decisiones de limpieza y transformación, con su justificación y su efecto

Decisión	Justificación	Efecto observado
Eliminar los duplicados exactos	El archivo carece de identificador de siniestro y el grupo mayor reúne diez filas idénticas en fecha, hora, esquina, tipo y gravedad	347 filas en el país y 90 en el recorte. Antes de eliminarlas, el máximo del objetivo era un artefacto de carga
Fijar el formato de fecha y verificarlo contra el día de la semana declarado	Una fecha ambigua admite dos lecturas sin emitir aviso; la etapa anterior probaba varios formatos en cascada	Un único formato explica el 100,0000 % de los días declarados, sin fechas inválidas
Descartar las columnas de gravedad	Agregadas por día suman exactamente el objetivo: como predictoras serían una fuga perfecta	El conjunto no permite modelar por gravedad sin rehacer el procedimiento
Resumir el calendario en una categórica de tres niveles	El año no aparece en entrenamiento con una partición cronológica; mes, día del año y semana son cíclicos y, como enteros, separan diciembre de enero; todas se recuperan desde la fecha	Conserva el 22,3 % de la varianza diaria, frente al 20,8 % del día de la semana
Mantener el panel sin variables de nivel de zona	La tasa histórica del municipio debe estimarse solo con entrenamiento	Una verificación automática detiene la ejecución si una variable de ese tipo se incorpora
Conservar el nulo al normalizar columnas de texto	En pandas 2.x, astype(str) convierte el faltante en la cadena "nan", que se contaría como un valor válido	Corregido en los tres procedimientos donde aparecía el patrón; no altera ninguna cifra de este informe

Fuente: elaborado por los autores.

Tabla E1 – Verificación cruzada entre dos implementaciones independientes

Comprobación	Reconstrucción del diagnóstico	Salida del procedimiento de preparación	Resultado
Filas del panel	13.160	13.160	Coincide
Siniestros totales	36.612	36.612	Coincide
Municipios	8	8	Coincide
Días	1.645	1.645	Coincide
Máximo de la variable objetivo	13	13	Coincide

Fuente: elaboración propia.

La verificación detectó dos situaciones durante el desarrollo. En una primera ejecución no pudo realizarse, porque la salida disponible correspondía a un alcance anterior; el procedimiento se abstuvo de comparar en lugar de informar una discrepancia falsa. En una segunda instancia detectó un error real de interpretación de fechas en formato ISO, que fue corregido. La tabla corresponde a la ejecución posterior a ambas correcciones.

Anexo F – Resultados complementarios de la línea base

Tabla F1 – Efecto de limitar la profundidad del árbol B (validación interna)

Árbol	Desviación de Poisson	MAE	Total predicho / observado	Profundidad	Hojas
Sin podar (configuración por omisión)	12,6468	2,4863	1,0476	31	943
Con profundidad máxima de 4 niveles	1,4005	1,6815	0,9981	4	13

Fuente: elaboración propia.

Tabla F2 – Importancia de variables del árbol B, por reducción de impureza

Variable	Importancia
Indicadora de fin de semana	0,525
Tiempo transcurrido en años	0,226
Indicadora de feriado	0,171
Rezago de 21 días	0,064
Rezago de 7 días	0,013
Rezago de 14 días	0,000


Fuente: elaboración propia.

Tabla F3 – Volumen mensual predicho y observado del árbol B en el bloque final

Mes de 2025	Observado	Predicho	Razón
Febrero (parcial)	72	63,12	0,877
Marzo	112	82,19	0,734
Abril	116	82,04	0,707
Mayo	111	85,52	0,770
Junio	110	84,86	0,771
Julio	121	85,66	0,708
Agosto	134	86,45	0,645
Setiembre	134	85,04	0,635
Octubre	128	91,58	0,715
Noviembre	109	86,12	0,790
Diciembre	128	89,16	0,697


Fuente: elaboración propia.

Ilustración F1 – Observado y predicho en el conjunto de prueba por la referencia con calendario, la media constante y el árbol B.



Fuente: elaboración propia.

Ilustración F2 – Volumen mensual predicho y observado, dispersión entre lo predicho y lo observado en el bloque final (Anexo F).



Fuente: elaboración propia.

Tabla F4 – Variabilidad semanal de la desvianza en el bloque final (modelos sin variables exógenas)

Model	Mínima	Mediana	Máxima	Semanas con menor desvianza que L0
L0 – Promedio de las últimas cuatro semanas	0,473	1,209	2,516	—
Media constante	0,318	1,147	2,388	29 de 47
Árbol A	0,551	2,158	19,339	8 de 47
Repetir semana anterior	0,322	2,417	34,962	6 de 47

Fuente: elaboración propia.

F.1 Ejecución en el servidor institucional

Campo	Valor
Usuario / grupo	grp04 · host lidia
Fecha	18/09/2026, 12:42:01 a 12:42:11 (–03)

Campo	Valor
Job ID (Slurm)	104 · grp04_cpu_train_base · partición cpu, 4 CPU, 12 G, límite 04:00:00
Script	train_base.py (modelo base, Municipio C)
Imagen	tensorflow_ngc_24.04_tf2_py3_mlcx.sif
Entorno del contenedor	Python 3.10.12, pandas 1.5.3, NumPy 1.24.4, scikit-learn 1.2.0, matplotlib 3.10.9
Entrada	data/processed/panel_zona_top.csv
Resultado	Ejecución completa sin error; RUN_ID 20260918_124207; 18 tablas y figuras en /outputs/runs/20260918_124207

Fuente: log de la ejecución, vinculado en el repositorio como documentacion/logs/slurm_104_20260918.log.