ITR UTEC Norte
Universidad Tecnológica

SEDE: RIVERA

CARÁTULA DEL PROYECTO FINAL

Unidad curricular:

Proyecto de Aprendizaje Automático

LICENCIATURA EN INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL

Nombre del trabajo: “Modelado predictivo de siniestros de tránsito basado en series temporales en Montevideo”

Autores: Juan Lucas Pimentel Barreto
Víctor Samuel Uría Padilla

Tutor: Mag. Matias Leonardo López Pérez

Fecha: 25/10/2026

UTEC
Universidad Tecnológica

Declaración de autoría

Quienes suscriben declaran que el presente trabajo es resultado de su actividad académica e intelectual y que ha sido elaborado respetando los principios de integridad académica, propiedad intelectual, protección de datos y uso responsable de tecnologías.

Asimismo, declaran que todas las ideas, textos, datos, códigos, algoritmos, modelos, imágenes, tablas, figuras, recursos digitales y contribuciones provenientes de terceros han sido debidamente identificados, citados o referenciados, según corresponda.

Cuando se utilizaron bibliotecas de software, repositorios, conjuntos de datos, modelos pre entrenados, servicios tecnológicos o componentes desarrollados por terceros, su procedencia y condiciones de utilización fueron informadas en el cuerpo del trabajo, en las referencias o en los anexos.

Cualquier utilización de herramientas de inteligencia artificial generativa ha sido declarada de manera transparente en la sección correspondiente. Su utilización no transfiere la autoría ni exime a los estudiantes de la responsabilidad por la exactitud, originalidad, validez metodológica, funcionamiento técnico, interpretación de resultados y cumplimiento ético y normativo del trabajo.

Cuando el trabajo sea grupal, todos los integrantes deberán conocer y poder explicar las decisiones metodológicas y técnicas fundamentales del proyecto, aunque haya existido una distribución diferenciada de tareas.

Los estudiantes asumen plena responsabilidad por el contenido del informe, la solución tecnológica desarrollada y los materiales complementarios entregados.

Nombre completo	Documento de identidad	Firma	Fecha
Juan Lucas Pimentel Barreto	5.466.322-2		25/10/2026
Víctor Samuel Uría Padilla	5.496.563-0		25/10/2026

UTEC
Universidad Tecnológica

Declaración de uso de herramientas de inteligencia artificial generativa

Se utilizaron herramientas de inteligencia artificial generativa, según se detalla a continuación.

Herramienta, proveedor y modelo o versión	Fecha o período	Finalidad	Sección o componente	Revisión y validación
Claude (Anthropic), mediante Claude Code; modelo según la sesión	Entregables 2 y 3; detalle por sesión en el registro de uso de IA	Asistente de programación: generación y depuración de código de preparación, diagnóstico, experimentación, evaluación, prototipo y pruebas; resúmenes técnicos de resultados	Repositorio: cuadernos, src/, app/, tests/ y documentacion /	Revisión del código por el equipo; pruebas automáticas; contraste de las cifras con las tablas de salida
Claude (Anthropic), mediante Claude.ai; Claude Opus	Octubre de 2026	Análisis de las salidas del proyecto, planificación y redacción del informe y de la presentación, y revisión de su consistencia	Informe completo y presentación del Entregable 3	Revisión del equipo; contraste de cada cifra con las tablas del repositorio; devolución del tutor
Gamma	Octubre de 2026	Diseño gráfico de la presentación a partir de un contenido elaborado por el equipo	Presentación del Entregable 3	Revisión del equipo de cada diapositiva y de sus cifras

Los estudiantes declaran que los contenidos generados fueron revisados y validados; que las afirmaciones técnicas y académicas fueron contrastadas con fuentes confiables; que no se ingresaron datos personales, confidenciales o sensibles sin autorización y protección adecuada; y que asumen plena responsabilidad por los productos presentados.

UTEC
Universidad Tecnológica

Resumen

Este trabajo estima la cantidad esperada de siniestros de tránsito registrados por municipio y por día en Montevideo, con siete días de anticipación, a partir del registro de la Unidad Nacional de Seguridad Vial (36.612 hechos entre julio de 2021 y diciembre de 2025) y del calendario. Con un protocolo de origen móvil de 47 cortes semanales sobre el bloque de desarrollo, se compararon tres referencias simples con modelos lineales generalizados de Poisson y binomial negativa y con potenciación de gradiente (XGBoost) con pérdida de Poisson, variando conjuntos de variables, hiperparámetros y ventanas de entrenamiento. La regla de selección fijada antes de ejecutar eligió un modelo de Poisson con ventana expansiva; antes de la evaluación final, el equipo se apartó de ella y adoptó, con argumentos de validación declarados, la misma especificación —nivel por municipio y calendario de ocho niveles— reentrenada cada semana con los últimos 364 días. Esa solución se evaluó una sola vez sobre un bloque final de 47 semanas que ya había sido consultado en una etapa anterior, por lo que no constituye una prueba independiente: obtuvo una desvianza de Poisson de 1,1063, frente a 1,1359 de la mejor referencia y 1,3152 de la media constante, con menor error en los ocho municipios y un 96 % del volumen observado. La mejora sobre la referencia es consistente pero modesta y se asocia principalmente a la ventana de entrenamiento; el nivel de cada municipio y el calendario concentran la señal predecible, y XGBoost no aportó frente al modelo lineal. La cobertura de los intervalos de predicción queda cerca de la que espera el propio modelo. La solución se integró como prototipo en el tablero del Proyecto de Ingeniería de Datos y su entrenamiento se reprodujo en el servidor institucional.

Palabras clave: siniestralidad vial; datos de conteo; modelos lineales generalizados; validación temporal; Montevideo.

UTEC
Universidad Tecnológica

Abstract

This work estimates the expected number of recorded road traffic crashes per municipality and day in Montevideo, seven days ahead, from the National Road Safety Unit registry (36,612 crashes between July 2021 and December 2025) and the calendar. Using a rolling-origin protocol with 47 weekly folds on the development block, three simple baselines were compared with Poisson and negative binomial generalized linear models and with Poisson-loss gradient boosting (XGBoost), varying feature sets, hyperparameters and training windows. The selection rule fixed before execution chose a Poisson model with an expanding window; before the final evaluation, the team departed from it and adopted, with declared validation arguments, the same specification —a municipal level and an eight-level calendar— retrained weekly on the last 364 days. This solution was evaluated once on a final block of 47 weeks that had already been consulted at an earlier stage, so it is not an independent test: it achieved a Poisson deviance of 1.1063, against 1.1359 for the best baseline and 1.3152 for the constant mean, with lower error in all eight municipalities and 96% of the observed volume. The improvement over the baseline is consistent but modest and is mainly associated with the training window; municipal level and calendar concentrate the predictable signal, and XGBoost did not improve on the linear model. The coverage of the prediction intervals is close to what the model itself expects. The solution was integrated as a prototype into the dashboard of the previous Data Engineering Project, and its training was reproduced on the institutional server.

Keywords: road safety; count data; generalized linear models; temporal validation; Montevideo.

UTEC
Universidad Tecnológica

Índice

Declaración de autoría **2**
Declaración de uso de herramientas de inteligencia artificial generativa **3**
Resumen **4**
Abstract **5**
Lista de cuadros, ilustraciones y tablas **9**
Cuadros 9
Ilustraciones 9
Tablas 9
Glosario de abreviaciones y definiciones **11**
1. Introducción **1**
1.1 Problema 2
1.2 Pregunta orientadora, hipótesis o desafío de ingeniería 2
1.3 Objetivos 3
1.3.1 Objetivo general 3
1.3.2 Objetivos específicos 3
1.4 Alcance 4
1.4.1 Entregables y criterios de aceptación 5
1.5 Limitaciones y supuestos 6
2. Marco conceptual **7**
2.1 Antecedentes y soluciones existentes 7
2.1.1 La siniestralidad vial como problema público y como objeto de medición 7
2.1.2 Modelos de conteo para la frecuencia de siniestros 7
2.1.3 Modelos clásicos de series temporales y soluciones existentes 7
2.1.4 Aprendizaje automático y predicción espacialmente desagregada 8
2.1.5 Las condiciones meteorológicas como variables exógenas 8
2.2 Fundamentos conceptuales y técnicos 9
2.2.1 Siniestro de tránsito y unidad de análisis 9
2.2.2 Serie temporal, componentes y estacionariedad 9
2.2.3 Datos de conteo, sobredispersión y exceso de ceros 10
2.2.4 Variables exógenas, rezagos y disponibilidad al predecir 10
2.2.5 Fuga de información y validación temporal 10
2.2.6 Métricas, calibración e intervalos de predicción 10
2.2.7 Línea base y referencias 11
2.2.8 Modelos lineales generalizados para conteos 11
2.2.9 Árboles de decisión y potenciación de gradiente 12
2.2.10 Modelos de series temporales: viabilidad de SARIMA 12
2.2.11 Modelos locales y globales, y exclusión de zonas 13
2.2.12 Explicabilidad e interpretación 13
2.3 Brecha identificada y contribución del proyecto 13
3. Metodología de investigación, diseño y desarrollo de la solución **14**
3.1 Enfoque metodológico y diseño del proyecto 14

3.2 Contexto, población, participantes y unidad de análisis....15
3.3 Técnicas, instrumentos y fuentes de información....15
3.4 Procedimiento de recolección y diagnóstico....16
3.5 Procedimiento de análisis de la información y los datos....17
3.5.1 Variables....17
3.5.2 Diseño de la evaluación....18
3.5.3 Medidas contra la fuga de información....19
3.5.4 Referencias, candidatos y regla de selección....20
3.5.5 Interpretación, errores, intervalos y robustez....22
3.5.6 Prototipo, pruebas y reproducción en el servidor....22
3.5.7 Aspectos éticos....23
4. Resultados....24
4.1 Datos y condiciones finales de trabajo....24
4.1.1 Calidad y cobertura....24
4.1.2 Adecuación al problema....25
4.1.3 Conjunto final y condiciones de trabajo....26
4.2 Solución implementada....27
4.2.1 Configuración de la solución....27
4.2.2 Interpretación del modelo....27
4.2.3 Modelo exportado y prototipo....28
4.3 Evaluación y validación....30
4.3.1 Antecedente: la línea base del Entregable 2....30
4.3.2 Referencias y experimentación en validación....30
4.3.3 Selección de la solución....33
4.3.4 Evaluación final en el bloque final....34
4.4 Análisis de errores y desempeño técnico....35
4.4.1 Errores por municipio y por tipo de día....35
4.4.2 Semanas de mayor error....36
4.4.3 Calibración y deriva....36
4.4.4 Intervalos de predicción....37
4.4.5 Robustez: exclusión de un municipio por vez....37
4.4.6 Desempeño técnico, reproducibilidad y pruebas del pipeline....38
5. Discusión....40
5.1 Interpretación de los resultados....40
5.2 Comparación con antecedentes....42
5.3 Aplicabilidad y viabilidad....43
5.4 Limitaciones y amenazas a la validez....43
6. Conclusiones y recomendaciones....46
6.1 Cumplimiento de los objetivos....46
6.2 Contribuciones del proyecto....47
6.3 Recomendaciones....47
6.4 Trabajo futuro....47

Referencias **48**
Anexos **50**
Anexo A – Procedencia y verificación de las fuentes 50
Anexo B – Calidad: faltantes y valores atípicos 51
Anexo C – Cobertura territorial por municipio 52
Anexo D – Estructura temporal de las series y homogeneidad entre municipios 53
Anexo E – Preparación: cobertura de las acciones y verificación 55
Anexo F – Línea base del Entregable 2, servidor, tablero y evidencias del repositorio 56
F.1 Ejecuciones en el servidor institucional 57
F.2 Procedencia del tablero 58
F.3 Ejecución de la inferencia sin reentrenar y evidencias 58
Anexo G – Resultados complementarios de la experimentación y la evaluación final 59

UTEC
Universidad Tecnológica

Lista de cuadros, ilustraciones y tablas

Cuadros

Cuadro 1 – Objetivos, pregunta e hipótesis: indicadores y medios de verificación..... 4
Cuadro 2 – Entregables y criterios de aceptación.....5
Cuadro 3 – Síntesis de los antecedentes revisados..... 8
Cuadro 4 – Métricas de evaluación y su papel en la comparación.....20
Cuadro 5 – Medidas contra la fuga de información.....20
Cuadro 6 – Modelos evaluados y su papel..... 22
Cuadro 7 – Metodología prevista y realizada.....42
Cuadro 8 – Matriz de riesgo: limitaciones y amenazas a la validez.....45
Cuadro 9 – Cumplimiento de los objetivos, la pregunta y la hipótesis.....47
Cuadro E1 – Cobertura de las acciones de preparación..... 56
Cuadro E2 – Decisiones de limpieza y transformación, con su justificación y su efecto... 57

Ilustraciones

Ilustración 1 – Diseño del protocolo de evaluación.....15
Ilustración 2 – Razones de tasas del GLM con su intervalo de confianza del 95 %.....29
Ilustración 3 – Pestaña «Predicción (PAA)», modo «Semana posterior al corte»..... 30
Ilustración 4 – Pestaña «Predicción (PAA)», modo «Histórico».....31
Ilustración 5 – Desvianza por corte en el bloque final.....36
Ilustración B1 – Cobertura temporal del registro en el desarrollo, con el tramo excluido señalado.....53
Ilustración C1 – Distribución territorial de los siniestros acumulados por municipio en el desarrollo.....54
Ilustración D1 – Autocorrelación del residuo de calendario por municipio, frente a la banda nula.....55
Ilustración G1 – Calibración por deciles y residuos por corte en el bloque final.....62
Ilustración G2 – Cobertura de los intervalos de predicción en el bloque final.....62

Tablas

Tabla 1 – Particiones cronológicas del conjunto..... 19
Tabla 2 – Aporte de cada bloque de información fuera de muestra, medido en desvianza de Poisson.....27
Tabla 3 – Razones de tasas estimadas por el GLM de Poisson (últimos 364 días del desarrollo)..... 28
Tabla 4 – Referencias en validación (47 cortes, ocho municipios, ventana expansiva).....32
Tabla 5 – Paso A: conjuntos de variables en validación (ventana expansiva).....32
Tabla 6 – Paso C: ventanas de entrenamiento en validación..... 33
Tabla 7 – Desempeño en el bloque final (47 cortes, 2.632 predicciones por modelo).....35
Tabla 8 – Desvianza por municipio en el bloque final..... 37
Tabla 9 – Cobertura de los intervalos de predicción de la solución..... 38
Tabla 10 – Pruebas del pipeline de inferencia del prototipo.....39
Tabla A1 – Fuentes de datos, procedencia y verificación..... 51

Tabla A2 – Recorte del archivo al alcance del proyecto.....51
Tabla B1 – Faltantes codificados como texto, por columna, hasta el 05/02/2025.....52
Tabla B2 – Valores atípicos de la serie diaria del departamento en el desarrollo, según dos criterios de Tukey..... 52
Tabla B3 – Cobertura temporal y evolución interanual en el desarrollo.....52
Tabla C1 – Cobertura territorial por municipio en el desarrollo..... 53
Tabla C2 – Caracterización del panel según la partición territorial (antecedente)..... 54
Tabla D1 – Estructura temporal de las series de los ocho municipios..... 54
Tabla D2 – Homogeneidad entre municipios y comparación predictiva de modelos mínimos.....56
Tabla F1 – Entregable 2: desempeño en validación interna, Municipio C.....58
Tabla F2 – Entregable 2: desempeño en el bloque final, evaluado preliminarmente, Municipio C.....58
Tabla F3 – Trabajos ejecutados en el servidor institucional.....58
Tabla F4 – Evidencias del repositorio que respaldan el informe.....59
Tabla G1 – Paso B: grilla de XGBoost y binomial negativa en validación (conjunto (a), ventana expansiva)..... 60
Tabla G2 – Errores por tipo de día en el bloque final (desvianza)..... 61
Tabla G3 – Las cinco semanas de mayor desvianza de la solución en el bloque final.....61
Tabla G4 – Diferencias de desvianza corte a corte en el bloque final (descriptivas)..... 61

UTEC
Universidad Tecnológica

Glosario de abreviaciones y definiciones

α (alfa): Parámetro de dispersión de la binomial negativa. Cuanto mayor es, más supera la varianza a la media; con α = 0 el modelo se reduce al de Poisson. Definido en 2.2.8.

ACF *(Autocorrelation Function)*: Función de autocorrelación: correlación de una serie consigo misma desplazada k períodos. Definida en 2.2.2.

ADF *(Augmented Dickey-Fuller)*: Prueba de raíz unitaria. Su hipótesis nula es la presencia de una raíz unitaria; rechazarla es evidencia a favor de la estacionariedad en media.

ARIMA / SARIMA / SARIMAX *(Autoregressive Integrated Moving Average)*: Familia de modelos de series temporales que combina términos autorregresivos, de diferenciación y de media móvil. SARIMA agrega un componente estacional y SARIMAX, además, regresores exógenos.

Banda nula: Rango de valores de una autocorrelación compatible con la ausencia de estructura: ±1,96/√n, donde n es la cantidad de días; con los 1.316 días del desarrollo vale ±0,0540.

Binomial negativa (NB2): Modelo de conteo con varianza $\mu + \alpha\mu^2$, que admite sobredispersión. Definido en 2.2.8.

Bloque final: Tramo cronológico final de la serie (06/02/2025–31/12/2025), definido al inicio como conjunto de evaluación. Fue consultado durante el Entregable 2 y evaluado una única vez en el Entregable 3, con la configuración ya fijada (Sección 3.5.3).

Box-Cox: Familia de transformaciones de potencia indexada por un parámetro λ, utilizada para estabilizar la varianza. Un λ cercano a 0 corresponde al logaritmo y uno cercano a 0,5, a la raíz cuadrada.

Calibración: Correspondencia entre la intensidad predicha por un modelo y la frecuencia efectivamente observada.

Cobertura: Proporción de observaciones que caen dentro de un intervalo de predicción. La cobertura esperada es la probabilidad que el propio modelo asigna a ese intervalo; con conteos, suele ser mayor que la nominal.

Conjuntos (0), (a), (b) y (c): Conjuntos anidados de variables comparados en la experimentación. Definidos en 3.5.1.

Contraste: Papel asignado a XGBoost en la evaluación final: se evalúa para comparar, pero no puede reemplazar a la solución.

Corte: Cada una de las 47 semanas de evaluación del origen móvil, con su propio entrenamiento y sus 56 predicciones (7 días por 8 municipios).

Dependencia parcial: Predicción media de un modelo al fijar una variable en cada uno de sus valores. Definida en 2.2.12.

Desarrollo: Tramo formado por el entrenamiento inicial y la validación (01/07/2021–05/02/2025, 1.316 días). El diagnóstico se calcula solo sobre él.

Desvianza de Poisson: Medida de discrepancia entre valores observados y predichos apropiada para conteos; pondera el error por el nivel esperado (McCullagh y Nelder, 1989). Métrica principal del trabajo.

Dispersión de Pearson: Suma de los residuos de Pearson al cuadrado dividida por los grados de libertad; un valor cercano a 1 es compatible con un modelo de Poisson.

EE: Error estándar. Aquí, el de la desvianza entre los 47 cortes: el desvío de las desvianzas por corte dividido por $\sqrt{47}$.

EPSG:4326: Sistema de referencia de coordenadas geográficas WGS 84.

Fecha de corte: Último día con datos disponibles para entrenar el modelo exportado: el 31/12/2025. El prototipo predice la semana posterior a esa fecha, en un entorno simulado.

ETL *(Extract, Transform, Load)*: Proceso de extracción, transformación y carga de datos.

Fuga de información: Uso, durante el entrenamiento o la selección de un modelo, de datos que no estarían disponibles al emitir la predicción.

GeoJSON: Formato abierto de intercambio de datos geográficos vectoriales basado en JSON.

GLM *(Generalized Linear Model)*: Modelo lineal generalizado. Definido en 2.2.8.

HAC *(Heteroskedasticity and Autocorrelation Consistent)*: Errores estándar robustos a la heterocedasticidad y a la autocorrelación de los residuos; aquí se usa el estimador de Newey y West (1987) con cuatro rezagos.

Horizonte: Cantidad de días que se predicen desde un origen; en este trabajo, siete.

IA: Inteligencia artificial.

IC 95 %: Intervalo de confianza del 95 % de un parámetro estimado.

Importancia por permutación: Aumento de la métrica de error al permutar al azar los valores de una variable o grupo de variables. Definida en 2.2.12.

Índice de dispersión: Cociente entre la varianza y la media de una variable de conteo. Un valor cercano a 1 es compatible con un proceso de Poisson.

Intervalo de predicción: Rango dentro del cual se espera, con una probabilidad dada, el conteo que se observará. Definido en 2.2.6.

IRLS *(Iteratively Reweighted Least Squares)*: Mínimos cuadrados ponderados iterativos: algoritmo de estimación de los GLM.

JSON *(JavaScript Object Notation)*: Formato de texto estándar para intercambiar datos estructurados.

KPSS *(Kwiatkowski-Phillips-Schmidt-Shin)*: Prueba de estacionariedad cuya hipótesis nula es la opuesta a la del ADF: que la serie es estacionaria.

L0: Referencia sin variables exógenas: promedio de lo observado el mismo día de la semana en las semanas previas. Definida en 2.2.7.

L1: Referencia con calendario: tasa histórica del municipio por un factor de calendario. Definida en 2.2.7.

Línea base: Punto de referencia simple y reproducible frente al cual se juzga si un modelo posterior aporta una mejora real.

Ljung-Box: Prueba conjunta de ausencia de autocorrelación hasta un rezago dado.

MAE *(Mean Absolute Error)*: Promedio del valor absoluto de la diferencia entre lo predicho y lo observado, en siniestros por día.

MCO: Mínimos cuadrados ordinarios.

Media constante: Referencia que predice el promedio del entrenamiento para todos los días y municipios.

Nivel reciente: Media de un municipio en los últimos 28, 56 o 91 días antes del origen.

Origen: Primer día a predecir en un corte; solo se conoce lo observado antes de él.

Origen móvil: Esquema de validación temporal en el que el origen avanza y el modelo se reentrena y evalúa en cada avance. Definido en 2.2.5.

PAA: Proyecto de Aprendizaje Automático, asignatura en la que se desarrolla este trabajo.

PACF *(Partial Autocorrelation Function)*: Función de autocorrelación parcial: correlación entre observaciones separadas por k períodos, descontado el efecto de los rezagos intermedios.

Panel: Estructura de datos en la que cada fila es la combinación de una unidad y un período; aquí, el par (día, municipio).

PID: Proyecto de Ingeniería de Datos, asignatura previa del mismo equipo, de la que este proyecto hereda datos y el tablero.

Potenciación de gradiente: Método que construye en secuencia un conjunto de árboles, cada uno corrigiendo el error de los anteriores. Definido en 2.2.9.

Predicción recursiva: Esquema en el que el modelo usa sus propias predicciones como entrada de los pasos siguientes. Ningún modelo del Entregable 3 la utiliza.

Prueba F de cuasi-verosimilitud: Prueba que compara dos modelos de conteo anidados corrigiendo por la sobredispersión observada.

pydeck: Biblioteca de Python para mapas interactivos, usada en el prototipo.

pytest: Herramienta de Python para escribir y ejecutar pruebas automáticas.

Razón de tasas: Coeficiente exponenciado de un GLM con enlace logarítmico: cuántas veces más siniestros se esperan en un nivel de una variable respecto del de referencia.

Regla de selección: Procedimiento de cuatro pasos, fijado antes de ejecutar, para elegir la solución. Definida en 3.5.4.

Rezago: Valor de la serie k días antes del día que se predice.

RMSE *(Root Mean Squared Error)*: Raíz del promedio de los errores al cuadrado; pondera más los errores grandes que el MAE.

Sensibilidad: Papel asignado al GLM con ventana expansiva en la evaluación final: muestra cuánto depende el resultado de la ventana, sin opción a reemplazar a la solución.

sha256: Función que produce una huella criptográfica de un archivo; si el archivo cambia, la huella cambia.

Slurm: Gestor de trabajos del servidor institucional de cómputo.

Sobredispersión: Situación en la que la varianza de una variable de conteo supera a su media.

Solución: Procedimiento seleccionado: modelo, variables, ventana de entrenamiento y frecuencia de reentrenamiento. Descrita en 4.2.1.

Streamlit: Biblioteca de Python para construir aplicaciones web de datos; con ella está hecho el tablero.

TRL *(Technology Readiness Level)*: Escala de madurez tecnológica. El nivel 5 corresponde a la validación de un prototipo en un entorno relevante.

UNASEV: Unidad Nacional de Seguridad Vial.

UTEC: Universidad Tecnológica del Uruguay.

Ventana deslizante: Variante del origen móvil en la que el entrenamiento usa solo los últimos N días antes del origen.

Ventana expansiva: Variante del origen móvil en la que el entrenamiento usa toda la historia anterior al origen.

WFS *(Web Feature Service)*: Protocolo estándar de acceso a datos geográficos vectoriales.

XGBoost: Implementación de la potenciación de gradiente con árboles. Definida en 2.2.9.

UTEC
Universidad Tecnológica

1. Introducción

La información sobre siniestralidad vial disponible en Uruguay permite describir con detalle lo ocurrido, pero no anticipar lo que ocurrirá a la escala en que se planifica la gestión pública. Los informes oficiales publican agregados anuales por departamento y el antecedente nacional de modelado proyecta, con periodicidad mensual, la serie de personas lesionadas del país (Unidad Nacional de Seguridad Vial, 2025, 2026). Entre esos agregados y la decisión de dónde reforzar la fiscalización la semana próxima existe una brecha de escala, que este trabajo aborda transformando el registro histórico en estimaciones prospectivas con su margen de error declarado.

El documento presenta el Proyecto de Aprendizaje Automático (PAA) de la Licenciatura en Ingeniería de Datos e Inteligencia Artificial de la Universidad Tecnológica (UTEC). El proyecto continúa el Proyecto de Ingeniería de Datos (PID) del mismo equipo, del que hereda el registro nacional de siniestros ya unificado y georreferenciado y un tablero de visualización desarrollado en Streamlit. Concretamente, estima la cantidad esperada de siniestros de tránsito registrados por municipio y por día en el departamento de Montevideo, con un horizonte de siete días, a partir de tres insumos sobre un período de 1.645 días (del 1.º de julio de 2021 al 31 de diciembre de 2025): el registro nacional de la Unidad Nacional de Seguridad Vial (UNASEV), del que se conservan 36.612 hechos de un total de 224.694; la cartografía oficial de los ocho municipios de Montevideo; y una serie meteorológica diaria del departamento, preparada pero no utilizada por la solución final (Sección 1.4).

El ámbito se restringe a Montevideo y su unidad territorial es el municipio. El departamento concentra el volumen de siniestros necesario para sostener series de conteo suficientemente pobladas, y el municipio es la partición administrativa oficial, con autoridades propias, de modo que una estimación referida a él puede traducirse en una decisión de gestión. Particiones más finas, como una grilla de un kilómetro o los barrios, se ensayaron en etapas previas y se descartaron porque la mayoría de sus días no registra ningún siniestro (Anexo C, Tabla C2).

El informe se organiza en seis capítulos: el 1 plantea el problema, la pregunta orientadora y la hipótesis, los objetivos, el alcance y las limitaciones; el 2 reúne los antecedentes y los fundamentos e identifica la brecha; el 3 describe el diseño, los datos y los procedimientos; el 4 presenta los resultados; el 5 los interpreta y discute su validez; y el 6 verifica el cumplimiento de los objetivos y formula recomendaciones. Los anexos A a G reúnen el

detalle de las fuentes y los datos, la línea base del Entregable 2, las ejecuciones en el servidor, las evidencias del repositorio y resultados complementarios.

1.1 Problema

Ninguno de los formatos de información disponibles responde la pregunta que enfrenta quien debe decidir dónde concentrar un operativo de fiscalización la semana próxima, o si conviene reforzar la presencia en una zona durante un fin de semana largo. La falta de capacidad prospectiva no responde a la falta de datos sino a su nivel de agregación: el registro nacional acumula más de doscientos mil hechos georreferenciados y la cartografía de los municipios es de acceso abierto. Lo que falta es un procedimiento que convierta ese registro en una estimación por zona y período, con su margen de error declarado y evaluado de forma honesta. La relevancia del fenómeno como problema de salud pública se documenta en la Sección 2.1.1.

El objeto de estudio es la serie diaria de siniestros de tránsito registrados en cada uno de los ocho municipios de Montevideo. El problema se formula como la estimación de la cantidad esperada de siniestros registrados por municipio y por día, con siete días de anticipación, a partir del registro histórico y de variables conocidas al momento de predecir, evaluada con un protocolo que respete el orden temporal de los datos y compare las alternativas contra referencias simples y explícitas.

El problema también se delimita por lo que no es. El objeto de la predicción no es el siniestro individual: los datos no permiten anticipar en qué esquina ni a qué hora ocurrirá un hecho. Tampoco es el riesgo por unidad de exposición, porque no se dispone de volumen de tránsito: lo que se modela es la cantidad de siniestros registrados, no la probabilidad de siniestro por viaje. Un municipio con más siniestros registrados no es necesariamente el más peligroso para quien circula por él, y el informe se abstiene de esa lectura.

1.2 Pregunta orientadora, hipótesis o desafío de ingeniería

La propuesta aprobada del proyecto, fechada el 17 de agosto de 2026, formuló la siguiente pregunta orientadora: *¿es posible estimar, a partir de la serie histórica de siniestros y de variables exógenas (clima y calendario), la cantidad esperada de siniestros por zona y período?* En este trabajo, la zona es el municipio, el período es el día y la estimación se emite con siete días de anticipación. «Es posible» se entiende en sentido operativo: una estimación es útil si mejora de forma consistente a referencias simples y explícitas sobre datos que no intervinieron en su elección.

La hipótesis se formuló a partir del diagnóstico de los ocho municipios, ejecutado el 5 de octubre de 2026 y registrado en el repositorio el 8 de octubre, antes de que se ejecutara cualquier modelo candidato (19 de octubre): *un solo modelo común con una variable de nivel por municipio es suficiente para el panel; los modelos separados por municipio no están respaldados por los datos, con la posible excepción del Municipio A, que se aborda primero con un término propio dentro del modelo común.* La hipótesis se mantiene tal como se formuló, con independencia de lo que muestren los resultados; su contraste se discute en la Sección 5.1.

El proyecto plantea además un desafío de ingeniería: integrar la solución seleccionada en el tablero heredado del PID como un prototipo funcional de nivel de madurez tecnológica 5 (TRL 5), que prediga sin reentrenar y pueda ejecutarse sin la infraestructura de bases de datos del tablero original.

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar un modelo de aprendizaje automático para la predicción de siniestros de tránsito a partir de series temporales e integrar sus resultados en una interfaz que permita visualizar las zonas y períodos con mayor cantidad esperada de siniestros.

1.3.2 Objetivos específicos

- OE1. Adaptar el proceso ETL del Proyecto de Ingeniería de Datos para obtener la granularidad temporal requerida y reutilizar las variables exógenas ya disponibles, evitando nuevas llamadas recurrentes a interfaces externas con límite de uso.
- OE2. Evaluar y comparar estrategias de entrenamiento y validación (con y sin variables exógenas, ventana expansiva y ventana deslizante) mediante métricas de error estandarizadas.
- OE3. Seleccionar el modelo con mejor desempeño y solidez, documentando sus limitaciones y sesgos previsibles.
- OE4. Implementar en el tablero una nueva pestaña con interfaz gráfica intuitiva que permita visualizar las predicciones y la distribución territorial de la cantidad esperada de siniestros sobre un mapa.

La propuesta no fijó umbrales de desempeño: declaró que las métricas se documentarían una vez obtenidas. El Cuadro 1 explicita, para cada objetivo, para la pregunta y para la hipótesis, el indicador con que se juzga su cumplimiento y el medio que lo verifica. Los

criterios de comparación se fijaron antes de ejecutar los experimentos (Sección 3.5.4) y el estado de los objetivos se registró antes de leer el bloque final de evaluación (Sección 6.1).

Cuadro 1 – Objetivos, pregunta e hipótesis: indicadores y medios de verificación

Elemento	Indicador	Medio de verificación
Objetivo general	Desvianza de la solución en el bloque final frente a las referencias; integración al tablero	Secciones 4.2 y 4.3.4; modelo exportado y pestaña en el repositorio
OE1 – ETL	Panel día-municipio completo, sin fuga, regenerable desde las fuentes; verificaciones automáticas superadas	Sección 4.1.3; Anexo E; cuaderno de preparación
OE2 – Estrategias	Desvianza de Poisson media y su error estándar en 47 cortes de validación, con y sin exógenas y por ventana	Tablas 5 y 6; registro de experimentos (38 configuraciones)
OE3 – Selección	Aplicación de la regla de selección fijada antes de ejecutar; desempeño en el bloque final frente a la referencia; limitaciones documentadas	Secciones 4.3.3, 4.3.4, 4.4 y 5.4; cuaderno de experimentación y archivo de configuración registrado el 19/10/2026
OE4 – Pestaña	Pestaña operativa en sus dos modos, sin bases de datos ni reentrenamiento; pruebas del pipeline superadas	Sección 4.2.3; Tabla 10; registro de pruebas del pipeline
Pregunta orientadora	Diferencia de desvianza frente a la media constante, L0 y L1 en datos no usados para elegir	Sección 4.3.4 (Tabla 7); Sección 5.1
Hipótesis	Ningún conjunto más complejo que el modelo común con nivel por municipio lo supera por más de un error estándar; efecto de excluir un municipio	Tabla 5; Sección 4.4.5; Sección 5.1

Fuente: elaboración propia.

1.4 Alcance

En lo territorial, el estudio se circunscribe a Montevideo y adopta como unidad espacial los ocho municipios oficiales; en lo temporal, abarca del 1.º de julio de 2021 al 31 de diciembre de 2025, con periodicidad diaria (la evidencia que fundamenta el inicio del período está en la Sección 3.2). La unidad de análisis es el par formado por un día y un municipio, y la variable objetivo es la cantidad de siniestros registrados en ese par. El producto es un procedimiento reproducible que estima esa cantidad con intervalos de predicción, su evaluación desagregada por municipio, el modelo entrenado con sus artefactos de inferencia y su integración en el tablero heredado como prototipo funcional, ejecutable en entorno local.

Quedan fuera del alcance la gravedad de los siniestros y su distribución horaria, que la agregación diaria por municipio descarta; el riesgo por unidad de exposición, por

ausencia de datos de tránsito; la localización puntual de hechos individuales; y las causas del fenómeno: el trabajo es predictivo, de modo que la asociación entre una variable y la cantidad de siniestros no autoriza a afirmar que la primera produzca la segunda.

Las decisiones tomadas durante el desarrollo modificaron el alcance inicial en cinco puntos. Primero, el protocolo se puso a punto sobre la serie de un único municipio (Entregable 2) antes de extenderse al panel de ocho (Entregable 3). Segundo, el árbol de decisión de la línea base se retiró de los candidatos antes de ejecutarlos, porque no extrapoló la tendencia, y se reemplazó por la potenciación de gradiente con pérdida de Poisson (Sección 2.2.9). Tercero, la meteorología se excluyó de los modelos: la lluvia del día a predecir no se conoce con siete días de anticipación y el diagnóstico no le encontró aporte (Sección 3.5.1). Cuarto, los modelos clásicos de series temporales de la familia SARIMA, previstos en la propuesta, no se priorizaron (Sección 2.2.10). Quinto, el prototipo se ejecuta en entorno local; su despliegue en el tablero del servidor institucional quedó pendiente (Sección 5.3).

1.4.1 Entregables y criterios de aceptación

La propuesta no definió criterios de aceptación propios. Los del Cuadro 2 combinan los resultados que la guía de la asignatura exige para el Entregable 3 con los compromisos de la propuesta, en particular el de reservar un tramo final de los datos que no se use para seleccionar modelos ni ajustar hiperparámetros.

Cuadro 2 – Entregables y criterios de aceptación

Entregable	Criterio de aceptación	Dónde se verifica
Experimentación sistemática	Alternativas de variables, modelos, hiperparámetros y ventanas comparadas con un protocolo común; todas las configuraciones registradas, incluidas las descartadas	Sección 4.3.2; Anexo G
Solución seleccionada	Elegida con criterios explícitos, no solo con una métrica, y sin usar el bloque final	Secciones 3.5.4 y 4.3.3
Evaluación final	Una única evaluación sobre el bloque final con la configuración ya fijada, comparada con las referencias; el bloque se había consultado antes y no es una prueba independiente (Sección 3.5.3)	Sección 4.3.4
Explicación y análisis crítico	Interpretación del modelo; errores por municipio, día y semana; calibración; intervalos; robustez	Secciones 4.2.2 y 4.4
Modelo y artefactos de inferencia	Modelo entrenado que se carga y predice sin reentrenar; entrenamiento reproducible en el servidor institucional	Secciones 4.2.3 y 4.4.6; Anexo F

Entregable	Criterio de aceptación	Dónde se verifica
Pruebas del pipeline	Pruebas automáticas superadas, con registro de errores hallados y su corrección	Sección 4.4.6 (Tabla 10)
Prototipo TRL 5	Pestaña integrada al tablero que muestra predicciones comprensibles e instrucciones para ejecutarla sin reentrenar	Sección 4.2.3

Fuente: elaboración propia.

1.5 Limitaciones y supuestos

Las limitaciones se enuncian aquí de forma sintética; su evidencia y su tratamiento se analizan en la Sección 5.4.

- Subregistro. Los datos comprenden solo los siniestros registrados; la fracción no registrada es desconocida y posiblemente desigual entre municipios.
- Sin datos de exposición. Sin volumen de tránsito, las conclusiones se limitan a la cantidad esperada de siniestros registrados y no al riesgo por viaje.
- Zonas parecidas. La razón entre el municipio con más siniestros y el que menos registra es de 1,71, lo que estrecha el margen para ordenarlos y debilita la prueba de generalización.
- Evaluación sobre una única serie de 47 semanas. El bloque final es un tramo continuo que ya se había consultado durante el Entregable 2: no es una prueba independiente ni admite réplicas.
- Restricciones del marco académico. El plazo y los recursos de la asignatura obligaron a priorizar la solidez del procedimiento sobre la exploración exhaustiva de alternativas.

El trabajo descansa además en cinco supuestos. S1: el procedimiento de registro de UNASEV fue homogéneo durante el período, de modo que los cambios en la serie reflejan cambios en los siniestros registrados y no en la forma de registrarlos. S2: las coordenadas de origen ubican correctamente cada hecho, condición de la asignación a su municipio. S3: los feriados oficiales y bancarios se conocen de antemano, por lo que el calendario está disponible al predecir. S4: la relación entre el nivel de cada municipio, el calendario y la cantidad de siniestros se mantiene estable dentro de una ventana de un año, lo que justifica reentrenar con los últimos 364 días. S5: la semana a predecir no presenta perturbaciones ajenas a la historia reciente, como cambios normativos o eventos excepcionales.

UTEC
Universidad Tecnológica

2. Marco conceptual

Este capítulo reúne los antecedentes que sirven de punto de partida al proyecto (2.1), los fundamentos conceptuales y técnicos que justifican sus decisiones de modelado y evaluación (2.2), y la brecha que el trabajo atiende, con su contribución (2.3).

2.1 Antecedentes y soluciones existentes

La revisión se organizó en cinco núcleos: la siniestralidad vial como problema público y objeto de medición, los modelos de conteo para la frecuencia de siniestros, los modelos clásicos de series temporales, el aprendizaje automático aplicado a la predicción espacialmente desagregada y el papel de la meteorología. El Cuadro 3 sintetiza los trabajos que orientaron las decisiones.

2.1.1 La siniestralidad vial como problema público y como objeto de medición

Los siniestros de tránsito son una de las principales causas de mortalidad en el mundo y se cobran alrededor de 1,19 millones de vidas por año (World Health Organization, 2023). En el marco del Decenio de Acción para la Seguridad Vial 2021-2030, la gestión de datos se concibe como un insumo estratégico para las políticas basadas en evidencia. En Uruguay, la UNASEV registra la siniestralidad y publica informes anuales por departamento (Unidad Nacional de Seguridad Vial, 2026); Montevideo concentra el mayor volumen absoluto de hechos, en un entorno urbano denso.

2.1.2 Modelos de conteo para la frecuencia de siniestros

La literatura de seguridad vial trata la cantidad de siniestros en una unidad espacial y un período como una variable de conteo, y adopta la regresión de Poisson y la binomial negativa como modelos de referencia (Lord y Mannering, 2010). La revisión de esos autores identifica como problemas centrales de estos datos la sobredispersión —varianza mayor que la media—, las medias muestrales bajas, la ausencia de medidas de exposición y la correlación temporal y espacial, y discute las extensiones propuestas para cada uno. Ese marco es el punto de partida de este trabajo: la variable objetivo es un conteo y las familias de modelos evaluadas derivan de él (Sección 2.2.8).

2.1.3 Modelos clásicos de series temporales y soluciones existentes

La predicción mediante modelos autorregresivos estacionales (SARIMA) se apoya en los patrones periódicos semanales y anuales de la movilidad (Deretić et al., 2022), y la metodología de Box-Jenkins ofrece un marco formal de identificación y diagnóstico

(Hyndman y Athanasopoulos, 2021). La solución existente más próxima es el modelo SARIMA de la UNASEV, que proyecta personas lesionadas a escala nacional y mensual (Unidad Nacional de Seguridad Vial, 2025). Junto con los informes anuales y el tablero descriptivo desarrollado en el PID, que muestra lo ocurrido pero no lo anticipa, conforma el conjunto de herramientas disponibles; en la revisión realizada no se identificó una herramienta prospectiva a escala municipal.

2.1.4 Aprendizaje automático y predicción espacialmente desagregada

La predicción desagregada enfrenta conteos bajos o nulos en áreas reducidas, la interdependencia espacio-temporal entre zonas y la variabilidad no observada del comportamiento humano (de Medrano y Aznarte, 2021). Una revisión sistemática de comparaciones entre modelos ARIMA y de aprendizaje automático en distintos dominios de aplicación encuentra que los segundos, en particular los basados en árboles y sus conjuntos, suelen superar a los primeros en series complejas, y advierte que muchos estudios omiten una línea base estadística bien especificada contra la cual juzgar si la mejora es real (Kontopoulou et al., 2023). Se la utiliza como antecedente metodológico general, no como evidencia del desempeño de esos modelos en siniestralidad vial.

2.1.5 Las condiciones meteorológicas como variables exógenas

A escala diaria, la precipitación aumenta el riesgo de siniestro, y el efecto crece con la duración del período seco previo (Eisenberg, 2004). Ese efecto se manifiesta el mismo día de la lluvia, lo que condiciona su uso predictivo: con siete días de anticipación solo podría incorporarse a través de un pronóstico meteorológico (Sección 3.5.1).

Cuadro 3 – Síntesis de los antecedentes revisados

Autores (año)	Técnicas	Metodología / datos	Aporte para este trabajo
World Health Organization (2023)	Estadística descriptiva; indicadores comparados	Relevamiento global de registros nacionales	Dimensiona la siniestralidad como problema de salud pública y vincula las metas del Decenio de Acción con la calidad de los sistemas de información
Lord y Mannering (2010)	Poisson, binomial negativa y sus extensiones	Revisión metodológica de modelos de frecuencia de siniestros	Establece los modelos de conteo como referencia y sistematiza sus problemas: sobredispersión, medias bajas, exposición y correlación
Eisenberg (2004)	Binomial negativa; rezagos de precipitación	Datos estado-día y estado-mes, EE. UU., 1975-2000	La lluvia aumenta el riesgo a escala diaria y el efecto crece con el período seco previo

Autores (año)	Técnicas	Metodología / datos	Aporte para este trabajo
Hyndman y Koehler (2006)	Análisis comparado de métricas de error	Evaluación teórica y empírica	Limitaciones de las métricas porcentuales ante valores nulos; propuesta del error escalado
de Medrano y Aznarte (2021)	Redes neuronales espacio-temporales	Predicción por barrio en Madrid	Rareza de los siniestros e interdependencia entre zonas como dificultades de la predicción desagregada
Deretić et al. (2022)	SARIMA; Box-Jenkins	Identificación por ACF y PACF y diagnóstico de residuos	Pertinencia del enfoque estacional y procedimiento reproducible de especificación
Kontopoulou et al. (2023)	ARIMA, SARIMA, árboles, potenciación de gradiente	Revisión sistemática de estudios comparativos en diversos dominios	Antecedente metodológico general: el aprendizaje automático suele superar a ARIMA, pero muchos estudios omiten una línea base bien especificada
Unidad Nacional de Seguridad Vial (2025)	SARIMA	Serie nacional mensual de personas lesionadas	Antecedente nacional directo, agregado en el espacio y en el tiempo

Fuente: elaboración propia.

2.2 Fundamentos conceptuales y técnicos

Los apartados 2.2.1 a 2.2.7 presentan los fundamentos conceptuales; los 2.2.8 a 2.2.12, los técnicos y por qué se eligieron para estos datos.

2.2.1 Siniestro de tránsito y unidad de análisis

En este trabajo, un siniestro de tránsito es todo hecho ocurrido en la vía pública con participación de al menos un vehículo que figura en el registro de la UNASEV. El registro clasifica cada hecho por tipo y por gravedad, con cuatro niveles: fatal, grave, leve y sin lesionados (Sección 3.2). El proyecto cuenta todos los hechos registrados, sin distinguir tipo ni gravedad, y la unidad de análisis es el par formado por un día y un municipio. Ninguna afirmación del informe se extiende a hechos que no ingresan al registro.

2.2.2 Serie temporal, componentes y estacionariedad

Una serie temporal es una secuencia de observaciones ordenadas a intervalos regulares, que el análisis clásico descompone en tendencia, estacionalidad —aquí semanal y anual— y un componente irregular (Hyndman y Athanasopoulos, 2021). La familia ARIMA requiere estacionariedad y se identifica con la función de autocorrelación (ACF) y la

autocorrelación parcial (PACF). Como una serie de Poisson sin memoria también produce autocorrelaciones no nulas, estas se contrastan con la banda nula ±1,96/√n.

2.2.3 Datos de conteo, sobredispersión y exceso de ceros

La variable objetivo es un conteo entero no negativo. El índice de dispersión —cociente entre varianza y media— vale uno en un proceso de Poisson; valores mayores indican sobredispersión y motivan la binomial negativa (Lord y Mannering, 2010). La desagregación espacial fina induce exceso de ceros (de Medrano y Aznarte, 2021), pero la partición por municipios lo reduce a menos del 10 % de los pares día-municipio y permite tratar el problema como una regresión de conteo ordinaria. La proporción de ceros, por sí sola, no prueba la ausencia de inflación de ceros, aunque con el diagnóstico disponible no hay evidencia para priorizar esa familia (Sección 4.1.2).

2.2.4 Variables exógenas, rezagos y disponibilidad al predecir

Las variables exógenas aportan información sin ser predichas por el modelo; aquí, el calendario y la meteorología. Los rezagos —valores pasados de la propia serie— y las variables derivadas, como el nivel medio reciente, permiten reformular la serie como un problema de aprendizaje supervisado sobre una tabla de observaciones y atributos. La condición que gobierna su uso es la disponibilidad al predecir: con un horizonte de siete días, solo pueden usarse variables conocidas antes del primer día a predecir, lo que excluye los rezagos de menos de siete días salvo que el modelo realimente sus propias predicciones, y excluye la meteorología observada del día a predecir.

2.2.5 Fuga de información y validación temporal

La fuga de información consiste en usar, al entrenar o elegir un modelo, datos que no estarían disponibles al emitir la predicción. Su prevención exige particiones cronológicas, ajustar toda transformación solo con el entrenamiento y evaluar por origen móvil: el momento desde el cual se predice avanza, y en cada avance el modelo se reentrena con lo observado antes de él y se evalúa sobre el horizonte siguiente (Hyndman y Athanasopoulos, 2021). El entrenamiento puede usar toda la historia disponible (ventana expansiva) o solo un tramo reciente de longitud fija (ventana deslizante), que sigue mejor un nivel cambiante a costa de usar menos datos.

2.2.6 Métricas, calibración e intervalos de predicción

En un problema de conteo se estima la intensidad esperada del proceso. La métrica principal es la desvianza de Poisson media, que corresponde a la familia de la variable,

pondera el error según el nivel esperado y penaliza con fuerza predecir cerca de cero cuando se observan siniestros (McCullagh y Nelder, 1989). El MAE y el RMSE la acompañan en siniestros por día. Se prescinde del error escalado propuesto por Hyndman y Koehler (2006) porque expresa el error relativo a un método de referencia y no en la unidad en que se planifica; las referencias se comparan explícitamente (Sección 2.2.7).

La calibración es la correspondencia entre la intensidad predicha y la frecuencia observada; se evalúa con la razón entre el total predicho y el observado, y por deciles de la predicción. Un intervalo de predicción acota el conteo que se observará con una probabilidad dada. Con una variable discreta, el intervalo entre los cuantiles 0,10 y 0,90 cubre según el propio modelo al menos el 80 % de los casos, y en general más; por eso su cobertura observada se compara con la cobertura que el modelo espera, y no con el valor nominal.

Cuando la evaluación se repite en varios cortes de origen móvil, el error estándar de la métrica entre cortes mide cuánto varía de una semana a otra. Una regla de selección habitual considera empatadas las alternativas que quedan a menos de un error estándar de la mejor y, entre ellas, prefiere la más simple (Hastie et al., 2009); es el criterio que adopta este trabajo (Sección 3.5.4).

2.2.7 Línea base y referencias

Una línea base es un punto de referencia simple y reproducible que permite juzgar si un modelo posterior aporta una mejora real: una reducción del error que no supere con claridad a la línea base indica que la complejidad adicional no se justifica (Kontopoulou et al., 2023). Este trabajo usa tres referencias. La media constante predice el promedio del entrenamiento. L0 usa solo la historia de la serie: predice cada día con el promedio de lo observado el mismo día de la semana en las semanas anteriores. L1 descompone la intensidad en la tasa histórica del municipio por un factor de calendario, ambos estimados con el entrenamiento; la forma multiplicativa se prefiere al cruce completo de municipio por día, que fuera de muestra rinde peor que una constante (Sección 4.1.2).

2.2.8 Modelos lineales generalizados para conteos

Un modelo lineal generalizado (GLM) de Poisson con enlace logarítmico expresa el logaritmo de la intensidad esperada como una combinación lineal de las variables, de modo que cada coeficiente, exponenciado, es una razón de tasas: cuántas veces más siniestros se esperan en un nivel de la variable respecto del de referencia, con el resto

fijo. Se estima por máxima verosimilitud mediante mínimos cuadrados ponderados iterativos (IRLS), y su desvianza es la misma que se usa como métrica (McCullagh y Nelder, 1989). Con indicadoras de municipio y de día, el GLM de Poisson generaliza la referencia L1: estima conjuntamente el nivel de cada municipio y el efecto de calendario.

La binomial negativa agrega un parámetro de dispersión α y, en su forma NB2, tiene varianza $\mu + \alpha\mu^2$, que se reduce a la de Poisson cuando α tiende a cero; es el modelo habitual ante la sobredispersión de los datos de siniestros (Lord y Mannering, 2010). α puede estimarse por máxima verosimilitud o, de forma más simple, por momentos, a partir de la diferencia entre la varianza observada de los residuos y la media. Con sobredispersión leve, la media de NB2 es casi la de Poisson; su aporte está en los intervalos de predicción, más anchos y acordes con la variabilidad real, y en la inferencia sobre los coeficientes.

2.2.9 Árboles de decisión y potenciación de gradiente

Un árbol de decisión particiona el espacio de atributos mediante cortes binarios y asigna una predicción a cada región; representa no linealidades e interacciones sin especificarlas y no exige estacionariedad, pero tiene varianza alta y no extrapola fuera del rango observado, de modo que una tendencia sostenida debe tratarse con atributos explícitos (Géron, 2023). La potenciación de gradiente construye un conjunto de árboles poco profundos en secuencia, cada uno corrigiendo el error de los anteriores, y reduce la varianza del árbol único (Géron, 2023). XGBoost es una implementación escalable de este método (Chen y Guestrin, 2016) que admite como función de pérdida la verosimilitud de Poisson («count:poisson»), coherente con la naturaleza de conteo del objetivo; sus hiperparámetros principales son la profundidad de los árboles, su cantidad y la tasa de aprendizaje. Su interés aquí es contrastar si las interacciones que un GLM aditivo no representa aportan predicción.

2.2.10 Modelos de series temporales: viabilidad de SARIMA

La familia ARIMA y su extensión estacional con regresores exógenos (SARIMAX) es la aproximación clásica en siniestralidad y la del antecedente nacional. Su aporte sobre un panel depende de que cada serie conserve autocorrelación distinguible del ruido una vez descontado el calendario; en este panel, ningún municipio la conserva en el rezago de siete días y solo uno supera la banda nula en el de un día (Sección 4.1.2). No priorizarla es una decisión de pertinencia, costo y alcance —ocho series que especificar y diagnosticar para un aporte esperado reducido—, no de validez técnica.

2.2.11 Modelos locales y globales, y exclusión de zonas

Un modelo local ajusta una especificación por zona; uno global ajusta una sola para todas, con atributos de nivel de zona, y aprovecha la información compartida cuando los conteos individuales son bajos (de Medrano y Aznarte, 2021). Para evaluar si un modelo global depende de los datos de una zona en particular, el procedimiento defendible con pocas unidades es excluir una zona por vez y promediar, asumiendo que la estimación tiene varianza alta.

2.2.12 Explicabilidad e interpretación

La explicabilidad se entiende como la capacidad de fundamentar el comportamiento del modelo con evidencia obtenida en su desarrollo y evaluación. En un GLM, los coeficientes exponenciados son razones de tasas legibles con su intervalo de confianza. Para modelos de conjunto, como XGBoost, se usan recursos independientes del modelo: la importancia por permutación, que mide cuánto empeora la métrica al permutar al azar los valores de una variable o de un grupo de variables, y la dependencia parcial, que muestra la predicción media al fijar una variable en cada uno de sus valores (Molnar, 2025). Ambas describen de qué depende el modelo, no qué causa el fenómeno.

2.3 Brecha identificada y contribución del proyecto

La revisión permite identificar cuatro brechas. En granularidad espacial, no se identificaron antecedentes que modelen la siniestralidad a nivel municipal en Montevideo. En granularidad temporal, predominan los datos mensuales, que diluyen el ciclo semanal (Eisenberg, 2004). En comparación, la revisión de Kontopoulou et al. (2023), referida a diversos dominios, señala que es habitual omitir una línea base simple y bien especificada, y en la revisión realizada fueron escasas las evaluaciones que comparan modelos estadísticos de conteo y de aprendizaje automático bajo un mismo protocolo. Por último, las herramientas existentes son descriptivas: ninguna emite una estimación prospectiva con su margen de error.

La contribución del proyecto responde a esas brechas: un panel diario por municipio de Montevideo, construido de forma reproducible y sin fuga de información; una comparación de modelos de conteo y de potenciación de gradiente contra tres referencias explícitas, con un protocolo temporal y una regla de selección fijados antes de ejecutar; una solución con intervalos de predicción cuya cobertura se verifica; y su integración en el tablero existente como prototipo que estima la semana siguiente.

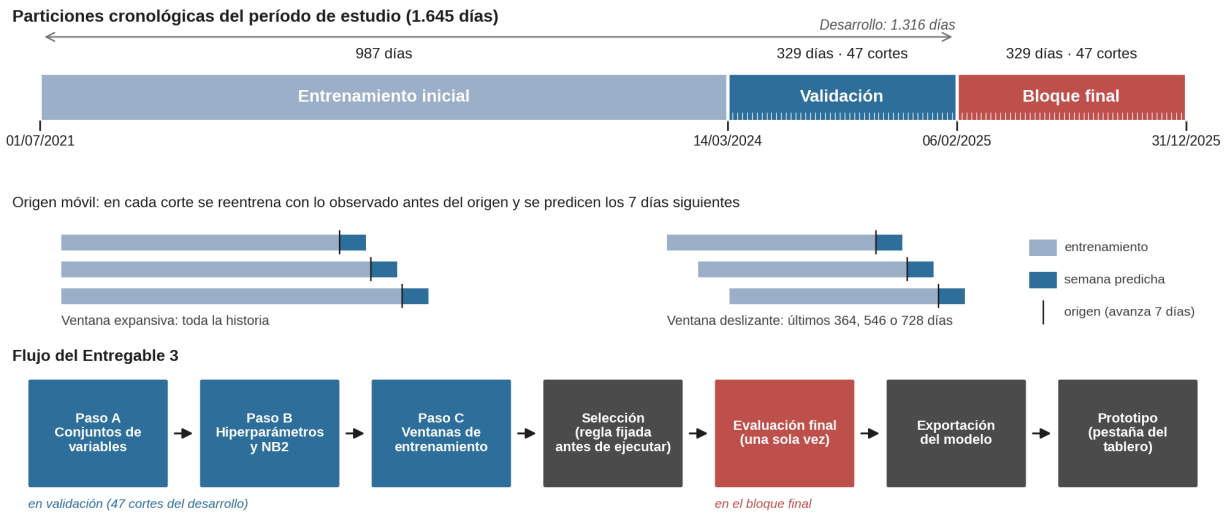
3. Metodología de investigación, diseño y desarrollo de la solución

3.1 Enfoque metodológico y diseño del proyecto

La investigación es aplicada y de enfoque cuantitativo: busca resolver un problema práctico, estimar con anticipación la cantidad de siniestros en una unidad territorial de gestión, a partir de registros administrativos y series numéricas, sin recolección de datos primarios. Es descriptiva en su primera etapa (fuentes, calidad, cobertura y estructura de los datos) y predictiva en la segunda (estimación fuera de muestra); no tiene alcance explicativo ni causal. Por la dependencia cronológica de las observaciones y el riesgo de fuga de información (Sección 2.2.5), el diseño prescinde de particiones aleatorias y adopta un esquema cronológico con validación por origen móvil.

El proyecto se desarrolló en etapas. Tras la propuesta, el Entregable 2 preparó y diagnosticó los datos y puso a punto el protocolo sobre la serie del Municipio C. El Entregable 3 extendió el protocolo al panel de ocho municipios: experimentación en la ventana de validación en tres pasos —conjuntos de variables, hiperparámetros y ventanas—, selección con una regla fijada antes de ejecutar, una única evaluación final con la configuración ya registrada, interpretación y análisis de errores, exportación del modelo con su entrenamiento reproducido en el servidor institucional, e integración en el tablero como prototipo con pruebas del pipeline. La Ilustración 1 resume el diseño.

Ilustración 1 – Diseño del protocolo de evaluación



Fuente: elaboración propia.

3.2 Contexto, población, participantes y unidad de análisis

El ámbito es el departamento de Montevideo, particionado en sus ocho municipios oficiales (A, B, C, CH, D, E, F y G). Cada hecho se asigna a su municipio por intersección entre sus coordenadas de origen y la capa vectorial oficial (Intendencia de Montevideo, s. f.); como los límites discurren mayoritariamente sobre avenidas y cursos de agua de gran porte, el riesgo de error en los bordes es menor que con unidades más pequeñas.

La población son los siniestros de tránsito registrados por la UNASEV en Montevideo entre el 1.º de julio de 2021 y el 31 de diciembre de 2025: 36.612 hechos. Se obtienen del archivo nacional de 224.694 registros eliminando 347 filas duplicadas exactas (224.347), reteniendo Montevideo (62.288), acotando el período (36.623) y descartando 11 hechos que no caen dentro de ningún municipio (Anexo A, Tabla A2). Los participantes son todos los hechos del registro, sin distinción de tipo ni gravedad. El archivo nacional clasifica los hechos por tipo —colisión entre vehículos 64,98 %, caída 11,55 %, despiste 11,21 %, atropello de peatón 5,67 %, atropello de animales 3,55 % y colisión con obstáculo 3,02 %— y por gravedad —leve 59,95 %, sin lesionados 28,12 %, grave 10,49 % y fatal 1,45 %—; ninguna columna identifica el tipo de vehículo ni de participante. Esas proporciones corresponden al archivo nacional completo: la composición del recorte de Montevideo no se calculó.

La unidad de análisis es el par (día, municipio) definido en la Sección 2.2.1, organizado como un panel con ceros explícitos de 13.160 filas (1.645 días por ocho municipios); la variable objetivo es la cantidad de siniestros registrados en cada par. El período comienza el 1.º de julio de 2021 porque el primer semestre de ese año presenta un nivel deprimido de forma atípica. Una explicación posible, que este trabajo no verifica, son las restricciones de movilidad de la pandemia de COVID-19; la decisión se funda solo en el comportamiento de la serie, evaluado en tres pasos con el bloque de desarrollo (Sección 4.1.1).

El estudio hereda del PID el registro unificado y georreferenciado y el tablero; la preparación para el modelado se rediseñó para la nueva unidad de análisis, con archivos planos que se ejecutan sin infraestructura (Sección 3.4).

3.3 Técnicas, instrumentos y fuentes de información

La investigación se apoya en tres fuentes secundarias, cuya procedencia se detalla en el Anexo A (Tabla A1): el registro de siniestros de la UNASEV (224.694 hechos, 11 columnas, entre ellas fecha, hora, día de la semana, departamento, coordenadas, tipo de

siniestro y gravedad); la capa de municipios del servidor geográfico de la Intendencia de Montevideo (s. f.), de uso sin costos ni restricciones; y una serie meteorológica diaria de Open-Meteo (s. f.) para las coordenadas -34,87 y -56,17, que asume uniformidad espacial en el departamento. En cada ejecución, los procedimientos calculan la huella criptográfica sha256 de cada archivo y la comparan con la registrada, de modo que cada resultado puede atribuirse a una versión determinada de los datos.

Los instrumentos de procesamiento son cuadernos de Python que se ejecutan de principio a fin sin intervención (preparación, diagnóstico, experimentación y evaluación final) y dos módulos compartidos: uno construye las variables y otro entrena, guarda, carga y predice con el modelo; los usan tanto los cuadernos como el prototipo, de modo que la inferencia es coherente con el entrenamiento. Las bibliotecas principales son pandas 2.3.3, NumPy 2.5.2, SciPy 1.18.1, statsmodels 0.14.6 (GLM y binomial negativa), xgboost 3.4.1, holidays 0.103 (feriados), Streamlit 1.65.0 y pydeck 0.9.3 (prototipo) y pytest 9.1.1 (pruebas). Cada cuaderno escribe sus tablas y figuras, que son la fuente de todas las cifras de este informe, y la experimentación mantiene un registro con cada configuración evaluada, incluidas las descartadas.

El entorno se fija con dos archivos: uno con las 25 dependencias directas y su versión exacta, y otro con el árbol completo, que se aplica como restricción al instalar. Los cuadernos del Entregable 3 se ejecutaron con Python 3.13.2; el árbol completo se regeneró el 21/10/2026 en un entorno limpio con Python 3.13.9 al incorporar las dependencias del prototipo, sin cambiar ninguna versión anterior. La reproducibilidad del entorno se verificó el 20/09/2026 reejecutando todos los cuadernos de entonces en un entorno limpio, sin diferencias numéricas. El servidor institucional de cómputo, que ejecuta trabajos mediante el gestor Slurm dentro de un contenedor con su propio entorno, se usó para reproducir el entrenamiento del modelo final con una implementación independiente (Sección 3.5.6). Los datos crudos no se versionan; las instrucciones del repositorio indican cómo obtenerlos, y la preparación regenera el conjunto de modelado a partir de ellos.

3.4 Procedimiento de recolección y diagnóstico

El archivo de la UNASEV proviene del PID (26,19 MB, última modificación registrada el 24/08/2026). La capa de municipios se descargó el 7 de setiembre de 2026 mediante el servicio WFS en formato GeoJSON. La serie meteorológica se descargó una única vez y se almacena localmente para no repetir llamadas a un servicio con límite de uso. Las

fechas de descarga del registro y de la serie meteorológica no quedaron documentadas; la trazabilidad de su versión se apoya en sus huellas sha256.

La preparación extrae del archivo original, limpia, recorta al alcance, asigna cada siniestro a su municipio y construye el panel con ceros explícitos. Cinco decisiones determinan el resultado y se detallan en el Anexo E (Cuadro E2): eliminar los duplicados exactos; fijar el formato de fecha y verificarlo contra el día de la semana declarado; descartar las columnas de gravedad, que agregadas por día suman exactamente el objetivo y serían una fuga perfecta; resumir el calendario en el panel como una categórica de tres niveles (entre semana, fin de semana y feriado); y no incluir en el panel variables de nivel de zona, que solo pueden estimarse con el entrenamiento de cada partición. El procedimiento incorpora 16 verificaciones automáticas que detienen la ejecución ante una falla de integridad. El Anexo E (Cuadro E1) contrasta cada acción de preparación con las pautas de la asignatura, incluidas las que no corresponden, como la imputación o el balanceo.

El diagnóstico evalúa la completitud, la cobertura, la adecuación al problema y las limitaciones del panel de los ocho municipios, solo con el bloque de desarrollo (01/07/2021–05/02/2025, 1.316 días): los datos se leen descartando el bloque final en el mismo paso, de modo que ningún cálculo lo consulta. Incluye la estructura temporal de cada municipio, el aporte fuera de muestra de cada bloque de variables con dos pliegues cronológicos y una comparación de modelos mínimos que evalúa si un único modelo alcanza para los ocho municipios. La versión del diagnóstico del Entregable 2 se había calculado sobre el período completo; se recalculó solo con el desarrollo el 05/10/2026, y sus resultados se presentan en la Sección 4.1.

3.5 Procedimiento de análisis de la información y los datos

3.5.1 Variables

Las variables se construyen al modelar, con una única implementación compartida por la experimentación y el prototipo, y solo con información anterior al primer día a predecir (el origen):

- Calendario de ocho niveles: los siete días de la semana y el feriado, que tiene prioridad sobre el día. Se deriva de la fecha y de los feriados oficiales y bancarios de Uruguay, conocidos de antemano.
- Nivel del municipio: una indicadora por municipio, cuyo coeficiente se estima solo con la ventana de entrenamiento.

- Nivel reciente: la media de cada municipio en los últimos 28, 56 o 91 días antes del origen, fija para los siete días del horizonte.
- Rezagos de 7, 14, 21 y 28 días: siempre observados, porque con un horizonte de siete días ninguno cae después del origen; ningún modelo realimenta sus predicciones.
- Término propio del Municipio A: la interacción de A con el día de la semana, motivada por su ciclo semanal distinto (Sección 4.1.2).

Con ellas se definieron cuatro conjuntos anidados, cada uno motivado por el diagnóstico: (0) sin exógenas, con municipio, nivel reciente y rezagos; (a) municipio y calendario; (b) el (a) más el término de A; y (c) el (b) más el nivel reciente. Un quinto conjunto, el (a) con lluvia, se retiró el 14/10/2026, antes de ejecutar ningún candidato, por dos razones: la lluvia del día a predecir no se conoce con siete días de anticipación —solo existiría un pronóstico, con su propio error— y el diagnóstico no le encontró aporte fuera de muestra (Sección 4.1.2). La serie meteorológica permanece en el conjunto preparado, pero ningún modelo la usa. Quince pruebas automáticas verifican que, al reemplazar el objetivo posterior al origen por un valor imposible, ninguna variable cambia; con la protección deshabilitada a propósito, cinco de ellas fallan, lo que muestra que detectan la fuga.

3.5.2 Diseño de la evaluación

La serie se divide cronológicamente en un bloque de desarrollo (80 %), formado por el entrenamiento inicial y la validación, y un bloque final (20 %), según la Tabla 1.

Tabla 1 – Particiones cronológicas del conjunto

Bloque	Desde	Hasta	Días	%	Uso
Entrenamiento inicial	01/07/2021	13/03/2024	987	60,0	Primer entrenamiento de la validación
Validación	14/03/2024	05/02/2025	329	20,0	47 cortes semanales: experimentación y selección
Bloque final	06/02/2025	31/12/2025	329	20,0	Consultado en el Entregable 2; evaluación final del Entregable 3, una sola vez, en 47 cortes semanales

Fuente: elaboración propia.

Dentro del desarrollo se aplica el origen móvil (Sección 2.2.5): el primer origen es el 14/03/2024, cada modelo predice los siete días siguientes, el origen avanza siete días y el modelo se reentrena con lo observado antes de él, hasta completar 47 cortes; cada corte evalúa 56 pares (7 días por 8 municipios), 2.632 en total. Se comparan la ventana expansiva y las deslizantes de 364, 546 y 728 días. La evaluación final repite

exactamente el procedimiento sobre el bloque final, con orígenes del 06/02/2025 al 25/12/2025: en cada corte, cada modelo se reentrena con todo lo observado antes del origen —el desarrollo más las semanas ya transcurridas del bloque— y su ventana, como ocurriría en operación al reentrenar cada semana.

Las métricas y su papel se resumen en el Cuadro 4. El error estándar de la desvianza se calcula como el desvío de las 47 desvianzas por corte dividido por $\sqrt{47}$. La calibración se examina además por deciles de la predicción y mediante la tendencia del residuo medio por corte, estimada por mínimos cuadrados ordinarios con errores estándar robustos a la autocorrelación del tipo HAC (Newey y West, 1987), con cuatro rezagos, para detectar una deriva que el modelo no acompañe. Las diferencias de desvianza corte a corte entre modelos se informan como descripción y no como pruebas de significación: los cortes son semanas consecutivas de una misma serie, no muestras independientes, y no se fijó una prueba antes de ejecutar.

Cuadro 4 – Métricas de evaluación y su papel en la comparación

Métrica	Papel	Lectura
Desvianza de Poisson media	Principal: comparar y seleccionar	Menor es mejor. Las predicciones nulas se reemplazan por 10^{-6} para poder calcularla
Error estándar entre cortes	Define el empate en la regla de selección	Cuánto varía la desvianza de una semana a otra
MAE y RMSE	Secundarias	Siniestros de diferencia por día; el RMSE pondera más los errores grandes
Total predicho / observado	Calibración del volumen	1 indica volumen correcto; menos de 1, subestimación
Calibración por deciles	Calibración por nivel de intensidad	Observado sobre predicho en cada décimo de las predicciones
Cobertura de los intervalos	Incertidumbre	Proporción de observaciones dentro del intervalo, frente a la esperada por el modelo
Peor municipio y desvío entre cortes	Estabilidad: desempate	Desvianza del municipio peor predicho y variabilidad semanal

Fuente: elaboración propia.

3.5.3 Medidas contra la fuga de información

El Cuadro 5 resume las salvaguardas aplicadas para que ningún modelo reciba información que no tendría en operación (Sección 2.2.5).

Cuadro 5 – Medidas contra la fuga de información

Riesgo	Medida adoptada
Entrenar con datos posteriores a los evaluados	Partición estrictamente cronológica; el bloque final es el tramo final de la serie

Riesgo	Medida adoptada
Estimar parámetros con información futura	En cada corte, cada modelo se reentrena solo con lo observado antes del origen. El modelo recibe una vista del panel con el objetivo de los días posteriores al origen reemplazado por valores faltantes, comprobada con un modelo de prueba
Realimentar predicciones como si fueran observaciones	Ningún modelo es recursivo; los rezagos son de siete días o más y su construcción falla si alguno cae en el origen o después. La solución no usa rezagos
Dar a un modelo variables que no debe usar	Una única implementación de las variables, compartida con el prototipo; las pruebas de la Sección 3.5.1 verifican que el objetivo futuro no las altera
Leer el bloque final durante el desarrollo	El cuaderno de experimentación nunca carga el bloque final: el panel se lee por tramos y cada tramo se recorta al 05/02/2025 antes de acumularse, con una verificación que detiene la ejecución si sobrevive alguna fila posterior. Solo el cuaderno de evaluación final y el script del servidor lo leen
Elegir la configuración con información del bloque final	La configuración seleccionada se registró en el repositorio el 19/10/2026 y no cambió después; el cuaderno de evaluación se registró el 20/10/2026 antes de ejecutarse, y al iniciar verifica automáticamente esas condiciones
Consulta del bloque final durante el Entregable 2	Riesgo declarado, no eliminado: el bloque se consultó al evaluar la línea base y en la primera versión del diagnóstico, por lo que no es una prueba independiente. Desde el 05/10/2026 ningún diagnóstico lo consulta; lo decidido antes no se revierte

Fuente: elaboración propia.

Uso del bloque final. El tramo 06/02/2025–31/12/2025 se definió al inicio como bloque reservado, pero durante el Entregable 2 se evaluaron sobre él la línea base y los árboles de arranque, y esos resultados influyeron en decisiones posteriores: retirar el árbol, revisar la ventana de L0 y tratar la deriva del nivel (Sección 4.3.1). Por lo tanto, el bloque no cumple la condición de prueba reservada que exige la guía de la asignatura, y sus resultados no constituyen una prueba independiente. Se mantuvo como bloque de evaluación final con ese uso declarado y, en el Entregable 3, se evaluó una única vez, el 20/10/2026, con la configuración ya registrada y sin tomar después ninguna decisión de modelado; esa ejecución única no elimina la dependencia histórica. El tratamiento de esta falta de independencia queda sujeto al criterio del docente responsable, que este informe no presupone. Los datos del primer semestre de 2026 que publicó la UNASEV no se descargaron ni se usaron.

3.5.4 Referencias, candidatos y regla de selección

Las referencias son la media constante, L0 y L1 (Sección 2.2.7). La ventana de L0 se revisó en validación con dos, cuatro y ocho semanas; la de ocho, que pasa a la evaluación final, se eligió mirando esos mismos 47 cortes, de modo que su resultado en validación es optimista. Los candidatos forman una lista cerrada, escrita el 16/10/2026 en

la primera sección del cuaderno de experimentación, antes de ejecutar ningún candidato: GLM de Poisson, GLM binomial negativa (NB2) y XGBoost con pérdida de Poisson (Secciones 2.2.8 y 2.2.9). La lista responde a la condición con que el Comité Académico aprobó la propuesta —acotar la cantidad de modelos y evaluar el costo de SARIMA (Sección 2.2.10)—. Las precisiones posteriores se agregaron debajo, fechadas, sin modificar el texto original. El Cuadro 6 resume los modelos y su papel.

Cuadro 6 – Modelos evaluados y su papel

Modelo	Información que usa	Papel	Evaluado en
Media constante	Ninguna: media del entrenamiento	Piso común	Validación y bloque final
L0	Promedio del mismo día de la semana en las 2, 4 u 8 semanas previas	Referencia sin exógenas (8 semanas)	Validación (las tres) y bloque final (8 semanas)
L1	Nivel del municipio × calendario de ocho niveles	Referencia con calendario	Validación y bloque final
GLM de Poisson	Conjuntos (0), (a), (b) y (c)	Candidato; solución y sensibilidad	Validación y bloque final
GLM binomial negativa (NB2)	Conjunto (a)	Candidato; fuente de α para los intervalos	Validación; α en el bloque final
XGBoost con pérdida de Poisson	Conjuntos (0) a (c); 12 combinaciones de hiperparámetros	Candidato; contraste en la evaluación final	Validación y bloque final
Retirados antes de ejecutar	Árbol de decisión; conjunto con lluvia	Secciones 1.4 y 3.5.1	—

Fuente: elaboración propia.[1]

La experimentación siguió tres pasos con la ventana expansiva salvo en el último. El paso A comparó los conjuntos de variables con el GLM de Poisson y con XGBoost de configuración fija (profundidad 3, 300 árboles, tasa de aprendizaje 0,05), eligiendo la longitud del nivel reciente por desvianza dentro de cada familia. El paso B recorrió, sobre el conjunto elegido, una grilla de XGBoost —profundidad {2, 3, 4}, árboles {100, 300} y tasa de aprendizaje {0,05; 0,1}— y estimó la NB2, con α por máxima verosimilitud en cada corte. El paso C comparó las cuatro ventanas para el GLM y el XGBoost elegidos. Los demás parámetros de XGBoost quedaron en sus valores por defecto, con semilla fija. En total se evaluaron 38 configuraciones, todas en el registro de experimentos.

La regla de selección, fijada antes de ejecutar, tiene cuatro pasos: (1) menor desvianza media en validación; (2) se consideran empatadas las alternativas a menos de un error estándar de la mejor; (3) entre las empatadas, la más simple y explicable —GLM antes

[1]En las tablas y cuadros de este informe, el guion (—) indica que el valor no corresponde, no que falte. Aquí, los modelos retirados no se evaluaron.

que XGBoost, Poisson antes que NB2, menos variables antes que más y, en XGBoost, menor profundidad y menos árboles—; y (4) si persiste el empate, la más estable —primero el peor municipio, con una tolerancia de un error estándar, después el menor desvío entre cortes— y por último la mejor calibrada. Cómo aplicar los pasos 3 y 4 dentro de una familia y entre ventanas se precisó el 19/10/2026, con los resultados del paso A ya vistos y antes de ejecutar los pasos B y C; la ventana no cuenta como complejidad. Como la búsqueda de hiperparámetros y la selección usan los mismos 47 cortes, el desempeño del ganador en validación es optimista. La configuración finalmente adoptada se apartó del resultado de esta regla; la secuencia completa de la decisión se presenta en la Sección 4.3.3.

3.5.5 Interpretación, errores, intervalos y robustez

La interpretación del modelo seleccionado usa sus coeficientes, ajustados con los últimos 364 días del desarrollo (2.912 filas), expresados como razones de tasas con su intervalo de confianza del 95 %; la importancia por permutación de dos grupos de variables —municipio y calendario—, permutados en bloque entre las 56 filas de cada corte, con cinco repeticiones; y la dependencia parcial, comparada con la de XGBoost. Los errores se analizan por municipio, por tipo de día y en las cinco semanas de mayor desvianza, junto con la calibración por deciles y la tendencia del residuo (Sección 3.5.2). Los intervalos de predicción del 80 % y del 95 % toman la media del modelo seleccionado y el α de una NB2 ajustada en el mismo corte y la misma ventana; si la NB2 no converge, α se estima por momentos. La robustez se examina excluyendo un municipio por vez: el modelo se ajusta con los otros siete, el calendario del excluido sale de ellos y su nivel, de su propia historia previa al origen, de modo que la prueba mide la dependencia del modelo de los datos de cada municipio y no la generalización a zonas sin datos. Todo se calculó primero en validación y se repitió en el bloque final, sin efecto sobre la selección.

3.5.6 Prototipo, pruebas y reproducción en el servidor

El tablero del PID se copió sin modificaciones desde su repositorio de origen (Anexo F) en un registro separado. Sobre él se agregó una pestaña nueva con tres cambios mínimos en el archivo principal: la entrada en la barra de navegación, su ícono y la rama que la invoca. La pestaña predice a través del módulo compartido y del modelo exportado, sin bases de datos y sin reentrenar; el modelo se guarda en formato JSON, sin serialización de objetos de Python, y se carga y predice sin las bibliotecas de entrenamiento. Las pruebas del pipeline se escribieron con pytest y con el entorno de pruebas de Streamlit (Sección 4.4.6, Tabla 10).

Para el servidor institucional se escribió un script de entrenamiento independiente, porque el contenedor no dispone de statsmodels ni de la biblioteca de feriados: ajusta el GLM con IRLS implementado en NumPy, estima α por momentos y usa el calendario de la semana como constante verificada. El criterio de aceptación, fijado antes de correrlo, es una diferencia relativa máxima de 10^{-6} en los coeficientes, en las 56 predicciones de la semana y en α respecto del modelo exportado localmente.

3.5.7 Aspectos éticos

El proyecto no trata datos personales en los términos de la Ley N.º 18.331: los registros carecen de identificación de las personas y se agregan al par (día, municipio). Las tres fuentes se usan dentro de sus condiciones de acceso. El repositorio versiona los conteos observados del bloque final, agregados por municipio y día, porque el modo histórico del prototipo los muestra; el equipo verificó que hacerlo no viola las condiciones de uso de los datos de la UNASEV. El riesgo ético principal está en la interpretación: una estimación por municipio podría leerse como un ordenamiento de peligrosidad territorial, lectura sin sustento por la falta de datos de exposición y por un subregistro posiblemente desigual entre zonas; por eso el informe y el prototipo restringen su vocabulario a la «cantidad esperada de siniestros registrados». El uso de herramientas de inteligencia artificial generativa se declara en la Declaración de uso de herramientas de inteligencia artificial generativa de este informe y se documenta de forma incremental en el registro de uso de IA del repositorio (documentacion/registro_uso_IA.md); no constituye una fuente académica citada.

4. Resultados

Este capítulo presenta los datos y condiciones con que se trabajó (4.1), la solución implementada (4.2), su evaluación y validación (4.3) y el análisis de sus errores y de su desempeño técnico (4.4). Las cifras proceden de las tablas que los cuadernos generan en cada ejecución; la interpretación se reserva para el capítulo 5.

4.1 Datos y condiciones finales de trabajo

Las estadísticas de los apartados 4.1.1 y 4.1.2 son del desarrollo (1.316 días) y no consultan el bloque final.

4.1.1 Calidad y cobertura

Calidad. El archivo casi no tiene valores nulos (uno, en la columna de calle), pero sí faltantes codificados como texto: en el recorte de Montevideo afectan al 4,47 % de las localidades y al 2,32 % de las calles, frente al 18,14 % y al 12,50 % del archivo nacional (Anexo B, Tabla B1); como ninguna de esas columnas se usa —el municipio se deriva de las coordenadas—, no se imputan. Hay 347 filas idénticas en todas sus columnas, una de ellas repetida diez veces; sin identificador de siniestro no puede distinguirse con certeza un duplicado de carga de dos hechos idénticos, y se eliminan como decisión conservadora. El día de la semana declarado permite verificar el formato de fecha: la lectura con el mes primero explica el 100 % de los días, mientras que la del día primero deja 133.356 fechas no interpretables. Entre el 83,17 % y el 95,31 % de los hechos de cada municipio comparten coordenadas con otros, lo que indica una geocodificación ajustada a esquina o tramo de calle, suficiente para la asignación territorial; 11 hechos (0,03 %) caen fuera de todo polígono, en bordes costeros o departamentales, y se descartan. Todos los días del desarrollo registran al menos un siniestro en el departamento (mínimo 4, mediana 22, máximo 43); el criterio de Tukey marca 7 días atípicos, todos por encima, y ninguno se eliminó ni corrigió (Tabla B2). La serie meteorológica cubre el período sin faltantes.

Cobertura temporal. El desarrollo acumula 3.936 siniestros en el segundo semestre de 2021, 7.665 en 2022, 7.873 en 2023 y 8.398 en 2024, con variaciones interanuales de +2,7 % y +6,4 % desde 2023 (Anexo B, Tabla B3 e Ilustración B1). El primer semestre de 2021, excluido del período (Sección 3.2), promedia 16,34 siniestros diarios frente a 20,78 en los mismos meses de 2022 a 2024 (-21,4 %); su índice estacional mensual se aparta del patrón de referencia entre -7,3 % y -15,5 %, lo que descarta que responda a un nivel

anual más bajo; y el tramo conservado encadena con los años siguientes con variaciones de entre +2,8 % y +5,7 %. La exclusión cuesta 2.957 registros y 181 días.

Cobertura territorial. Los ocho municipios están representados y el reparto es parejo (Anexo C, Tabla C1 e Ilustración C1): el C concentra el 15,80 % de los siniestros y el CH, el 9,22 %, con una razón de 1,71 entre ambos, y en todos más del 83 % de los días registra al menos un hecho. En el desarrollo, el panel tiene 10.528 filas, un 9,34 % de ceros y una media de 2,7104 siniestros por par día-municipio; con la grilla de un kilómetro y con los barrios ensayados antes, los ceros eran el 95,08 % y el 71,96 % (Tabla C2). La partición por municipios convierte el problema en una regresión de conteo ordinaria.

4.1.2 Adecuación al problema

La variable objetivo tiene una media de 2,7104 y una varianza de 3,4415: un índice de dispersión de 1,270, con valores entre 1,069 (F) y 1,291 (C) por municipio. El exceso de ceros sobre un proceso de Poisson de igual media va de 0,30 a 3,11 puntos porcentuales, sin evidencia para modelos con inflación de ceros. Es un conteo con sobredispersión leve, para el que la Poisson es la familia de referencia y la binomial negativa, su primera extensión (Sección 2.2.3).

La señal temporal se contrasta con la banda nula (±0,0540 con 1.316 días). En el rezago de siete días la señal es enteramente de calendario: descontados el día de la semana y el feriado, ningún municipio queda sobre la banda. En el rezago de un día, solo el Municipio C la supera, por poco, y en ningún municipio esa persistencia explica más del 0,3 % de la varianza (Anexo D, Tabla D1 e Ilustración D1). Las series no requieren diferenciación ni transformación: la prueba ADF rechaza la raíz unitaria en los ocho municipios, diferenciar induce una autocorrelación negativa fuerte (entre -0,46 y -0,55) y el parámetro de Box-Cox no apunta al logaritmo. El objetivo se modela como conteo, y la deriva lenta del nivel se trata en el modelado.

El aporte de cada bloque de información se midió fuera de muestra, con dos pliegues cronológicos dentro del desarrollo (Tabla 2). La tasa histórica del municipio mejora más que el calendario; su combinación multiplicativa suma ambos aportes y fundamenta la referencia L1; la lluvia, como indicador binario, no mejora la combinación (-0,36 % y -0,01 %); y las celdas saturadas rinden peor que no usar información. La media por municipio sube un 5,03 % y un 8,83 % entre el tramo de ajuste y el de validación, señal de la deriva creciente del nivel.

Tabla 2 – Aporte de cada bloque de información fuera de muestra, medido en desvianza de Poisson

Información disponible (estimada solo con el ajuste)	Pliegue A	Mejora	Pliegue B	Mejora
Constante global	1,3897	—	1,4014	—
Solo calendario	1,3291	+4,36 %	1,3441	+4,09 %
Solo tasa histórica del municipio	1,2885	+7,28 %	1,2958	+7,54 %
Tasa del municipio por calendario	1,2278	+11,65 %	1,2385	+11,63 %
Tasa del municipio, calendario y lluvia	1,2323	+11,33 %	1,2386	+11,61 %
Celdas de municipio por calendario	1,2305	+11,45 %	1,2344	+11,91 %
Celdas saturadas de municipio, calendario y mes	1,4958	-7,64 %	1,4477	-3,31 %

Fuente: elaboración propia en base a datos de la UNASEV y de Open-Meteo (s. f.). Pliegues de 658 y 987 días de ajuste, evaluados sobre los 329 días siguientes; mejora: reducción porcentual de la desvianza media de los ocho municipios frente a la constante global.[2]

¿Un modelo o varios? Pruebas F de cuasi-verosimilitud y una comparación predictiva de seis modelos mínimos, con una regla fijada antes de ejecutar, muestran que la heterogeneidad dominante entre municipios es el nivel (F = 134,47; conocerlo mejora la desvianza un 7,62 % y un 7,86 %). El perfil de calendario difiere estadísticamente, pero especializarlo no mejora en promedio (-0,22 % y +0,32 %); solo el Municipio A necesita un calendario propio según la regla (+4,06 % y +4,24 %): es el único con un ciclo semanal de forma distinta, con el sábado alto y una correlación de 0,609 con el perfil agregado, frente a 0,953 o más en el resto (Anexo D, Tabla D2). De este resultado surge la hipótesis de la Sección 1.2.

4.1.3 Conjunto final y condiciones de trabajo

La preparación produce un panel de 13.160 filas y doce columnas con los 36.612 siniestros del recorte y ceros explícitos, junto con la capa georreferenciada de hechos, el catálogo de municipios y un diccionario de datos de 50 entradas. Las dieciséis verificaciones automáticas resultaron favorables —entre otras, que el panel conserva todos los siniestros y es el producto completo de días por municipios, sin claves repetidas ni faltantes— y la reejecución integral del 20/09/2026 reprodujo los archivos del conjunto idénticos byte a byte. En el Entregable 3, la lectura del desarrollo devolvió exactamente 10.528 filas (1.316 días por ocho municipios) y la evaluación final verificó que el panel completo tiene la misma huella sha256 que el usado en el diagnóstico. En validación, con ventana expansiva, los modelos se entrenan con entre 7.168 y 9.744 filas por corte; con la ventana deslizante de 364 días, con 2.912. En el desarrollo, el calendario reparte los

[2]En la fila de la constante global, el guion (—) indica que no corresponde calcular la mejora: es el punto de comparación.

días en 891 entre semana, 364 de fin de semana y 61 feriados, con medias departamentales de 23,65, 18,01 y 14,87 siniestros diarios.

4.2 Solución implementada

4.2.1 Configuración de la solución

La solución es un procedimiento completo, no solo un modelo: un GLM de Poisson con el conjunto de variables (a) —ocho indicadoras de municipio, sin constante, y siete de calendario, con el lunes como referencia—, entrenado con una ventana deslizante de 364 días y reentrenado cada siete días, que predice la semana siguiente para los ocho municipios. Los intervalos de predicción del 80 % y del 95 % combinan su media con el parámetro de dispersión de una binomial negativa ajustada en la misma ventana (Sección 3.5.5). Cómo se llegó a esta configuración se presenta en la Sección 4.3.3. En la evaluación final la acompañan dos modelos con papel fijado de antemano: la misma especificación con ventana expansiva, como análisis de sensibilidad, y XGBoost con el mismo conjunto y la misma ventana, como contraste, sin opción a reemplazarla.

4.2.2 Interpretación del modelo

La Tabla 3 y la Ilustración 2 presentan las razones de tasas del GLM ajustado con los últimos 364 días del desarrollo (dispersión de Pearson 1,1006). El fin de semana y los feriados tienen tasas menores que el lunes, con intervalos que excluyen el 1: el sábado, un 15 % menos; el domingo, un 30 %; y el feriado, un 35 % menos, siempre como asociación en ese año y respecto del lunes. De martes a viernes, los intervalos incluyen el 1: el modelo no distingue esos días del lunes. Los municipios se separan en dos grupos: C, A, D y B, con entre 3,47 y 3,94 siniestros esperados un lunes, y F, G, E y CH, con entre 2,14 y 3,04.

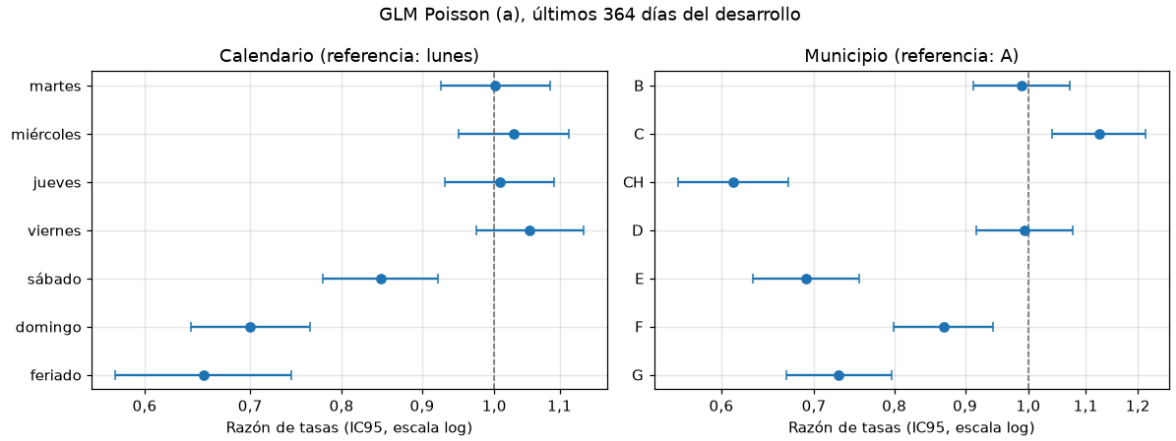
Tabla 3 – Razones de tasas estimadas por el GLM de Poisson (últimos 364 días del desarrollo)

Calendario (respecto del lunes)	Razón	IC 95 %	Municipio (respecto de A)	Razón	IC 95 %	Esperados un lunes
Martes	1,0015	0,9246–1,0848	B	0,9891	0,9125–1,0721	3,4673
Miércoles	1,0282	0,9486–1,1145	C	1,1244	1,0399–1,2157	3,9415
Jueves	1,0080	0,9308–1,0917	CH	0,6118	0,5579–0,6709	2,1446
Viernes	1,0529	0,9734–1,1390	D	0,9933	0,9165–1,0765	3,4820
Sábado	0,8467	0,7786–0,9207	E	0,6908	0,6320–0,7550	2,4215
Domingo	0,7001	0,6415–0,7640	F	0,8681	0,7986–0,9435	3,0431
Feriado	0,6537	0,5748–0,7434	G	0,7294	0,6683–0,7961	2,5570

Calendario (respecto del lunes)	Razón	IC 95 %	Municipio (respecto de A)	Razón	IC 95 %	Esperados un lunes
Lunes (referencia)	1	—	A (referencia)	1	—	3,5056

Fuente: elaboración propia en base a datos de la UNASEV. Intervalos de Wald del modelo de Poisson; los de la binomial negativa son apenas más anchos.[3]

Ilustración 2 – Razones de tasas del GLM con su intervalo de confianza del 95 %



Fuente: elaboración propia en base a datos de la UNASEV.

La importancia por permutación confirma ese orden: permutar el municipio aumenta la desvianza del modelo en 0,2270 (+18,6 %) y permutar el calendario, en 0,1277 (+10,5 %). XGBoost depende de los mismos grupos en el mismo orden (+0,1717 y +0,0955) y su dependencia parcial reproduce el ordenamiento del GLM entre municipios y días, con un rango más angosto entre municipios. Estas medidas describen de qué depende el modelo; no indican que el municipio o el día causen los siniestros, ni que un municipio sea más riesgoso que otro (Sección 1.1).

4.2.3 Modelo exportado y prototipo

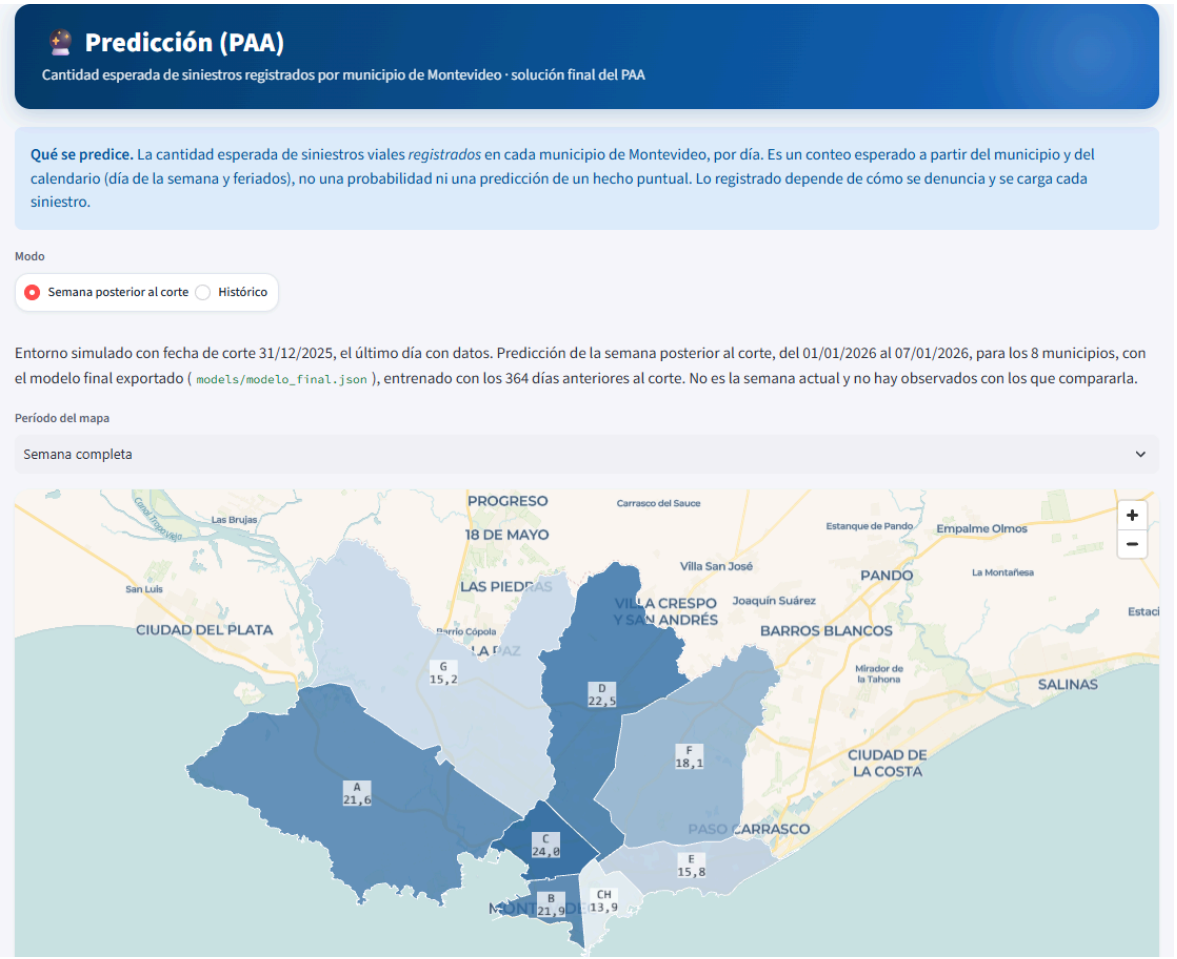
El modelo exportado se entrenó con la ventana del 02/01/2025 al 31/12/2025 (364 días, 2.912 filas; el GLM convergió en cuatro iteraciones) y predice la semana del 1.º al 7 de enero de 2026. Se guarda en un archivo JSON de 1.335 bytes con sus coeficientes, α y los datos del ajuste, acompañado de un archivo de metadatos con la configuración, la fecha de corte, las versiones y las huellas sha256 del panel y del modelo. Como la binomial negativa no convergió en esa ventana, α se estimó por momentos (0,0094).

El prototipo es la pestaña «Predicción (PAA)», agregada al tablero heredado del PID (Ilustraciones 3 y 4), y funciona en un entorno simulado: los datos disponibles llegan

[3]Las categorías de referencia (el lunes y el Municipio A) tienen una razón igual a 1 por definición y carecen de intervalo: el guion (—) indica que el valor no corresponde, no que falte.

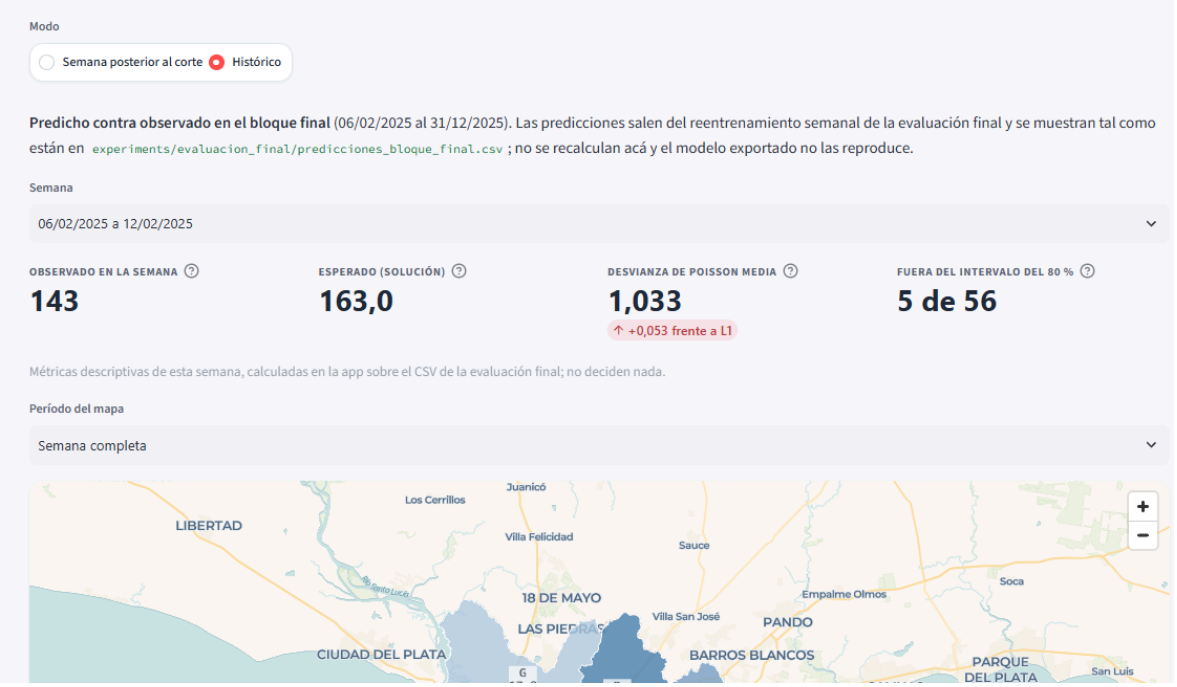
hasta el 31/12/2025, que es la fecha de corte. Tiene dos modos. «Semana posterior al corte» muestra la cantidad esperada de siniestros registrados por municipio y día para la semana siguiente a esa fecha, del 01/01/2026 al 07/01/2026, con intervalos del 80 % y del 95 %, calculada por el modelo exportado; no corresponde a la semana en curso. «Histórico» permite elegir una de las 47 semanas del bloque final y comparar lo predicho con lo observado, tal como quedó registrado en la evaluación final, sin recalcular; esas predicciones provienen del reentrenamiento semanal de la Sección 4.3.4, y no del modelo exportado. Ambos modos presentan un mapa de los ocho municipios coloreado por la cantidad esperada, una tabla y gráficos por municipio y día, y un texto breve que aclara qué se predice y qué no. La pestaña carga el modelo exportado sin reentrenar ni usar bases de datos; las páginas heredadas, que consultan las bases del PID, muestran su propio error de conexión cuando estas no están disponibles. El equipo verificó su funcionamiento en entorno local el 21/10/2026; la instrucción de ejecución y la ubicación de las evidencias en el repositorio se detallan en el Anexo F (F.3). Su integración en el tablero del servidor institucional está pendiente.

Ilustración 3 – Pestaña «Predicción (PAA)», modo «Semana posterior al corte»



Fuente: elaboración propia.

Ilustración 4 – Pestaña «Predicción (PAA)», modo «Histórico»



Fuente: elaboración propia.

4.3 Evaluación y validación

4.3.1 Antecedente: la línea base del Entregable 2

En el Entregable 2, el protocolo se puso a punto sobre la serie del Municipio C, con un calendario de tres niveles (Anexo F, Tablas F1 y F2). En validación, la referencia con calendario redujo la desvianza de la media constante un 9,2 % y un árbol de decisión de profundidad acotada, un 7,7 %. Sobre el bloque final, consultado entonces de forma preliminar, la referencia con calendario la redujo un 14,1 %, el promedio de las últimas cuatro semanas quedó un 5,2 % por detrás de la media constante, y ninguno de los dos árboles superó a las referencias: el de profundidad acotada subestimó el volumen un 28 % porque no extrapola el tiempo transcurrido. Esas cifras corresponden a una única serie y no son comparables con las del panel; lo que pasó al Entregable 3 fueron tres decisiones: retirar el árbol único, revisar la ventana de L0 y tratar la deriva del nivel.

4.3.2 Referencias y experimentación en validación

Referencias. L1 tiene la menor desviana de las referencias y es la única que no queda a más de un error estándar de sí misma (Tabla 4); le gana a la media constante en 44 de los 47 cortes y es la mejor en siete de los ocho municipios. Al alargar la ventana de L0, su desvianza baja: la de cuatro semanas, usada en el Entregable 2, queda por detrás de la

media constante, y la de dos semanas produce 27 predicciones nulas. La de ocho semanas es la mejor de las tres, aunque su ventaja sobre la media constante (0,0341) es menor que un error estándar (0,0447). L1 y la media constante predicen el 93,05 % del total observado: subestiman, porque el nivel crece.

Tabla 4 – Referencias en validación (47 cortes, ocho municipios, ventana expansiva)

Referencia	Desvianza	EE	MAE	RMSE	Pred. / obs.	Días con predicción 0
L1 (nivel × calendario de 8 niveles)	1,2319	0,0358	1,4006	1,7960	0,9305	0
L0 (8 semanas)	1,3626	0,0414	1,4957	1,8958	1,0067	0
Media constante	1,3967	0,0447	1,5209	1,9212	0,9305	0
L0 (4 semanas)	1,5210	0,0443	1,5723	1,9988	1,0054	0
L0 (2 semanas)	2,4384	0,1686	1,7179	2,1741	1,0044	27

Fuente: elaboración propia en base a datos de la UNASEV. EE: error estándar de la desvianza entre los 47 cortes; 2.632 predicciones por modelo.

Paso A: conjuntos de variables (Tabla 5). En las dos familias, los conjuntos (a), (b) y (c) quedan a menos de un error estándar del mejor de su familia, y la regla elige el más simple, (a). El conjunto sin exógenas (0), con historia reciente y rezagos semanales pero sin calendario, es peor que L1 en ambas familias. El término propio de A reduce la desvianza de ese municipio de 1,2950 a 1,2388 (-4,34 %), pero no mejora el global en más de un error estándar; el nivel reciente del conjunto (c) corrige la subestimación solo en parte (de 0,9341 a 0,9523 en el GLM). Ninguna configuración se distingue de L1 por más de un error estándar, aunque el GLM (c) le gana en 38 de los 47 cortes. Los 376 ajustes del GLM convergieron y su dispersión de Pearson osciló entre 1,1035 y 1,1171.

Tabla 5 – Paso A: conjuntos de variables en validación (ventana expansiva)

Familia y conjunto	Desvianza	EE	Pred. / obs.	Diferencia con L1	Cortes que gana a L1	Empata con el mejor de su familia
GLM (c), nivel de 28 días	1,2150	0,0363	0,9523	-0,0169	38	Sí (mejor)
GLM (b)	1,2207	0,0362	0,9341	-0,0111	35	Sí
GLM (a) – elegido	1,2302	0,0359	0,9341	-0,0017	36	Sí
GLM (0), nivel de 91 días	1,2757	0,0389	0,9529	+0,0438	15	No
XGBoost (b)	1,2200	0,0362	0,9338	-0,0119	32	Sí (mejor)
XGBoost (a) – elegido	1,2217	0,0361	0,9338	-0,0102	31	Sí
XGBoost (c), nivel de 28 días	1,2219	0,0370	0,9586	-0,0100	29	Sí

Familia y conjunto	Desvianza	EE	Pred. / obs.	Diferencia con L1	Cortes que gana a L1	Empata con el mejor de su familia
XGBoost (0), nivel de 28 días	1,2864	0,0395	0,9590	+0,0546	14	No
L1 (referencia)	1,2319	0,0358	0,9305	0	—	—

Fuente: elaboración propia en base a datos de la UNASEV. Para (0) y (c) se muestra la longitud del nivel reciente elegida en cada familia; las demás constan en el registro de experimentos.[4]

Paso B: hiperparámetros y binomial negativa. La NB2 y el GLM de Poisson con el conjunto (a) dan prácticamente la misma predicción (desvianza 1,2301 contra 1,2302; diferencia máxima de 0,0071 siniestros), con α entre 0,0349 y 0,0400 y convergencia en los 47 cortes; la regla elige el de Poisson por ser más simple. En la grilla de XGBoost, 11 de las 12 combinaciones empatan con la mejor (1,2197) y la regla elige la más simple —profundidad 2, 100 árboles y tasa de 0,1—, cuya desvianza (1,2375) es la décima de las doce y queda por encima de L1 (Anexo G, Tabla G1). Es un resultado incómodo, consecuencia directa de la regla, y se reporta como tal.

Paso C: ventanas de entrenamiento (Tabla 6). Las ocho configuraciones empatan a menos de un error estándar (umbral 1,2569). En las dos familias, todas las ventanas deslizantes tienen menor desvianza media que la expansiva, y el total predicho se acerca a 1 a medida que la ventana se acorta: en el GLM pasa de 0,9341 con la expansiva a 0,9717 con la de 364 días, y en el Municipio A, de 0,8695 a 0,9330.

Tabla 6 – Paso C: ventanas de entrenamiento en validación

Configuración	Desvianza	EE	Pred. / obs.	Pred. / obs. en A	Desvío entre cortes	Cortes que gana a L1
GLM (a), deslizante 364 días	1,2205	0,0364	0,9717	0,9330	0,2495	32
GLM (a), deslizante 546 días	1,2242	0,0361	0,9588	0,9151	0,2476	31
GLM (a), deslizante 728 días	1,2263	0,0360	0,9495	0,8939	0,2468	34
GLM (a), expansiva	1,2302	0,0359	0,9341	0,8695	0,2464	36
XGBoost (a), deslizante 364 días	1,2280	0,0377	0,9712	0,9030	0,2582	26
XGBoost (a), deslizante 546 días	1,2322	0,0378	0,9582	0,8855	0,2591	25
XGBoost (a), deslizante 728 días	1,2320	0,0377	0,9489	0,8647	0,2582	26

[4]En la fila de L1, el guion (—) indica que no corresponde: L1 es la referencia contra la que se calculan la diferencia y los cortes ganados, y no compite en la regla de selección.

Configuración	Desvianza	EE	Pred. / obs.	Pred. / obs. en A	Desvío entre cortes	Cortes que gana a L1
XGBoost (a), expansiva	1,2375	0,0375	0,9336	0,8378	0,2573	20
L1 (referencia)	1,2319	0,0358	0,9305	0,8641	0,2456	—

Fuente: elaboración propia en base a datos de la UNASEV. XGBoost con profundidad 2, 100 árboles y tasa de aprendizaje 0,1.[5]

Los resultados negativos también orientaron decisiones: el conjunto sin calendario, la L0 de dos y cuatro semanas, la XGBoost elegida por la regla —peor que L1 en validación— y la falta de aporte de la binomial negativa a la media.

4.3.3 Selección de la solución

La configuración final no resulta de aplicar la regla de selección: es una desviación del equipo, tomada con evidencia de validación antes de la evaluación final. La secuencia fue la siguiente:

- 16/10/2026: la regla de cuatro pasos se escribe en la primera sección del cuaderno de experimentación, antes de ejecutar ningún candidato (Sección 3.5.4).
- 19/10/2026, después del paso A y antes de los pasos B y C: se agregan, fechadas y debajo del texto original, precisiones sobre cómo aplicar los pasos 3 y 4 dentro de una familia y entre ventanas; la ventana no cuenta como complejidad.
- 19/10/2026, paso C: aplicada la regla, las ocho configuraciones empatan; la simplicidad conserva las cuatro del GLM; las cuatro pasan la tolerancia del peor municipio (el E en todas); y el desvío entre cortes elige la ventana expansiva, con 0,246353 frente a 0,246801 de la de 728 días, una diferencia de 0,00045, unas ochenta veces menor que el error estándar de la desvianza. La regla eligió el GLM (a) con ventana expansiva.
- 19/10/2026, sin leer el bloque final: el equipo adopta el GLM (a) con ventana deslizante de 364 días, con tres criterios que la regla no usa para desempatar: menor desvianza media (1,2205 frente a 1,2302), menor desvianza que la expansiva en 30 de los 47 cortes y mejor calibración del volumen (0,9717 frente a 0,9341; en A, 0,9330 frente a 0,8695). Ninguna de esas diferencias de desvianza supera un error estándar.
- 19/10/2026: la configuración se registra en el repositorio (registro 1560a5b) con dos papeles fijos: la expansiva elegida por la regla, como análisis de sensibilidad, y la

[5]El guion (—) de la fila de L1 indica que no corresponde contar los cortes que L1 se gana a sí misma.

XGBoost de 364 días, como contraste, ambas sin opción a reemplazar a la solución.

- 20/10/2026: se registra el cuaderno de evaluación y se ejecuta una única vez (Sección 4.3.4).

En validación, la diferencia corte a corte entre la solución y L1 es de -0,0114 (error estándar de la diferencia 0,0054), con 32 cortes ganados de 47; es un análisis descriptivo, decidido después de ver los resultados.

4.3.4 Evaluación final en el bloque final

El bloque final no es una prueba independiente: ya se había consultado en el Entregable 2 (Sección 3.5.3), y sus resultados deben leerse con esa salvedad. La evaluación final se ejecutó una sola vez, el 20/10/2026, con el procedimiento de la Sección 3.5.2; antes de leer el bloque final, el cuaderno reprodujo sobre la validación 35 comprobaciones con una diferencia máxima de $5 \cdot 10^{-7}$. La Tabla 7 reúne los resultados.

Tabla 7 – Desempeño en el bloque final (47 cortes, 2.632 predicciones por modelo)

Modelo	Papel	Desvianza	EE	MAE	Pred. / obs.	Desvianza en validación	Diferencia con su referencia (cortes ganados)
GLM (a), 364 días	Solución	1,1063	0,0335	1,3985	0,9606	1,2205	-0,0295 (33)
XGBoost (a), 364 días	Contraste	1,1198	0,0341	1,4148	0,9608	1,2280	-0,0161 (22)
GLM (a), expansiva	Sensibilidad	1,1329	0,0355	1,4019	0,8989	1,2302	-0,0030 (40)
L1	Referencia	1,1359	0,0357	1,4023	0,8952	1,2319	—
L0 (8 semanas)	Referencia	1,2432	0,0387	1,4844	0,9785	1,3626	-0,0720 (34)
Media constante	Referencia	1,3152	0,0401	1,5244	0,8944	1,3967	—

Fuente: elaboración propia en base a datos de la UNASEV. Ningún modelo produjo predicciones nulas. La referencia de los candidatos es L1 y la de L0, la media constante; entre paréntesis, cortes de 47 en que el modelo tiene menor desvianza que su referencia.[6]

La solución tiene la menor desvianza de los seis modelos, y el orden de los cuatro primeros es el mismo que en validación. Frente a L1 reduce la desvianza en 0,0295 (2,6 %) y le gana en 33 de los 47 cortes; frente a la media constante, en 0,2088 (15,9 %) y en 46 de los 47 cortes, aunque L1 ya obtiene 0,1793 de esa reducción. Tiene además

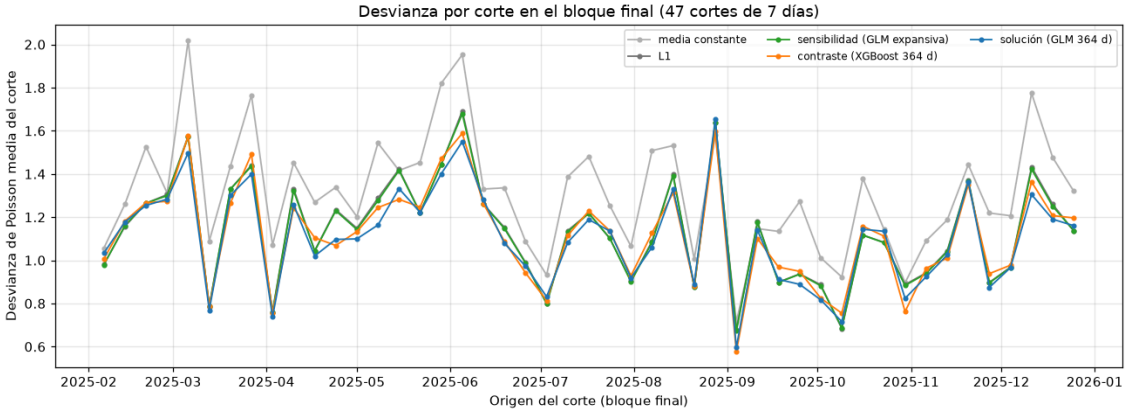
[6]El guion (—) de las filas de L1 y de la media constante indica que no corresponde: son las referencias contra las que se calculan las diferencias.

menor desvianza que L1 en los ocho municipios (Sección 4.4.1) y predice el 96,06 % del total observado, frente a cerca del 90 % de L1, la sensibilidad y la media constante. El contraste le gana a L1 en menos de la mitad de los cortes (22). La L0 de ocho semanas, a diferencia de la de cuatro del Entregable 2, tiene menor desvianza que la media constante (34 de 47 cortes).

La comparación entre la solución y L1 combina dos diferencias: el modelo y la ventana de entrenamiento, porque L1 se estima con toda la historia disponible y la solución, con los últimos 364 días. Dos comparaciones que difieren en un solo factor permiten separarlas de forma descriptiva (Anexo G, Tabla G4): con la misma ventana expansiva, el GLM reduce la desvianza de L1 apenas en 0,0030, mientras que, con el mismo GLM, pasar de la ventana expansiva a la de 364 días la reduce en 0,0265. La mejora frente a L1 se asocia, por lo tanto, principalmente a la ventana y no al algoritmo. L1 con una ventana de 364 días no se evaluó, por lo que la descomposición no es completa.

Todos los modelos, incluida la media constante, tienen menor desvianza en el bloque final que en validación, con diferencias de entre -0,0815 y -0,1195 (la solución, -0,1142): el bloque resultó más fácil de predecir para todos, y esa mejora no puede atribuirse a ningún modelo. Por eso las comparaciones informativas son las hechas dentro del mismo bloque. Las diferencias corte a corte, con su error estándar, están en el Anexo G (Tabla G4); son descriptivas y no constituyen pruebas de significación (Sección 3.5.2). La Ilustración 5 muestra la desvianza semana a semana.

Ilustración 5 – Desvianza por corte en el bloque final



Fuente: elaboración propia en base a datos de la UNASEV.

4.4 Análisis de errores y desempeño técnico

Los análisis de este apartado se refieren al bloque final; cuando se cita la validación, se indica. No se atribuyen causas a los errores: los datos no registran qué ocurrió en cada día o semana.

4.4.1 Errores por municipio y por tipo de día

La solución tiene menor desvianza que L1 en los ocho municipios (Tabla 8). El contraste es el mejor en CH, E y F, y la solución, en A, B, C, D y G. CH es el municipio peor predicho por todos los modelos, salvo la media constante. El residuo medio de la solución —observado menos predicho— es positivo en seis municipios, entre 0,0702 (A) y 0,2049 (B) siniestros por día, y casi nulo en F y G; su total predicho va del 92,33 % (E) al 100,54 % (F) de lo observado. En L1, el residuo es positivo en los ocho, entre 0,1812 (G) y 0,4537 (A). En validación ya se observaba lo mismo: la solución acercaba a 1 el total predicho en los seis municipios que L1 subestimaba, con el mayor cambio en A (de 0,8641 a 0,9330).

Tabla 8 – Desvianza por municipio en el bloque final

Municipio	Solución	Sensibilidad	Contraste	L1	Media constante
A	1,0614	1,1064	1,0767	1,1130	1,2708
B	1,1401	1,1520	1,1698	1,1546	1,3965
C	1,0448	1,0869	1,0883	1,0875	1,6149
CH	1,2777	1,2883	1,2680	1,2887	1,4165
D	1,0989	1,1227	1,1364	1,1257	1,4261
E	1,1150	1,1606	1,1076	1,1648	1,1847
F	1,0701	1,0858	1,0664	1,0892	1,0854
G	1,0427	1,0604	1,0454	1,0635	1,1266

Fuente: elaboración propia en base a datos de la UNASEV.

Por tipo de día, la solución subestima el total en siete de los ocho niveles (el miércoles predice el 100,53 %); su mayor desvianza está en el sábado (1,2353) y el feriado (1,2256), y la menor, en el viernes (0,9191) (Anexo G, Tabla G2).

4.4.2 Semanas de mayor error

Las cinco semanas de mayor desvianza de la solución son también las cinco peores de L1, y ninguna contiene feriados (Anexo G, Tabla G3). En tres de ellas el total predicho queda a menos del 3 % del observado, de modo que el error se concentra en cómo se distribuyen los siniestros entre días y municipios más que en el volumen semanal. La excepción es la semana del 5 al 11 de junio de 2025, con 216 siniestros observados

frente a 166,74 predichos. En validación, la peor semana fue la del 2 al 8 de enero de 2025, con 100 observados frente a 155,15 predichos.

4.4.3 Calibración y deriva

Por deciles de la predicción, la razón entre observado y predicho de la solución va de 0,9426 a 1,1095, con 8 de los 10 deciles por encima de 1; la de la sensibilidad va de 1,0331 a 1,1985, con los 10 por encima (Anexo G, Ilustración G1). La pendiente del residuo medio por corte es de -0,00115, con un intervalo del 95 % entre -0,0079 y 0,0056, que incluye el cero: no se detecta una deriva sostenida dentro del bloque, lo que no equivale a demostrar que no exista. La subestimación es menor en la segunda mitad del bloque (observado sobre predicho 1,025) que en la primera (1,058); en la sensibilidad y en L1 se mantiene entre 1,10 y 1,13 en ambas mitades.

4.4.4 Intervalos de predicción

La Tabla 9 compara la cobertura observada con la que espera el propio modelo (Sección 2.2.6). Al 80 %, la cobertura de los intervalos con dispersión de binomial negativa supera en 1,3 puntos a la esperada (0,9005 contra 0,8871); al 95 %, queda 0,2 puntos por debajo (0,9791 contra 0,9810). Los fallos son asimétricos: hay más observaciones por encima del intervalo que por debajo (al 80 %, 6,8 % contra 3,2 %), coherente con la subestimación del volumen. En el bloque final, el α de la binomial negativa se estimó por máxima verosimilitud en 45 cortes y por momentos en 2, con valores entre 0,0093 y 0,0339; el α del modelo exportado (0,0094) está en el extremo inferior de ese rango. La Ilustración G2 (Anexo G) presenta la cobertura de los intervalos. Que la cobertura observada se acerque a la esperada no valida toda la incertidumbre: los intervalos reflejan los supuestos del modelo —conteos de Poisson o binomial negativa, independientes entre días y municipios— y no incorporan los errores de registro, el subregistro ni la dependencia temporal.

Tabla 9 – Cobertura de los intervalos de predicción de la solución

Intervalo	Nominal	Validación: observada / esperada	Bloque final: observada / esperada	Bloque final: debajo / encima	Ancho medio
Binomial negativa	80 %	0,8883 / 0,8959	0,9005 / 0,8871	0,0315 / 0,0680	4,47
Binomial negativa	95 %	0,9787 / 0,9840	0,9791 / 0,9810	0,0019 / 0,0190	6,71
Poisson	80 %	0,8712 / 0,8937	0,8913 / 0,8873	0,0334 / 0,0752	4,30

Intervalo	Nominal	Validación: observada / esperada	Bloque final: observada / esperada	Bloque final: debajo / encima	Ancho medio
Poisson	95 %	0,9734 / 0,9833	0,9745 / 0,9799	0,0038 / 0,0217	6,44

Fuente: elaboración propia en base a datos de la UNASEV. Esperada: probabilidad que el propio modelo asigna al intervalo; ancho medio en siniestros, en el bloque final.

4.4.5 Robustez: exclusión de un municipio por vez

En validación, excluir cada municipio del ajuste y predecirlo con el calendario de los otros siete y su propio nivel empeora la desvianza global un 0,42 % y la del Municipio A un 2,00 %; en los demás, el cambio es de 0,54 % o menos, y en G mejora levemente (-0,11 %). El total predicho cambia como mucho 0,0005. El modelo depende poco de los datos de cada municipio para el calendario, salvo en A, coherente con su ciclo semanal propio. Con ocho municipios, la prueba tiene poco poder y no mide la generalización a zonas sin historia (Sección 3.5.5).

4.4.6 Desempeño técnico, reproducibilidad y pruebas del pipeline

Todos los ajustes de la experimentación terminaron sin avisos y todos los GLM convergieron; la binomial negativa convergió en los 47 cortes de validación. El cuaderno de experimentación completo demora unos 16 minutos y el entrenamiento del modelo final, del orden de segundos. Las reejecuciones del cuaderno de evaluación reprodujeron su registro con una diferencia relativa máxima de $2{,}51 \cdot 10^{-15}$.

El equipo ejecutó el entrenamiento del modelo final en el servidor institucional el 21/10/2026 (Anexo F, Tabla F3). El contenedor tenía Python 3.10.12, NumPy 1.26.4, pandas 2.3.3, scikit-learn 1.7.2 y SciPy 1.12.0, sin statsmodels ni la biblioteca de feriados. Con una implementación distinta de la local, el modelo coincidió con el exportado con diferencias relativas máximas de $4{,}25 \cdot 10^{-12}$ en los coeficientes, $3{,}42 \cdot 10^{-12}$ en las 56 predicciones y $5{,}26 \cdot 10^{-13}$ en α, cinco órdenes de magnitud por debajo del criterio de 10^{-6}. Un primer intento se detuvo antes de entrenar porque la carpeta de datos se había subido con un espacio al final de su nombre. La corrida demuestra que el entrenamiento es reproducible en otro entorno; no evalúa el desempeño.

Las pruebas del pipeline de inferencia se resumen en la Tabla 10. La suite completa terminó con 76 pruebas aprobadas y ninguna fallida; en un clon limpio del repositorio, sin datos, 66 se aprobaron y 10 se omitieron por requerir el panel, ninguna de ellas del prototipo, y la aplicación arrancó y respondió a la verificación de estado. Las 30 pruebas del prototipo también pasaron con las versiones de Streamlit, plotly y pydeck que usa el

tablero del servidor. Las pruebas detectaron tres errores, todos corregidos: un mensaje de archivo ausente que fallaba cuando la ruta estaba fuera del repositorio; la capa simplificada de municipios, que representaba al Municipio CH como un polígono múltiple y lo habría dibujado mal; y pruebas que dejaban modificado un módulo compartido. No cubren la verificación visual del mapa y de los gráficos, que el equipo realizó de forma manual en entorno local el 21/10/2026, ni las páginas heredadas.

Tabla 10 – Pruebas del pipeline de inferencia del prototipo

Grupo	Qué verifica	Archivo y pruebas
Validación de entradas	Se aceptan los 47 orígenes del bloque final; fechas fuera de rango o de tipo inválido producen un mensaje claro	test_pipeline_inferencia.py: test_validar_semana_*
Carga del modelo y de archivos	Un archivo ausente o ilegible produce un mensaje claro y no un error interno; el modelo exportado carga y es un GLM	test_pipeline_inferencia.py: test_modelo_ausente_*, test_modelo_real_carga
Modo «Semana posterior al corte»	56 filas, sin nulos ni negativos, con intervalos ordenados; coinciden con la predicción del servidor (diferencia relativa ≤ 10^{-6})	test_pipeline_inferencia.py: test_proxima_semana_*
Modo «Histórico»	Las 47 semanas están completas y cada una coincide fila a fila, con igualdad exacta, con el archivo de predicciones	test_pipeline_inferencia.py: test_historico_, *test_semana_historica_*
Mapa	La capa trae los ocho municipios con su polígono y su color	test_pipeline_inferencia.py: test_datos_del_mapa_*
Independencia de las bases de datos	La pestaña no carga los conectores de bases de datos ni la configuración heredada	test_pipeline_inferencia.py: test_la_pestana_no_importa_*
Interfaz	La pestaña se muestra sin errores en los dos modos, cambiar de semana o municipio no falla, y lo que ve el usuario coincide con el archivo	test_app.py: 6 pruebas con el entorno de pruebas de Streamlit

Fuente: elaboración propia en base a documentacion/pruebas_pipeline.md (registro del 21/10/2026). Los nombres de las pruebas corresponden a esa fecha.

UTEC
Universidad Tecnológica

5. Discusión

Este capítulo interpreta los resultados del capítulo 4 en relación con la pregunta, la hipótesis y los objetivos (5.1), los compara con los antecedentes (5.2), discute su aplicabilidad (5.3) y analiza sus limitaciones y las amenazas a su validez (5.4). Al tratarse del tercer entregable, la discusión es preliminar: la versión final integrará la retroalimentación de la defensa.

5.1 Interpretación de los resultados

Respuesta a la pregunta orientadora. Es posible estimar la cantidad esperada de siniestros registrados por municipio y día con siete días de anticipación, con una mejora consistente pero modesta sobre referencias simples. En el bloque final, que no intervino en la selección del Entregable 3 pero se había consultado antes y no es una prueba independiente, la solución reduce la desvianza de L1 en un 2,6 %, le gana en 33 de las 47 semanas y en los ocho municipios, y predice el 96 % del volumen observado frente al 90 % de L1. Sin embargo, de la reducción que la solución logra frente a la media constante, L1 ya obtiene la mayor parte, lo que sugiere que, con la información evaluada, el nivel de cada municipio y el calendario concentran la señal predecible a esta escala. La historia reciente por sí sola —el conjunto sin calendario— no supera a L1, y la meteorología, que la pregunta incluía, no pudo evaluarse por no estar disponible con siete días de anticipación. El aporte más claro de la solución sobre L1 no está en el error medio sino en la calibración del volumen, y la comparación con la sensibilidad indica que se asocia sobre todo a reentrenar con la ventana de 364 días y no al algoritmo (Sección 4.3.4): un año de historia sigue mejor un nivel que crece que toda la historia acumulada. La cobertura de los intervalos de predicción queda cerca de la que espera el propio modelo, con un sesgo hacia observaciones por encima del límite superior que refleja la subestimación remanente.

Los resultados tienen también una lectura menos favorable. En validación, ninguna alternativa se distinguió de L1 por más de un error estándar, y la mejora del bloque final es pequeña frente a la variabilidad entre semanas. La mejora general entre validación y bloque final afectó a todos los modelos por igual, por lo que no prueba nada sobre la solución. Las semanas peor predichas coinciden con las de L1 y no se explican con estos datos: el equipo las interpreta como ruido propio de los conteos sumado a eventos que el calendario no recoge, sin evidencia que permita verificarlo. Por último, XGBoost no aportó frente al GLM: dado que las interacciones que puede representar no mejoraron la

predicción, la estructura aditiva de nivel por calendario parece suficiente para estos datos, lo que es coherente con la ausencia de memoria de corto plazo hallada en el diagnóstico.

Contraste de la hipótesis. Los resultados son compatibles con la hipótesis de la Sección 1.2. En las dos familias, la regla eligió el modelo común con nivel por municipio y calendario —el conjunto (a)—, ya que ninguna variante más compleja lo superó por más de un error estándar. El término propio de A mejoró la predicción de ese municipio (-4,34 %) sin mejorar el conjunto, y la exclusión de municipios mostró que A es el que más depende de sus propios datos; los modelos separados por municipio no se evaluaron porque el modelo común no fue superado, que era la condición prevista para hacerlo. La evidencia es débil por construcción —ocho municipios y un criterio de empate amplio—, de modo que la hipótesis no queda refutada, pero tampoco demostrada. Estos resultados valen para los ocho municipios y el período evaluados: no prueban que el modelo común se transfiera a territorios nuevos ni que sea superior en general.

Metodología prevista y realizada. El Cuadro 7 contrasta lo planificado en la propuesta y en el Entregable 2 con lo que efectivamente se hizo, y la razón de cada diferencia. Las desviaciones más relevantes para la validez son dos: la ventana de L0 y la configuración final se decidieron mirando los mismos cortes de validación, y el bloque final había sido consultado antes; ambas se declaran y se analizan en la Sección 5.4.

Cuadro 7 – Metodología prevista y realizada

Aspecto	Previsto	Realizado	Motivo de la diferencia
Familias de modelos	SARIMA y potenciación de gradiente con rezagos (propuesta); árbol de decisión (Entregable 2)	GLM de Poisson, NB2 y XGBoost con pérdida de Poisson; sin SARIMA ni árbol único	Condición del Comité; el árbol no extrapoló la tendencia; sin autocorrelación más allá del calendario
Variables exógenas	Clima y calendario	Solo calendario; la lluvia se retiró antes de ejecutar	No disponible con siete días de anticipación; sin aporte fuera de muestra
Calendario	Tres niveles	Ocho niveles	Forma identificada por el diagnóstico
Rezagos	1, 7, 14 y 21 días (árboles del Entregable 2)	7 a 28 días en los conjuntos (0) y (c); la solución no los usa	Horizonte de siete días sin recursión; sin aporte sobre el calendario
Línea base L0	Cuatro semanas, fijadas antes de ejecutar	Ocho semanas, elegidas en validación	La de cuatro semanas quedó por detrás de la media constante
Ventanas	Comparar expansiva y deslizante	Expansiva y deslizantes de 364, 546 y 728 días	Objetivo OE2

Aspecto	Previsto	Realizado	Motivo de la diferencia
Evaluación en el bloque final	Ajuste congelado en el desarrollo (Entregable 2)	Reentrenamiento semanal, igual que en validación; una única evaluación	Es el procedimiento validado y el de uso previsto
Selección	El modelo con mejor desempeño y solidez	Regla de cuatro pasos fijada antes; la configuración final se apartó de ella	Mejor desvianza media y calibración, con diferencias menores a un error estándar
Generalización	Excluir un municipio por vez	Realizada en validación, como análisis descriptivo	Con el nivel tomado de la historia propia del municipio excluido
Prototipo	Pestaña en el tablero existente	Pestaña en entorno local; despliegue en el servidor pendiente	Entorno del tablero del servidor desconocido; costo no estimable

Fuente: elaboración propia.

5.2 Comparación con antecedentes

Los resultados confirman el punto de partida de la literatura de frecuencia de siniestros: la Poisson es la familia de referencia y la binomial negativa su extensión ante la sobredispersión (Lord y Mannering, 2010). En este panel la sobredispersión es leve —dispersión de Pearson cercana a 1,10 y α entre 0,03 y 0,04—, por lo que la binomial negativa no mejoró la media y su aporte se limitó a los intervalos. Los problemas de medias bajas y exceso de ceros que esa revisión y de Medrano y Aznarte (2021) señalan para unidades pequeñas no se presentaron, porque la agregación municipal deja menos del 10 % de ceros; es la razón por la que se descartaron la grilla y los barrios.

La revisión de Kontopoulou et al. (2023), que reúne comparaciones entre ARIMA y aprendizaje automático en diversos dominios, encuentra que el segundo suele superar al primero y advierte sobre la omisión de líneas base; como antecedente metodológico general, no anticipa el resultado en siniestralidad municipal. Este trabajo es coherente con esa advertencia: comparado contra referencias bien especificadas, el modelo de potenciación de gradiente no superó al GLM, y la configuración que eligió la regla quedó incluso por detrás de L1 en validación. Cuando la señal se reduce a un nivel por zona y un ciclo semanal, la capacidad adicional del modelo no encuentra estructura que aprovechar.

Eisenberg (2004) documenta un efecto diario de la lluvia que este trabajo no pudo aprovechar: el diagnóstico no encontró mejora con un indicador binario de lluvia para todo el departamento, y con siete días de anticipación la lluvia solo existiría como pronóstico. La diferencia puede deberse a la medida —binaria y sin variación espacial—, al clima de

Montevideo o al horizonte, y no autoriza a concluir que la lluvia carezca de efecto. Respecto de los modelos SARIMA (Deretić et al., 2022; Unidad Nacional de Seguridad Vial, 2025), el componente estacional semanal quedó contenido en el calendario, y el antecedente nacional modela otra variable —personas lesionadas— a otra escala, nacional y mensual, de modo que los resultados no son comparables en cifras sino complementarios en escala. Por último, la diferencia entre validación y bloque final confirma la recomendación de evaluar por origen móvil y comparar siempre dentro del mismo tramo (Hyndman y Athanasopoulos, 2021): un único tramo de evaluación puede resultar más fácil o más difícil para todos los modelos.

5.3 Aplicabilidad y viabilidad

El uso potencial de la solución es como referencia semanal de la cantidad esperada de siniestros registrados por municipio y día, con un intervalo que indica qué cantidad sería inusual. Su utilidad para decisiones operativas, como planificar fiscalización o campañas preventivas, no se evaluó: requeriría validarla con las instituciones responsables. No sirve para ordenar municipios por riesgo ni, por sí sola, para asignar recursos (Sección 1.1).

En lo técnico, la solución es liviana: el entrenamiento demora segundos, el modelo ocupa poco más de un kilobyte, la predicción no requiere las bibliotecas de entrenamiento y el procedimiento se reprodujo en el servidor institucional con otra implementación. La condición operativa principal está fuera del modelo: reentrenar cada semana exige disponer de los siniestros registrados hasta el día anterior a la semana a predecir. El rezago con que la UNASEV publica sus datos no se estudió; si los datos llegan con semanas de atraso, el horizonte efectivo se alarga y el desempeño medido aquí deja de ser representativo, porque la evaluación simuló que los registros estaban disponibles de inmediato. El prototipo alcanza el nivel TRL 5 en entorno local, en un entorno simulado cuya fecha de corte es el 31/12/2025; su despliegue en el tablero del servidor está pendiente y depende de un entorno cuyas versiones no se pudieron conocer, aunque las pruebas del prototipo pasaron con las de Streamlit, plotly y pydeck que el tablero utiliza. Las fuentes son abiertas y las herramientas, de código abierto, por lo que el costo de operación es bajo. La aplicabilidad se limita a Montevideo y al período evaluado: departamentos con menos siniestros enfrentarían conteos más bajos y más ceros.

5.4 Limitaciones y amenazas a la validez

El Cuadro 8 reúne, como matriz de riesgo, las limitaciones y amenazas a la validez del trabajo, con su evidencia, una valoración cualitativa de su probabilidad y de su impacto

sobre las conclusiones, y su tratamiento. El subregistro es la de mayor alcance y la única que no puede acotarse: la fracción no registrada es desconocida y podría ser desigual entre municipios. La amenaza interna más relevante es el uso de los mismos 47 cortes para buscar, seleccionar y decidir la configuración final, compensado solo en parte por una evaluación final sobre un bloque que no era virgen.

Cuadro 8 – Matriz de riesgo: limitaciones y amenazas a la validez

Amenaza	Tipo de validez	Evidencia	Prob. / impacto	Tratamiento
Subregistro desigual entre municipios	Constructo	No medible con estos datos	Media / alto	Vocabulario limitado a siniestros registrados; sin ordenamientos de riesgo
Ausencia de datos de exposición	Constructo	No hay volumen de tránsito por municipio	Alta / medio	Ídem; la importancia del municipio no se lee como causa
Bloque final consultado en el Entregable 2	Interna	Evaluación preliminar de la línea base; primera versión del diagnóstico	Ocurrió / medio	Declarado en metodología, resultados y conclusiones; sin consultas desde el 05/10/2026; configuración registrada antes; una sola evaluación; tratamiento sujeto al criterio del docente responsable
Atribución de la mejora frente a L1	Interna	L1 usa toda la historia y la solución, 364 días: la comparación mezcla modelo y ventana	Ocurrió / medio	Descomposición descriptiva con la sensibilidad (Tabla G4); L1 con 364 días no evaluada
Selección con los mismos cortes; L0 y configuración final elegidas en validación	Interna	Validación optimista; la final se apartó de la regla	Alta / medio	Evaluación final; sensibilidad y contraste fijados sin opción a reemplazo
Una sola serie de 47 semanas dependientes	Conclusión estadística	El error estándar ignora la dependencia entre cortes	Alta / medio	Sin afirmaciones de significación; se informan cortes ganados y error estándar
Bloque final más fácil para todos	Conclusión estadística	Todos los modelos bajaron su desvianza	Ocurrió / medio	Comparaciones solo dentro del mismo bloque
Deriva creciente y subestimación	Interna	Total predicho del 96 %; nivel +5 % a +9 % entre tramos	Alta / medio	Ventana de 364 días y reentrenamiento semanal; intervalos asimétricos declarados

Amenaza	Tipo de validez	Evidencia	Prob. / impacto	Tratamiento
Municipios parecidos; poco poder para generalizar	Externa	Razón 1,71; exclusión de un municipio con nivel propio	Media / medio	No se afirma generalización a zonas sin historia
Otros departamentos o datos de 2026	Externa	No evaluados	Alta / alto	Declarado; trabajo futuro
Disponibilidad de los datos al operar	Externa	Rezago de publicación de la UNASEV desconocido	Media / alto	Condición de uso explícita (Sección 5.3)
α estimado por momentos en el modelo exportado	Interna	La NB2 no convergió en la ventana final; α en el extremo inferior del rango	Media / bajo	Declarado; intervalos posiblemente algo más angostos
Intervalos basados en los supuestos del modelo	Conclusión estadística	Suponen conteos independientes; no incorporan errores de registro ni subregistro	Media / medio	La cobertura se informa como verificación parcial, no como validación completa
Capa de municipios del prototipo	Constructo	Huella distinta de la usada en la preparación; mismos ocho polígonos y nombres	Baja / bajo	Se usa solo para colorear el mapa, no para asignar ni medir

Fuente: elaboración propia.

6. Conclusiones y recomendaciones

6.1 Cumplimiento de los objetivos

El Cuadro 9 resume el estado de cada objetivo con su evidencia y su medio de verificación. Los estados de los objetivos 1 a 3 se registraron antes de leer el bloque final; el del objetivo 4, después del prototipo. Las conclusiones sobre desempeño se apoyan en un bloque final que ya se había consultado (Sección 3.5.3) y que no constituye una prueba independiente; el tratamiento de esa limitación queda sujeto al criterio del docente responsable.

Cuadro 9 – Cumplimiento de los objetivos, la pregunta y la hipótesis

Elemento	Estado	Evidencia y medio de verificación	Lo que no se alcanzó
Objetivo general	Cumplido en entorno local, con la salvedad del bloque final	Menor desvianza que las tres referencias en el bloque final (Tabla 7) y pestaña integrada al tablero (Sección 4.2.3; carpeta app/ del repositorio)	Despliegue en el servidor; evaluación sobre un bloque independiente
OE1 – ETL	Cumplido (Entregable 2)	Panel regenerable y 16 verificaciones superadas (Sección 4.1.3; Anexo E; cuaderno de preparación)	Sin pendientes
OE2 – Estrategias	Cumplido en calendario y ventanas; no cumplido en meteorología	Conjuntos y ventanas comparados en 47 cortes (Tablas 5 y 6; registro de experimentos con 38 configuraciones)	La meteorología no se evaluó
OE3 – Selección	Cumplido en el procedimiento, con una salvedad	Regla y precisiones fechadas en el cuaderno de experimentación (16/10 y 19/10/2026); configuración registrada el 19/10/2026, antes de la evaluación final (Secciones 4.3.3 y 4.3.4; Anexo F, Tabla F4); limitaciones en la Sección 5.4	La configuración final no es la que eligió la regla
OE4 – Pestaña	Cumplido en entorno local	Pestaña con mapa en dos modos, verificada el 21/10/2026; 30 pruebas del prototipo aprobadas (Sección 4.4.6; Tabla 10; Anexo F.3)	Despliegue en el servidor
Pregunta orientadora	Respondida afirmativamente, con alcance acotado	Mejora consistente pero modesta sobre referencias simples, asociada sobre todo a la ventana (Secciones 4.3.4 y 5.1)	Sin variables meteorológicas; bloque no independiente
Hipótesis	No refutada	El modelo común con nivel por municipio no fue superado (Tabla 5; Sección 5.1)	Evidencia débil: ocho municipios

Fuente: elaboración propia.

6.2 Contribuciones del proyecto

El proyecto aporta un conjunto de datos reproducible: un panel diario de siniestros registrados por municipio de Montevideo, regenerable desde fuentes abiertas y sin fuga de información; una evaluación transparente, con lista cerrada de modelos, regla de selección escrita antes de ejecutar, todas las configuraciones registradas y las desviaciones declaradas; evidencia sobre el problema, limitada a los ocho municipios y al período evaluados: el nivel de cada municipio y el calendario concentran la señal predecible, y reentrenar con el último año corrige buena parte de la subestimación; y una herramienta integrada al tablero existente, con intervalos de predicción cuya cobertura se verificó.

6.3 Recomendaciones

- Usar la estimación como referencia semanal, leyendo cada valor junto con su intervalo, y no como ordenamiento de riesgo entre municipios ni como único criterio de asignación de recursos.
- Reentrenar el modelo cada semana con los últimos 364 días y mantener L1 como control: si durante varias semanas la solución no la supera, volver a la referencia más simple.
- Vigilar el total predicho sobre el observado y la cobertura de los intervalos, para detectar cambios de nivel.
- Antes de cualquier uso operativo, establecer con la UNASEV el rezago con que se dispone de los datos, condición de la que depende el horizonte real.

6.4 Trabajo futuro

- Incorporar pronósticos meteorológicos a siete días y datos de exposición, como el volumen de tránsito, evaluando su aporte con el mismo protocolo.
- Investigar la subestimación remanente y las semanas de mayor error con información de eventos y de movilidad.
- Evaluar la solución con los datos de 2026 publicados por la UNASEV y en otros departamentos.
- Desplegar la pestaña en el tablero del servidor institucional y agregar verificaciones visuales automáticas del mapa y los gráficos.

UTEC
Universidad Tecnológica

Referencias

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery. https://doi.org/10.1145/2939672.2939785

de Medrano, R., y Aznarte, J. L. (2021). A new spatio-temporal neural network approach for traffic accident forecasting. *Applied Artificial Intelligence, 35*(10), 782–801. https://doi.org/10.1080/08839514.2021.1935588

Deretić, N., Stanimirović, D., Awadh, M. A., Vujanović, N., y Djukić, A. (2022). SARIMA modelling approach for forecasting of traffic accidents. *Sustainability, 14*(8), Artículo 4403. https://doi.org/10.3390/su14084403

Eisenberg, D. (2004). The mixed effects of precipitation on traffic crashes. *Accident Analysis & Prevention, 36*(4), 637–647. https://doi.org/10.1016/S0001-4575(03)00085-X

Géron, A. (2023). *Aprende machine learning con Scikit-Learn, Keras y TensorFlow* (3.ª ed.). Anaya Multimedia.

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Hyndman, R. J., y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Hyndman, R. J., y Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688. https://doi.org/10.1016/j.ijforecast.2006.03.001

Intendencia de Montevideo. (s. f.). *Municipios de Montevideo* [Capa vectorial zon_v_sig_municipios]. Recuperado el 7 de setiembre de 2026, de https://montevideo.gub.uy/app/geoserver

Kontopoulou, V. I., Panagopoulos, A. D., Kakkos, I., y Matsopoulos, G. K. (2023). A review of ARIMA vs. machine learning approaches for time series forecasting in data driven networks. *Future Internet, 15*(8), Artículo 255. https://doi.org/10.3390/fi15080255

Lord, D., y Mannering, F. (2010). The statistical analysis of crash-frequency data: A review and assessment of methodological alternatives. *Transportation Research Part A: Policy and Practice, 44*(5), 291–305. https://doi.org/10.1016/j.tra.2010.02.001

McCullagh, P., y Nelder, J. A. (1989). *Generalized linear models* (2.ª ed.). Chapman & Hall.

Molnar, C. (2025). *Interpretable machine learning: A guide for making black box models explainable* (3.ª ed.). https://christophm.github.io/interpretable-ml-book/

Newey, W. K., y West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica, 55*(3), 703–708. https://doi.org/10.2307/1913610

Open-Meteo. (s. f.). *Historical Weather API* [Documentación técnica]. https://open-meteo.com/en/docs/historical-weather-api

Unidad Nacional de Seguridad Vial. (2025). *Modelos SARIMA para la predicción de lesionados en siniestros de tránsito en Uruguay*. Presidencia de la República. https://www.gub.uy/unidad-nacional-seguridad-vial/sites/unidad-nacional-seguridad-vial/files/2025-10/SARIMA_lesionados_Formato%20UNASEV.pdf

Unidad Nacional de Seguridad Vial. (2026). *Informe anual de siniestralidad vial 2025*. Presidencia de la República. https://www.gub.uy/unidad-nacional-seguridad-vial/datos-y-estadisticas/estadisticas

World Health Organization. (2023). *Global status report on road safety 2023*. https://www.who.int/publications/i/item/9789240086517

Anexos

Los anexos reúnen el material que respalda el cuerpo del informe y que, por su nivel de detalle, no lo integra. Cada uno está citado desde el texto. El código completo, los cuadernos, las tablas de salida y los registros de ejecución permanecen en el repositorio del proyecto.

Anexo A – Procedencia y verificación de las fuentes

Tabla A1 – Fuentes de datos, procedencia y verificación

Fuente	Archivo	Tamaño	Huella sha256	Verificación en cada corrida
Registro de siniestros (UNASEV)	uru_siniestros_unificado.csv	26,19 MB	48a8a7e8…	Huella, dimensiones y vocabulario de las columnas categóricas
Capa de municipios (Intendencia de Montevideo)	municipios_montevideo.geojson	2,87 MB	ed0ba13e…	Huella, cantidad de polígonos y fecha de modificación
Serie meteorológica (Open-Meteo)	clima_montevideo.csv	0,08 MB	f40e6c3c…	Cobertura del período y ausencia de faltantes

Fuente: elaboración propia. El prototipo usa una copia simplificada de la capa de municipios (38,8 kB), generada a partir de un archivo con huella c5d9f651…, distinta de la registrada; los ocho polígonos y sus nombres coinciden, y la copia se usa solo para colorear el mapa.

Tabla A2 – Recorte del archivo al alcance del proyecto

Paso	Registros	Porcentaje del archivo
Registros del archivo original	224.694	100,0 %
Tras eliminar 347 duplicados exactos	224.347	99,8 %
Tras retener el departamento de Montevideo	62.288	27,7 %
Tras retener las fechas desde el 1.º de julio de 2021	36.623	16,3 %
Tras descartar 11 hechos fuera de todo polígono	36.612	16,3 %

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: experiments/etl_montevideo/tablas/ (01_duplicados, 02_recorte y 03c_asignacion_zonas). Los duplicados se eliminan sobre el archivo nacional, antes de filtrar.

UTEC
Universidad Tecnológica

Anexo B – Calidad: faltantes y valores atípicos

Tabla B1 – Faltantes codificados como texto, por columna, hasta el 05/02/2025

Columna	Archivo nacional (196.431 registros)	Recorte de Montevideo (28.629 registros, antes de deduplicar)
Localidad	18,14 %	4,47 % (1.281 registros)
Calle	12,50 % (y un nulo)	2,32 % (663 registros)
Tipo de siniestro	0,01 %	0,03 % (10 registros)
Gravedad, día de la semana, departamento	0,00 %	0,00 %

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: 05b_faltantes_codificados.csv.

Tabla B2 – Valores atípicos de la serie diaria del departamento en el desarrollo, según dos criterios de Tukey

Indicador	Valor
Mínimo, mediana y máximo diarios	4; 22,0 y 43
Cuartiles (Q1, Q3) e intervalo intercuartílico	17, 26 y 9
Límites del criterio global	3,5 y 39,5
Días atípicos con el criterio global	7, todos por encima
Días atípicos dentro de su grupo de calendario	16: 14 por encima y 2 por debajo; ningún feriado
Días marcados por ambos criterios	7
Días marcados solo dentro de su grupo	9
Atípicos por municipio, dentro de su grupo	De 9 (E) a 35 (G y CH); 18 y 15 de los de G y CH con cinco siniestros o menos

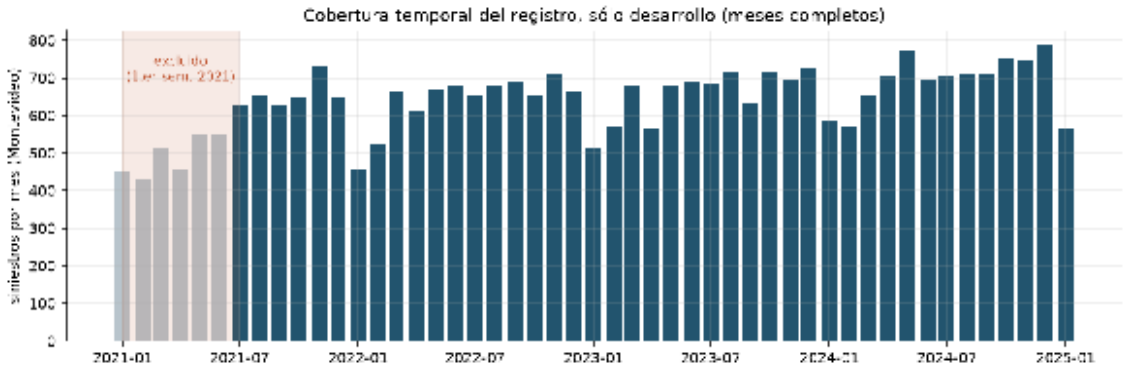
Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: 05g_serie_departamental_desarrollo.csv y 05_atipicos_por_municipio.csv. El criterio se aplica sobre la serie diaria del departamento, ya deduplicada, solo en el desarrollo; ningún día se eliminó ni se corrigió.

Tabla B3 – Cobertura temporal y evolución interanual en el desarrollo

Año	Siniestros	Días observados	Media diaria	Variación
2021 (julio a diciembre)	3.936	184	21,39	No comparable
2022	7.665	365	21,00	No comparable
2023	7.873	365	21,57	+2,7 %
2024	8.398	366	22,95	+6,4 %

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: 05f_cobertura_temporal_anual.csv. 2025 se omite: el desarrollo incluye solo 36 días de ese año. 2021 aporta solo el segundo semestre, el más activo, por lo que la variación hacia 2022 no es interpretable; entre segundos semestres, la media diaria pasa de 21,39 (2021) a 22,05, 22,68 y 23,96.

Ilustración B1 – Cobertura temporal del registro en el desarrollo, con el tramo excluido señalado



Fuente: elaboración propia en base a datos de la UNASEV.

Anexo C – Cobertura territorial por municipio

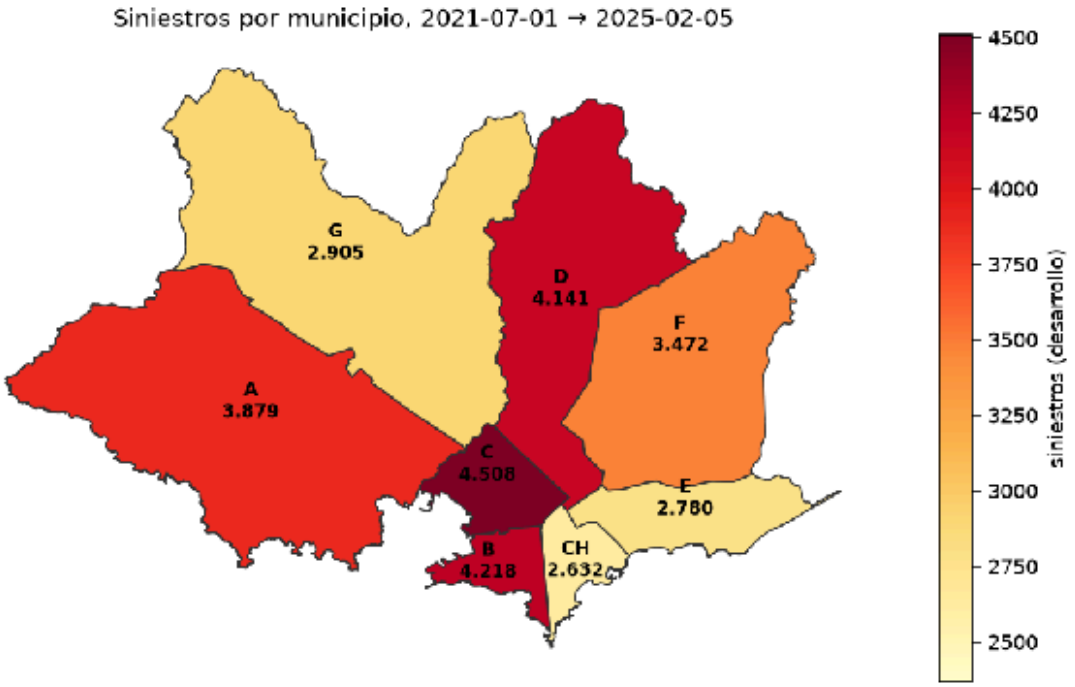
Tabla C1 – Cobertura territorial por municipio en el desarrollo

Municipio	Siniestros	Porcentaje	Días con al menos un siniestro	Media diaria
C	4.508	15,80 %	94,68 %	3,4255
B	4.218	14,78 %	94,53 %	3,2052
D	4.141	14,51 %	95,21 %	3,1467
A	3.879	13,59 %	93,39 %	2,9476
F	3.472	12,17 %	92,55 %	2,6383
G	2.905	10,18 %	86,63 %	2,2074
E	2.780	9,74 %	84,80 %	2,1125
CH	2.632	9,22 %	83,51 %	2,0000
Total	28.535	100 %	—	2,7104

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: 03_resumen_por_municipio.csv. Razón entre el municipio con más y el con menos siniestros: 1,71.[7]

[7]En la fila Total, el guion (—) indica que no corresponde un total: la columna es un porcentaje propio de cada municipio.

Ilustración C1 – Distribución territorial de los siniestros acumulados por municipio en el desarrollo



Fuente: elaboración propia en base a datos de la UNASEV.

Tabla C2 – Caracterización del panel según la partición territorial (antecedente)

Partición	Zonas	Filas	Ceros	Media	Índice de dispersión	Máximo	Período
Grilla de 1 km (superada)	403	735.878	95,08 %	0,0538	1,136	5	01/01/2021–31/12/2025
Barrios (superada)	62	113.212	71,96 %	0,3495	1,132	7	01/01/2021–31/12/2025
Municipios (vigente)	8	13.160	8,60 %	2,7821	1,259	13	01/07/2021–31/12/2025

Fuente: elaboración propia en base a datos de la UNASEV. Antecedente conservado sin recalcular: las tres filas provienen de versiones previas de la preparación sobre el período completo, que incluye el bloque final, y no deben mezclarse con las cifras de desarrollo del cuerpo (10.528 filas, 9,34 % de ceros). Como los períodos difieren, la diferencia de ceros no puede atribuirse en su totalidad al tamaño de las zonas.

Anexo D – Estructura temporal de las series y homogeneidad entre municipios

Tabla D1 – Estructura temporal de las series de los ocho municipios

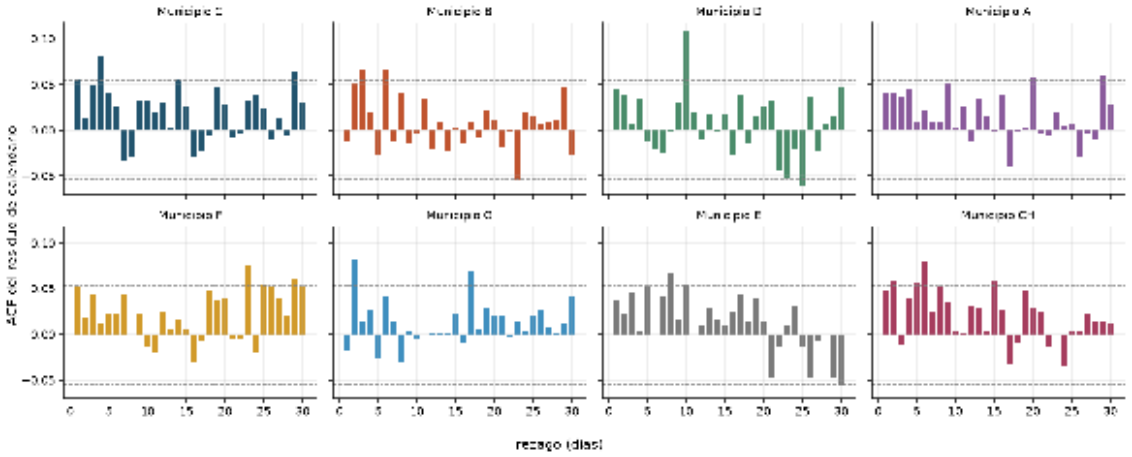
Indicador	C	B	D	A	F	G	E	CH
Media diaria	3,4255	3,2052	3,1467	2,9476	2,6383	2,2074	2,1125	2,0000
Índice de dispersión	1,291	1,157	1,153	1,134	1,069	1,080	1,267	1,214

UTEC
Universidad Tecnológica

Indicador	C	B	D	A	F	G	E	CH
Viernes ÷ domingo	2,19	1,58	1,45	1,43	1,44	1,41	1,88	1,79
ACF cruda, rezago 1	0,0557	0,0117	0,0459	0,0362	0,0526	-0,0214	0,0531	0,0661
ACF cruda, rezago 7	0,0765	0,0384	0,0064	0,0309	0,0698	0,0322	0,0933	0,0798
ACF cruda, rezago 14	0,1636	0,0158	0,0277	0,0441	0,0415	0,0164	0,0687	0,0532
ACF del residuo, rezago 1	0,0554	-0,0127	0,0453	0,0421	0,0517	-0,0175	0,0367	0,0468
Ljung-Box del residuo, p (7)	0,0045	0,0189	0,335	0,201	0,151	0,0516	0,129	0,0015
Ljung-Box del residuo, p (14)	0,0066	0,0776	0,0258	0,285	0,496	0,358	0,0606	0,0052
Ljung-Box del residuo, p (28)	0,0412	0,403	0,0152	0,525	0,0623	0,526	0,113	0,0169
ADF, p	< 0,001	< 0,001	< 0,001	< 0,001	< 0,001	< 0,001	< 0,001	< 0,001
KPSS, p	0,084	0,10	0,10	0,01	0,01	0,01	0,10	0,10
ACF rezago 1 con d = 1	-0,464	-0,513	-0,486	-0,493	-0,477	-0,549	-0,470	-0,484
λ de Box-Cox	0,448	0,497	0,409	0,461	0,420	0,419	0,251	0,257

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: 03, 09, 12 y 13 de experiments/diagnostico_municipios/tablas/. Autocorrelación sobre la serie cruda y sobre el residuo de calendario (descontados el día de la semana y el feriado); banda nula ±0,0540. KPSS acota el p entre 0,01 y 0,10.

Ilustración D1 – Autocorrelación del residuo de calendario por municipio, frente a la banda nula



Fuente: elaboración propia en base a datos de la UNASEV.

Con solo los 987 días del entrenamiento inicial (banda ±0,0624), el residuo de calendario no supera la banda en ningún municipio en los rezagos 1, 7, 14, 21 ni 28, mientras que la serie cruda la supera en C, CH y E: los picos en esos rezagos son calendario. La persistencia de C en el rezago 1 aparece al incluir la ventana de validación; la de CH se detecta también con solo el entrenamiento.

Tabla D2 – Homogeneidad entre municipios y comparación predictiva de modelos mínimos

Pregunta	Resultado
¿El nivel difiere entre municipios?	Sí: F = 134,47; reduce la desvianza un 7,545 %
¿Cuánto mejora conocer el nivel?	+7,62 % (pliegue A) y +7,86 % (pliegue B)
¿Cuánto aportan los datos propios de un municipio?	Frente a usar el nivel y el calendario de los otros siete, mejoran la desvianza un 9,81 % y un 10,20 %
¿El perfil de calendario difiere?	Estadísticamente sí (F = 2,71; 1,139 % de la desvianza), pero especializarlo no mejora en promedio: -0,22 % y +0,32 %, con intervalos que incluyen el cero
¿Qué municipios se apartan del perfil agregado?	A (p de Holm $3 \cdot 10^{-6}$; 2,92 %) y C (0,0008; 2,07 %); CH queda cerca (0,064)
¿Quién necesita calendario propio según la regla?	Solo A (+4,06 % y +4,24 %). C (-2,05 % y +1,22 %) y CH (+1,53 % y -0,56 %) cambian de signo; G empeora (-2,45 %)
¿Difieren la tendencia, la estacionalidad anual o el efecto de la lluvia?	No concluyente: p = 0,033, 0,016 y 0,35; reducciones de 0,92 % o menos
¿Alcanza el nivel histórico?	Subestima el volumen en siete de ocho municipios, más en A (razón 0,842 en el pliegue B): hay que recalibrarlo

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: las tablas 16 a 22 de experiments/diagnostico_municipios/tablas/. Modelos mínimos multiplicativos de nivel por calendario de ocho grupos, estimados solo con el tramo de ajuste de cada pliegue (658 y 987 días; validación de 329). Intervalos del 95 % por remuestreo de bloques semanales (2.000 remuestreos). Regla fijada antes de ejecutar: un municipio necesita calendario propio si este mejora al común en al menos un 1 % y el intervalo excluye el cero, en los dos pliegues. Las pruebas F suponen errores independientes.

Anexo E – Preparación: cobertura de las acciones y verificación

Cuadro E1 – Cobertura de las acciones de preparación

Acción	Estado	Fundamento
Limpieza	Aplicada	Duplicados exactos, formato de fecha verificado, coordenadas validadas
Transformación	Aplicada	Reproyección de coordenadas y agregación al par día-municipio
Transformación del objetivo	No corresponde	Ni diferenciación ni logaritmo o Box-Cox: el diagnóstico lo desaconseja para los ocho municipios (Sección 4.1.2)
Imputación	No corresponde	Sin faltantes en las columnas que sobreviven al recorte ni en la serie meteorológica

Acción	Estado	Fundamento
Codificación	Aplicada	Calendario de tres niveles en el panel; al modelar, calendario de ocho niveles derivado de la fecha
Escalado	No corresponde	Los modelos evaluados no lo requieren
Balanceo	No corresponde	La tarea es una regresión de conteo: no hay clases
Construcción de variables	Aplicada	Calendario, nivel del municipio, nivel reciente, rezagos y término de A, construidos al modelar solo con datos anteriores al origen (Sección 3.5.1)
Selección de variables	Aplicada	Descarte de constantes, de no utilizadas y de las que producirían fuga; conjuntos anidados comparados en validación
Reducción de dimensionalidad	No corresponde	El conjunto final tiene doce columnas

Fuente: elaboración propia.

Cuadro E2 – Decisiones de limpieza y transformación, con su justificación y su efecto

Decisión	Justificación	Efecto observado
Eliminar los duplicados exactos	El archivo carece de identificador de siniestro y el grupo mayor reúne diez filas idénticas en fecha, hora, esquina, tipo y gravedad	347 filas eliminadas en el archivo nacional, antes del recorte. Antes de eliminarlas, el máximo del objetivo era un artefacto de carga
Fijar el formato de fecha y verificarlo contra el día de la semana declarado	Una fecha ambigua admite dos lecturas sin emitir aviso	Un único formato explica el 100 % de los días declarados, sin fechas inválidas
Descartar las columnas de gravedad	Agregadas por día suman exactamente el objetivo: serían una fuga perfecta	El conjunto no permite modelar por gravedad sin rehacer el procedimiento
Resumir el calendario del panel en tres niveles	Mes, día del año y semana, como enteros, separan diciembre de enero; todas se recuperan desde la fecha	Conserva el 21,42 % de la varianza diaria del desarrollo, frente al 19,94 % del día de la semana
No incluir variables de nivel de zona en el panel	La tasa de cada municipio debe estimarse solo con el entrenamiento de cada partición	Una verificación automática detiene la ejecución si una variable de ese tipo se incorpora
Conservar el nulo al normalizar columnas de texto	En pandas 2.x, la conversión a texto transforma el faltante en la cadena «nan», que se contaría como un valor válido	Corregido; no altera ninguna cifra de este informe

Fuente: elaboración propia.

Anexo F – Línea base del Entregable 2, servidor, tablero y evidencias del repositorio

Las Tablas F1 y F2 conservan, como antecedente, los resultados del Entregable 2 sobre la serie del Municipio C (Sección 4.3.1): calendario de tres niveles, referencias y árboles de arranque y, sobre el bloque final, ajuste congelado en el desarrollo. No son

comparables con las cifras del panel de ocho municipios. El detalle de los árboles se conserva en el informe del Entregable 2 y en el repositorio.

Tabla F1 – Entregable 2: desempeño en validación interna, Municipio C

Modelo	Desvianza de Poisson	MAE	RMSE	Total predicho / observado
Media móvil de 56 días por calendario	1,3766	1,6501	2,1663	1,0102
Referencia con calendario (tres niveles)	1,3782	1,6114	2,1641	0,9146
Árbol de profundidad acotada	1,4005	1,6815	2,1958	0,9981
Media constante	1,5178	1,7591	2,2735	0,9133
Repetir la semana anterior	7,8956	2,3769	3,0647	1,0066

Fuente: elaboración propia en base a datos de la UNASEV (Entregable 2). 47 cortes con ventana expansiva.

Tabla F2 – Entregable 2: desempeño en el bloque final, evaluado preliminarmente, Municipio C

Modelo	Desvianza de Poisson	MAE	RMSE	Total predicho / observado	Días con predicción cero
Referencia con calendario (tres niveles)	1,085	1,592	1,967	0,884	0
Media constante	1,262	1,741	2,120	0,884	0
Promedio de las últimas cuatro semanas	1,332	1,755	2,179	0,981	0
Árbol de profundidad acotada	1,679	1,906	2,409	0,723	0
Árbol recursivo sin exógenas	3,462	2,137	2,738	0,967	7
Repetir la semana anterior	5,007	2,228	2,866	0,996	10

Fuente: elaboración propia en base a datos de la UNASEV (Entregable 2). 47 semanas con el ajuste congelado en el desarrollo. Las desvianzas de los modelos con predicciones nulas dependen del valor de reemplazo (10^{-6}).

F.1 Ejecuciones en el servidor institucional

Tabla F3 – Trabajos ejecutados en el servidor institucional

Campo	Job 104 (Entregable 2)	Job 136 (Entregable 3)
Fecha y hora (-03)	18/09/2026, 12:42:01 a 12:42:11	21/10/2026, 09:44:02 a 09:44:04
Script	train_base.py (modelo base, Municipio C)	train_modelo_final.py (modelo final, ocho municipios)
Recursos	Partición cpu, 4 CPU, 12 G, límite 04:00:00	Partición cpu, 4 CPU, 12 G, límite 04:00:00
Imagen	tensorflow_ngc_24.04_tf2_py3_mlcv.sif	tensorflow_ngc_24.04_tf2_py3_mlcv.sif
Entorno del contenedor	Python 3.10.12, pandas 1.5.3, NumPy 1.24.4, scikit-learn 1.2.0	Python 3.10.12, pandas 2.3.3, NumPy 1.26.4, scikit-learn 1.7.2, SciPy 1.12.0; sin statsmodels ni holidays

Campo	Job 104 (Entregable 2)	Job 136 (Entregable 3)
Entrada	Panel del Municipio C	Panel completo (huella sha256 coincidente) y modelo exportado (huella coincidente)
Resultado	Ejecución completa sin error; RUN_ID 20260918_124207	IRLS convergió en 5 iteraciones; α por momentos 0,009395; diferencias relativas máximas de $4{,}25 \cdot 10^{-12}$ (coeficientes), $3{,}42 \cdot 10^{-12}$ (μ) y $5{,}26 \cdot 10^{-13}$ (α); criterio ≤ 10^{-6} cumplido; RUN_ID 20261021_094404

Fuente: logs de las ejecuciones en documentacion/logs/ del repositorio. Un intento previo del 21/10/2026 (job 135) se detuvo antes de entrenar porque no encontró el panel: la carpeta se había subido con un espacio al final de su nombre.

F.2 Procedencia del tablero

El tablero proviene del repositorio del Proyecto de Ingeniería de Datos (git.utec.edu.uy/juan.pimentel/siniestros-viales-grp4, versión f803bd6), copiado sin modificaciones y sin sus dependencias empaquetadas ni archivos de credenciales. Los únicos cambios al código heredado son la entrada «Predicción (PAA)» en la barra de navegación, su ícono y la rama que invoca la pestaña nueva. La capa de municipios del mapa proviene del servidor geográfico de la Intendencia de Montevideo (capa zon_v_sig_municipios), sin costos ni restricciones de acceso declarados, y se simplificó con una tolerancia de unos 30 metros.

F.3 Ejecución de la inferencia sin reentrenar y evidencias

Con el entorno instalado desde la raíz del repositorio (pip install -r requirements.txt -c requirements-lock.txt), la instrucción streamlit run app/app.py abre el tablero en http://localhost:8501. La pestaña «Predicción (PAA)» carga el modelo exportado mediante el módulo src/modelo.py y predice sin reentrenar, sin los datos crudos y sin bases de datos; las pruebas se ejecutan con pytest. La Tabla F4 indica dónde se encuentran, en el repositorio, las evidencias que respaldan las cifras de este informe.

Tabla F4 – Evidencias del repositorio que respaldan el informe

Evidencia	Ubicación en el repositorio
Registro de las 38 configuraciones evaluadas	experiments/modelos_candidatos/registro_experimentos.csv
Regla de selección y precisiones fechadas	Primera sección del cuaderno de experimentación de modelos candidatos
Configuración seleccionada (19/10/2026)	solucion_seleccionada.json (registro 1560a5b)

Evidencia	Ubicación en el repositorio
Resultados de la evaluación final	experiments/evaluacion_final/tablas/ y figuras/
Modelo exportado y metadatos	models/modelo_final.json y models/metadata.json
Pruebas del pipeline y su registro	tests/ y documentacion/pruebas_pipeline.md
Ejecución en el servidor institucional	documentacion/logs/log_servidor_modelo_final.txt y documentacion/logs/servidor_modelo_final/resumen_corrida.json
Procedencia del tablero	app/ORIGEN.md
Registro de uso de inteligencia artificial	documentacion/registro_uso_IA.md

Fuente: elaboración propia.

Anexo G – Resultados complementarios de la experimentación y la evaluación final

Tabla G1 – Paso B: grilla de XGBoost y binomial negativa en validación (conjunto (a), ventana expansiva)

Configuración	Desvianza	EE	Pred. / obs.	Desvío entre cortes	Diferencia con L1	Cortes que gana a L1
XGBoost, prof. 4, 300 árboles, tasa 0,05	1,2197	0,0358	0,9339	0,2455	-0,0122	31
XGBoost, prof. 2, 300 árboles, tasa 0,1	1,2202	0,0360	0,9339	0,2468	-0,0117	33
XGBoost, prof. 4, 100 árboles, tasa 0,1	1,2204	0,0362	0,9338	0,2483	-0,0115	31
XGBoost, prof. 3, 300 árboles, tasa 0,1	1,2211	0,0358	0,9339	0,2453	-0,0108	29
XGBoost, prof. 3, 300 árboles, tasa 0,05	1,2217	0,0361	0,9338	0,2476	-0,0102	31
XGBoost, prof. 4, 300 árboles, tasa 0,1	1,2223	0,0356	0,9340	0,2441	-0,0096	29
XGBoost, prof. 3, 100 árboles, tasa 0,1	1,2264	0,0366	0,9337	0,2510	-0,0054	29
XGBoost, prof. 2, 300 árboles, tasa 0,05	1,2276	0,0368	0,9337	0,2521	-0,0042	27
XGBoost, prof. 4, 100 árboles, tasa 0,05	1,2290	0,0374	0,9336	0,2562	-0,0029	26
Binomial negativa (NB2)	1,2301	0,0359	0,9341	0,2464	-0,0018	33

Configuración	Desvianza	EE	Pred. / obs.	Desvío entre cortes	Diferencia con L1	Cortes que gana a L1
GLM de Poisson – elegido en su familia	1,2302	0,0359	0,9341	0,2464	-0,0017	36
L1 (referencia)	1,2319	0,0358	0,9305	0,2456	0	—
XGBoost, prof. 2, 100 árboles, tasa 0,1 – elegido en su familia	1,2375	0,0375	0,9336	0,2573	+0,0056	20
XGBoost, prof. 3, 100 árboles, tasa 0,05	1,2443	0,0380	0,9335	0,2607	+0,0124	17
XGBoost, prof. 2, 100 árboles, tasa 0,05	1,2671	0,0396	0,9332	0,2711	+0,0353	10

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: experiments/modelos_candidatos/tablas/18_paso_b_globales.csv. Empatan con la mejor de su familia las configuraciones con desvianza hasta 1,2555 (XGBoost) y 1,2660 (GLM).[8]

Tabla G2 – Errores por tipo de día en el bloque final (desvianza)

Tipo de día	n	Solución	Sensibilidad	Contraste	L1	Pred. / obs. de la solución
Lunes	352	1,1171	1,1323	1,1281	1,1367	0,9762
Martes	360	1,1665	1,2132	1,1846	1,2176	0,9355
Miércoles	368	1,0495	1,0614	1,0639	1,0602	1,0053
Jueves	344	1,1436	1,2181	1,1585	1,2239	0,9347
Viernes	360	0,9191	0,9399	0,9591	0,9391	0,9556
Sábado	368	1,2353	1,2340	1,2275	1,2352	0,9496
Domingo	352	1,0704	1,0874	1,0788	1,0915	0,9797
Feriado	128	1,2256	1,2622	1,2264	1,2743	0,9395

Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: experiments/evaluacion_final/tablas/11_errores_por_tipo_dia.csv.

Tabla G3 – Las cinco semanas de mayor desvianza de la solución en el bloque final

Rango	Semana	Solución	L1 (rango entre 47)	Observado	Predicho	Pred. / obs.
1	28/08/2025 a 03/09/2025	1,6535	1,6369 (2)	166	168,86	1,0172
2	05/06/2025 a 11/06/2025	1,5498	1,6923 (1)	216	166,74	0,7719
3	06/03/2025 a 12/03/2025	1,4979	1,5750 (3)	187	163,46	0,8741
4	29/05/2025 a 04/06/2025	1,4005	1,4419 (4)	165	165,97	1,0059
5	27/03/2025 a 02/04/2025	1,3992	1,4409 (5)	168	164,19	0,9773

[8]En la fila de L1, el guion (—) indica que no corresponde contar los cortes que la referencia se gana a sí misma.

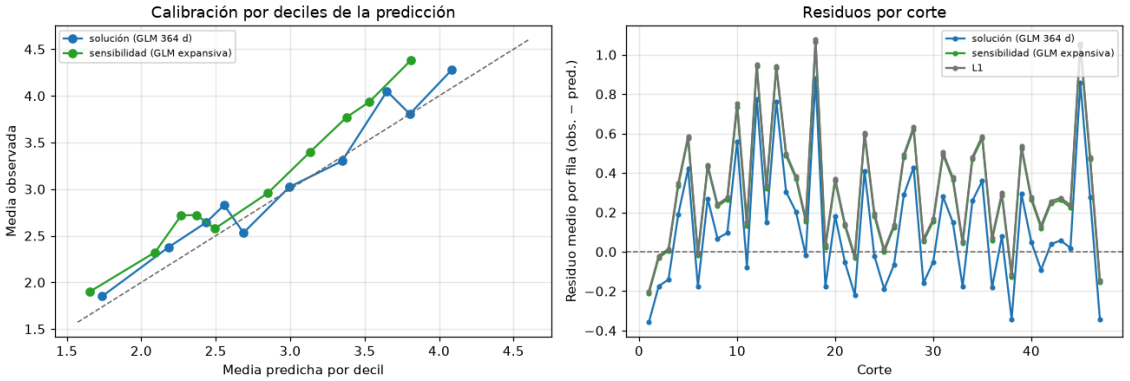
Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: experiments/evaluacion_final/tablas/12_semanas_mayor_desvianza.csv. Totales de los ocho municipios en la semana; ninguna contiene feriados.

Tabla G4 – Diferencias de desvianza corte a corte en el bloque final (descriptivas)

Comparación	Diferencia media	Error estándar de la diferencia	Cortes que gana / pierde
Solución - L1	-0,0295	0,0071	33 / 14
Sensibilidad - L1	-0,0030	0,0005	40 / 7
Contraste - L1	-0,0161	0,0084	22 / 25
Solución - sensibilidad	-0,0265	0,0067	33 / 14
Solución - media constante	-0,2088	0,0200	46 / 1

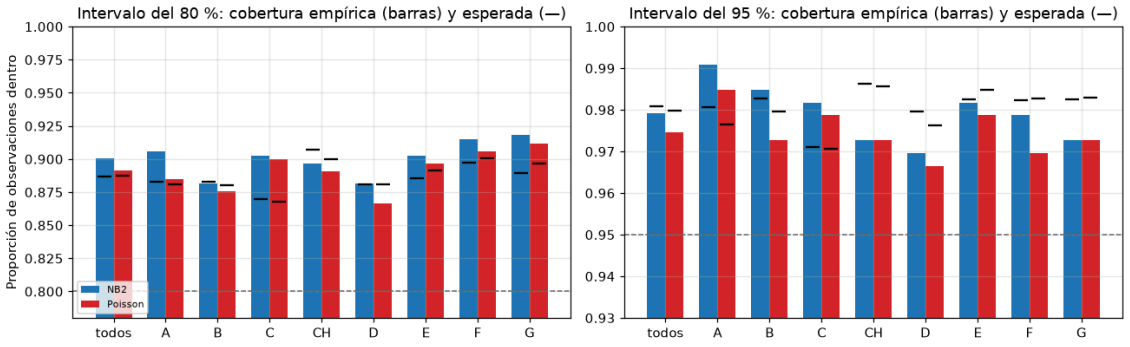
Fuente: elaboración propia en base a datos de la UNASEV; tablas de origen: experiments/evaluacion_final/tablas/09_pareado.csv. Los 47 cortes son semanas consecutivas de una misma serie: estas cifras describen el tamaño de la diferencia respecto de su variabilidad y no son pruebas de significación.

Ilustración G1 – Calibración por deciles y residuos por corte en el bloque final



Fuente: elaboración propia en base a datos de la UNASEV.

Ilustración G2 – Cobertura de los intervalos de predicción en el bloque final



Fuente: elaboración propia en base a datos de la UNASEV.